

Erkennung von Moiréstrukturen in digitalen Druckvorlagen mit Computer Vision Technologien

Masterarbeit
im Studiengang Informatik

vorgelegt von
Frederic Birwe
Matrikel-Nr.: 1271201

am 20.5.2024
an der Hochschule Bielefeld –
University of Applied Sciences and Arts (HSBI)

Erstprüfer: Prof. Dr.-Ing. Jan Rexilius
Zweitprüfer: Dr. Paul Glaysher

Die vorliegende Arbeit entstand in Kooperation mit den Unternehmen
Mohn Media Mohndruck GmbH und direct services Gütersloh GmbH BPG-IT

Zusammenfassung

In der Druckproduktion treten, insbesondere bei Verwendung von AM-Rastern, Interferenzen zwischen Strukturen im Motiv untereinander oder mit dem Druckraster auf. Die dadurch entstehenden Strukturen werden als Moirés bezeichnet. Da diese Moiréstrukturen nur schwer vor dem Druck zu erkennen sind und somit häufig erst zu einem späten Zeitpunkt in der Druckproduktion bemerkt werden, stellt das Problem eine relevante Herausforderung in der Qualitätssicherung der industriellen Druckproduktion dar.

Die vorliegende Arbeit untersucht Methoden zur Erkennung von Moiréstrukturen mit Hilfe von Computer Vision Technologien. Dafür wird ein Modell vorgestellt, welches in der Lage ist, synthetische Moirés zu erzeugen, indem Störstrukturen mit definierten Eigenschaften in Objekte zuvor moiréfreier Druckseiten montiert werden. Mit diesem Modell wurde ein Datensatz synthetischer Moirés erzeugt. Zusätzlich wurden reale Beispiele aus der Druckproduktion gesammelt. Die so erhobenen Daten wurden in drei Auflösungen, 150 dpi, 200 dpi und 300 dpi, in Kacheln gleicher Pixelgröße aufgeteilt. Auf dieser Basis wurden Deep Learning Modelle unter Verwendung der Resnet50 und der MobileNetV3 Architektur trainiert und deren Ergebnisse analysiert. Das Training erfolgte je einmal anhand des beschriebenen spatialen Datensatzes sowie auf Basis einer Umwandlung in die Frequenzdomäne mit Hilfe einer schnellen Fourier-Transformation. Die Ergebnisse wurden anhand eines Testdatensatzes aus realen und aus synthetischen Moirés separat geprüft.

Abstract

In the industrial print production occur interference patterns between structures in the motif or with the print screen on a regular basis. This happens especially if AM based screens are used. These interference patterns are known as moiré patterns. As these moiré structures are often difficult to detect before printing and are therefore often only noticed at a late stage in print production, the problem represents a relevant challenge in quality assurance in industrial print production.

This thesis investigates methods of recognizing moiré patterns in digital prepress data using computer vision technologies. For this purpose a model for generating synthetic moiré patterns is presented. It is able to generate moiré patterns by combining interfering patterns with defined properties with object of moiréfree pages. By using this model a dataset of synthetic moirés was generated. In addition, real examples from print production were collected. This data was divided into tiles of the same pixel size in three resolutions, 150 dpi, 200 dpi and 300 dpi. On this basis, deep learning models were trained using the Resnet50 and MobileNetV3 architecture and their results analyzed. For the training two datasets were used separately. The first contains spatial data, the second was created on the basis of a conversion to the frequency domain using a fast Fourier transformation. The results for the datasets and model architectures were checked separately using a test data set of real and synthetic moirés.

Inhaltsverzeichnis

Zusammenfassung	II
Abstract	II
1. Einleitung und Problemstellung	1
2. Theoretische Grundlagen des Moiréphänomens	2
2.1. Mathematische Beschreibung von Moiréstrukturen	3
2.2. Der Alias-Effekt	4
3. Grundlagen zur Erzeugung von farbigen Druckprodukten	6
3.1. Entstehung des Farbeindrucks im subtraktiven Farbsystem	6
3.2. Übertragung von Farbe auf den Bedruckstoff	6
3.3. Verwendung von amplitudenmodulierten und frequenzmodulierten Rastern zur Simulation eines Halbtonfarbeindrucks	8
3.3.1. Amplitudenmoduliertes Raster	9
3.3.2. Frequenzmoduliertes Raster	10
3.3.3. Erzeugung eines Unbuntaufbaus durch Verwendung von GCR-Software	11
4. Kategorisierung der im Druckkontext relevanten Moirés	12
4.1. Kategorisierung von Moirés anhand der Rahmenbedingungen der Entstehung	12
4.1.1. Entstehung von Moiréstrukturen im Halbtonbild	13
4.1.2. Entstehung einer Moiréstruktur durch Wechselwirkung von Bildstrukturen mit dem Druckraster	13
4.1.2.1. Entstehung von Moiréstrukturen durch Platzieren einer bereits gerasterten Vorlage	14
4.1.2.2. Entstehung eines Moirés durch Abrisseffekte in der Rastergenerierung	15
4.2. Kategorisierung anhand der geometrischen Eigenschaften der beteiligten Strukturen	15
4.2.1. Winkelunterschied	17
4.2.2. Skalierung	18
4.2.3. Perspektivische Verzerrung	20
4.2.4. Kreisförmiges Zusammenziehen und Expandieren	24
4.2.5. Wellenförmige Verzerrung	24
5. Aktueller Forschungsstand in der Moiréerkennung	26
5.1. Aktueller Forschungsstand in der Moiréentfernung	26
5.1.1. Multi-Scale Strategie	27
5.1.2. Nutzung der geometrischen Eigenschaften von Moiréstrukturen	27
5.1.3. Künstliche Generierung von Moirés	28
5.1.4. Übertragbarkeit auf die vorliegende Arbeit	28
6. Verwendete Technologien	29
7. Erstellung eines geeigneten Datensets	30
7.1. Vorverarbeitung und Auszeichnung der Druckseiten	32
7.2. Einrichtung einer geeigneten Bewertungssituation zur Bewertung von Moiréstrukturen	33
8. Algorithmus zur künstlichen Erzeugung von Moiréstrukturen	35
8.1. Erkennung von Objektmasken	37
8.2. Montage von künstlichen Störstrukturen in moiréfreie Seiten	38
8.2.1. Erstellung und Auswahl von Patternvorlagen	42
8.2.1.1. Technische Umsetzung der Erzeugung von Patternvorlagen	43
8.3. Anwendung von Patterneffekten	44
8.3.1.1. Rotation	44

2.	IV
<hr/>	
8.3.1.2. Skalieren und Verzerren	44
8.3.1.3. Gleichmäßige und ungleichmäßige perspektivische Verzerrung	44
8.3.1.4. Kreisförmiges Zusammenziehen und Expandieren	45
8.3.1.5. Wellenförmige Verzerrung	47
8.3.1. Algorithmus zur Auswahl der anzuwendenden Patterneffekte	47
8.4. Umwandlung Rasterabbildung	49
8.5. Auszeichnung der erzeugten Objektkacheln	49
9. Erstellung eines Klassifizierungsdatensatzes	50
9.1. Erstellung von Klassifizierungskacheln auf Basis erzeugter synthetischer Moirés	50
9.2. Umfang, Zusammenstellung und definierte Klassen des Klassifizierungsdatensatzes	51
9.3. Entfernung von Kacheln mit optisch nicht ausreichend erkennbarer Moiréstruktur	53
9.4. Frequenzbasierter Datensatz	53
9.5. Verwendung von Augmentierungen zur Steigerung der Robustheit des Datensatzes	55
10. Aufbau und Training des Klassifizierungsmodells	56
10.1. Vorabklassifizierung	56
10.2. Verwendete Modellarchitektur	57
10.3. Ablauf des Trainings und gewählte Hyperparameter	59
11. Diskussion der Ergebnisse	60
11.1. Auswertung der Patternerstellung	60
11.1.1. Auswertung nach Eigenschaften der Patternvorlagen	60
11.1.2. Einfluss der Eigenschaften der unveränderten Objektkachel	62
11.1.3. Auswertung anhand der verwendeten Effekte	62
11.1.4. Berechnung des Einflusses der Effektparameter	63
11.2. Auswertung der trainierten Klassifizierungsmodelle	65
11.2.1. Ergebnisse auf Basis der Klassifizierungskacheln	66
11.2.2. Auswertung der Ergebnisse gruppiert nach Auflösung der Klassifizierungskacheln	68
11.2.3. Auswertung der Ergebnisse gruppiert nach Objektkacheln	68
11.2.4. Verwendung der Modelle als Ensemble	72
12. Fazit und Ausblick	74
12.1. Erzeugung von synthetischen Moiréstrukturen	74
12.2. Aufbau und Training der Klassifizierungsmodelle	75
Glossar	76
Literaturverzeichnis	78
Abbildungsverzeichnis	81
Anhang	83

1. Einleitung und Problemstellung

Als Moirés werden optisch sichtbare regelmäßige Muster bezeichnet, die durch Interferenz von zwei oder mehr sich überlagernden periodischen Strukturen entstehen. In der Druckproduktion stellen Moirés eine signifikante Qualitätsminderung der hergestellten Druckprodukte dar und sollen daher vermieden werden. Die Erkennung und Vermeidung von Moirés ist jedoch eine nicht triviale Herausforderung. Dies liegt vor allem darin begründet, dass Moirés im Druck in vielen Fällen durch Interferenz mit dem zur Erzeugung des Farbeindrucks verwendeten Druckrasters (siehe: Abs. 3.3) entstehen und damit erst zu einem späten Zeitpunkt im Herstellungsprozess potenziell erkennbar sind. Zudem ist die Bewertung von potenziellen Moiréstrukturen am Bildschirm nur mit Einschränkungen möglich, da hier die Skalierung der Abbildung und das Pixelraster des Bildschirms als zusätzliche Faktoren, die zur Entstehung eines Moirés führen können, berücksichtigt werden müssen.

Moirés, welche die Qualität eines Druckproduktes maßgeblich mindern, sind ein seltenes Phänomen. Aus den oben beschriebenen Gründen werden sie jedoch häufig erst entdeckt, wenn bereits die gesamte oder relevante Teile der Auflage des Produktes bereits hergestellt sind. Dadurch kann das Auftreten von Moirés zu hohen Fehlerkosten führen.

Um diesem Problem zu begegnen, soll im Rahmen dieser Arbeit untersucht werden, inwiefern in der Druckproduktion entstehende Moirés mit Methoden der Computer Vision auf Basis der digitalen Druckvorlage erkannt werden können. Anders als im Falle der Entstehung von Moiréstrukturen durch Foto- oder Videoaufnahmen von Bildschirmen (siehe: Abs. 5), ist für das hier bearbeitete Problem eine Erkennung anstatt einer Entfernung von Moirés das angestrebte Ziel.

Wird ein Moiré erkannt, so kann es durch manuelle Korrektur der Druckvorlagen in der überwiegenden Zahl der Fälle entfernt werden. Idealerweise erfolgt diese Korrektur durch den Ersteller der Druckvorlagen. Dies ist in den meisten Fällen nicht die Druckerei sondern der Kunde der Druckerei oder eine von ihm engagierte Grafikagentur. Ein automatisierter Eingriff in die Druckvorlagen soll vermieden werden.

Die Erkennung von Moirés beinhaltet eine Reihe von Herausforderungen, welche das Problem von anderen Bildklassifizierungsproblemen unterscheidet. So können Moirés eine Vielzahl an optischen Erscheinungsbildern annehmen (siehe: Abs. 4.2). Zudem handelt es sich bei Moirés um Low-Level Eigenschaften der zu klassifizierenden Bilder, also isolierte Linien- und Kurvenformen, die sich nicht zu komplexeren Objekten verbinden. Die High-Level Features, also die konkret abgebildeten Objekte sollen hingegen durch ein Klassifizierungsmodell ignoriert werden.

In den folgenden Kapiteln werden eine Reihe von Begriffen eingeführt. Die sind in einem der Arbeit angehängten Glossar erklärt.

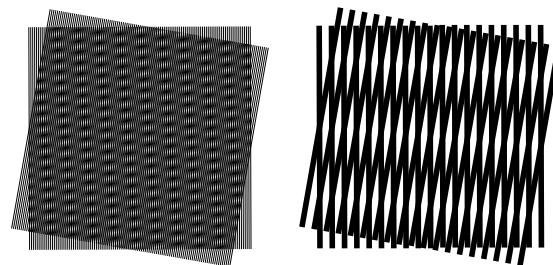
2. Theoretische Grundlagen des Moiréphänomens

Als Moiréphänomen werden Effekte bezeichnet, die durch die Interferenz von zwei oder mehr regelmäßigen Strukturen entstehen. Sie treten als zusätzliche optisch sichtbare regelmäßige Strukturen auf. Diese regelmäßigen Strukturen werden nachfolgend als Moiréstrukturen oder als Moiré bezeichnet. Ein Beispiel ist in ABB. 2.1 zu sehen. Moiréphänomene entstehen nicht nur durch die Eigenschaften des menschlichen Sehapparates, wie beispielsweise die Erzeugung eines Halbtontarbeindrucks im Druck (siehe: Abs. 3.3) sondern sind wirkliche messbare Eigenschaften der überlagernden Strukturen.

Das optische Erscheinungsbild von Moirés variiert stark in Abhängigkeit von den Eigenschaften der interferierenden Strukturen. Eine umfangreiche Übersicht über mögliche optische Erscheinungsbilder von Moirés findet sich in [1]. Auf optische Erscheinungsbilder von Moirés, die im Kontext der Druckproduktion besonders relevant sind, wird in Abs. 4 eingegangen. Eine wesentliche Eigenschaft von Moirés ist, dass ihr optisches Erscheinungsbild bei minimalen Änderungen an den geometrischen Eigenschaften der interferierenden Strukturen stark schwankt[2](1.1).

Moirés können in vielen unterschiedlichen Umfeldern beobachtet werden. ABB. 2.2 zeigt Beispiele für Moirés, die im Alltag beobachtet werden können. Eine im Bereich der 2D-Grafik besonders relevante Ursache für Moirés ist der so genannte Alias-Effekt. Dieser beschreibt das Auftreten von unerwünschten Strukturen bei Abtastung eines Signals mit zu niedriger Abtastrate. Auf den Alias-Effekt wird in Abs. 2.2 im Detail eingegangen. Ein Beispiel für das Entstehen von Moirés durch den Alias-Effekt ist in ABB. 2.5 zu sehen.

Darüber hinaus wird der Moiréeffekt in einer Vielzahl von Bereichen für spezielle Anwendungen genutzt, darunter beispielsweise die Herstellung von Spezialmaterialien[4], Anwendungen in der Messtechnik[5] oder Steigerung der Robustheit gegen Fälschungen in Gesichtserkennungsanwendungen[6].



1.

2.

ABB. 2.1. Beispiel für ein Moiré durch Überlagerung von Linienstrukturen mit identischer Periode und unterschiedlicher Winkelung. 2. zeigt einen Detailausschnitt aus 1.



1.



2.

ABB. 2.2. Beispiele für Moiréeffekte, die im Alltag beobachtet werden können. 1. zeigt ein Moiré, dass durch die Überlagerung der Brückengeländer entsteht. Da das hintere Geländer aus der Betrachtungsperspektive im Vergleich zum vorderen Geländer versetzt und verkleinert erscheint, überlagern sich die Metallstreben mit einer gewissen Frequenz, wodurch optisch ein zusätzliches Muster entsteht. 2. zeigt ein Moiré, dass durch die Überlagerung eines netzartigen Stoffes entsteht. Die beiden Stofflagen sind jeweils unterschiedlich verformt, wodurch zusätzliche optische Effekte durch Überlagerung entstehen.

2.1. Mathematische Beschreibung von Moiréstrukturen

In [2] werden Methoden zur Beschreibung von Moiréstrukturen durch Betrachtung der beteiligten Raster im Frequenzraum vorgestellt. Dafür werden die interferierenden Strukturen mit Hilfe einer Fourier-Transformation[3] in ihre Frequenzbestandteile zerlegt. Beispiele für Strukturen im Bild und ihre jeweilige Repräsentation im spektralen Raum finden sich in ABB. 2.3 (1.) und (2.) beziehungsweise (4.) und (5.). ABB. 2.3 (1.) und (2.) zeigen kosinusförmige Strukturen, um für diese Grafiken einzelne Impulse in der Frequenzansicht zu erhalten. Die durch die Fourier-Transformation extrahierten Sinus- und Kosinusbestandteile werden als Impulse (f) bezeichnet. Jeder Impuls besteht aus einem Impuls-

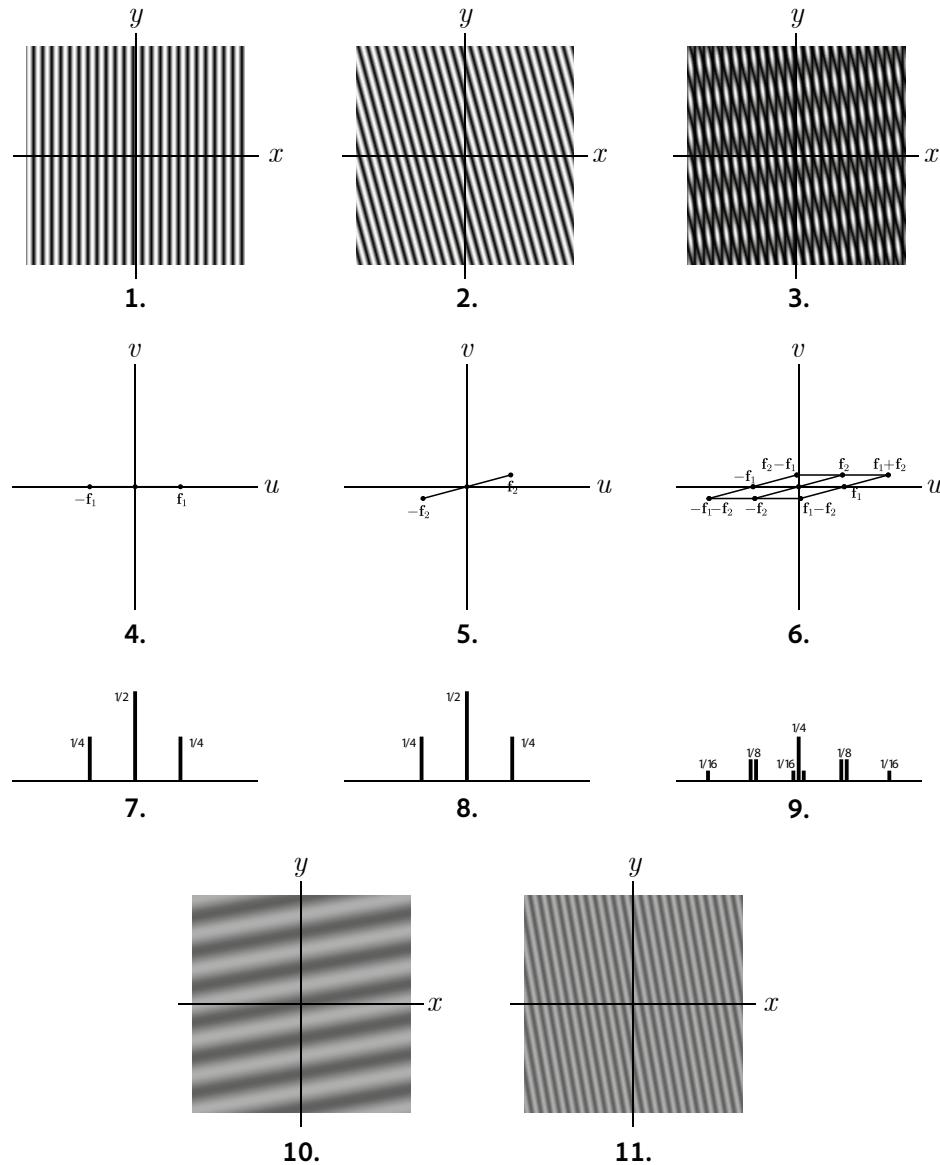


ABB. 2.3. Die erste Reihe zeigt kosinusförmige Strukturen (1.) und (2.) und ihre Überlagerung (3.) im Bildbereich. Die zweite Reihe zeigt in 4. und 5. die jeweiligen Spektren von 1. und 2. sowie deren Faltung (6.). Die schwarzen Punkte in den Spektren zeigen die geometrischen Orte der Impulse an. Die Liniensegmente wurden nur zur Verdeutlichung der geometrischen Beziehungen hinzugefügt. 7., 8. und 9. zeigen die Seitenansicht der selben Spektren zur Visualisierung der Impulsamplituden. Man beachte die beiden neuen Impulspaare die in der Spektralfaltung (9.) erschienen sind. Diese neu erschienenen Impulse sind isoliert in der Bildform in 10. und 11. dargestellt.

paar. Diese Impulspaare haben jeweils den selben Abstand zum Ursprung und liegen sich punktsymmetrisch zum Ursprung gegenüber. Die Polarkoordinate des Impulses gibt Auskunft über Frequenz und Winkelung der Struktur im Bildraum. Der Abstand zum Ursprung entspricht der Frequenz (f) der Struktur im Bildraum. Der Winkel (θ) des Impulses entspricht dem Winkel im Bildraum + 90°. Zusätzlich zu den Impulspaaren existiert ein einzelner Impuls am Ursprung des Frequenzdiagrammes. Dieser wird als DC-Impuls bezeichnet und äußert sich im Bild als konstanter Tonwert. ABB. 2.3(3.) zeigt eine Überlagerung der Strukturen aus ABB. 2.3 (1.) und (2.) durch Multiplikation der Impulse. Mathematisch lässt sich die Überlagerung von Impulsen wie folgt beschreiben: Gegeben sind die Impulsfunktionen $r_1(x, y)$ (ABB. 2.3(1.)) und $r_2(x, y)$ (ABB. 2.3 (2.)). Ihre jeweilige Darstellung im Frequenzraum (ABB. 2.3 (4.) und (5.)) wird durch $R_1(u, v)$ und $R_2(u, v)$ beschrieben. Eine Überlagerung wie in ABB. 2.3 (3.) zu sehen ergibt sich aus der Multiplikation der Impulsfunktionen (siehe: (2.1))

$$(2.1) \quad r_1(x, y) \cdot r_2(x, y)$$

Dem Faltungstheorem[7] folgend kann das Gegenstück im Frequenzraum durch Faltung mit der Frequenzdarstellungen R_1 und R_2 dargestellt werden (siehe: (2.2)).

$$(2.2) \quad R_1(u, v) * R_2(u, v)$$

Das Ergebnis ist in ABB. 2.3 (6.) zu sehen. Zusätzlich zu den in ABB. 2.3(4.) und ABB. 2.3(5.) vorhandenen Impulsen sind in ABB. 2.3(6.) durch Faltung zwei weitere Impulspaare hinzugekommen, eines mit einer niedrigeren und eines mit einer höheren Frequenz als die beiden ursprünglich beteiligten Impulse. Diese zusätzlichen Impulse sind in ABB. 2.3(3.) erkennbar. Zur Veranschaulichung sind die Impulse in ABB. 2.3(10.) und (11.) zusätzlich jeweils isoliert in der Bildform abgebildet. Die Eigenschaften des menschlichen Sehapparates sorgen dafür, dass sehr hohe und sehr niedrige Frequenzen optisch nicht mehr wahrnehmbar sind. Die Grenzwerte sind nicht allgemein definierbar, da sie von weiteren Faktoren wie Kontrast, Beleuchtungssituation oder dem Betrachtungsabstand abhängen. Zusätzlich sind die maximal und minimal sichtbaren Frequenzen auch abhängig vom Winkel der Struktur. Frequenzen, die auf dem 45° Winkel liegen, sind für das Auge am wenigsten wahrnehmbar [2](Abs. 2.2, S.13) (siehe: Abs. 3.3.1).

2.2. Der Alias-Effekt

Das Nyquist-Shannon Theorem beschreibt, dass zur verlustfreien Abtastung eines Signals mit einer maximalen Frequenz f_{\max} eine Abtastfrequenz f_{abtast} gewählt werden muss, für die gilt: $f_{\text{abtast}} > 2f_{\max}$. Die Frequenz $f_{\text{abtast}}/2$ wird als Nyquist-Frequenz (f_{nyquist}) bezeichnet. Jede Frequenz f für die gilt $f < f_{\text{nyquist}}$ ist verlustfrei wiederherstellbar[3](S.219). Die Gültigkeit des Theorems lässt sich anhand von ABB. 2.4 optisch leicht erkennen.

Wird die Nyquist-Frequenz überschritten, kann dies zum sogenannten Alias-Effekt führen. Durch eine zu geringe Abtastrate werden die abzutastenden Frequenzen unzureichend rekonstruiert. Im Falle von Bildern äußern sich Alias-Effekte in Form von unerwünschten Strukturen, die zu den Moiréstrukturen gezählt werden können. Ein Beispiel ist in ABB. 2.5 abgebildet.

Im Herstellungprozess von Druckprodukten findet mehrfach eine Abtastung von kontinuierlichen oder diskreten Bildsignalen statt. Zunächst wird häufig ein reales Objekt mit Hilfe einer Digitalkamera fotografiert. Dabei findet eine Abtastung durch den Sensor der Kamera statt. Weitere Abtastungen können bei der digitalen Nachbearbeitung der aufgenommenen Bilder stattfinden.

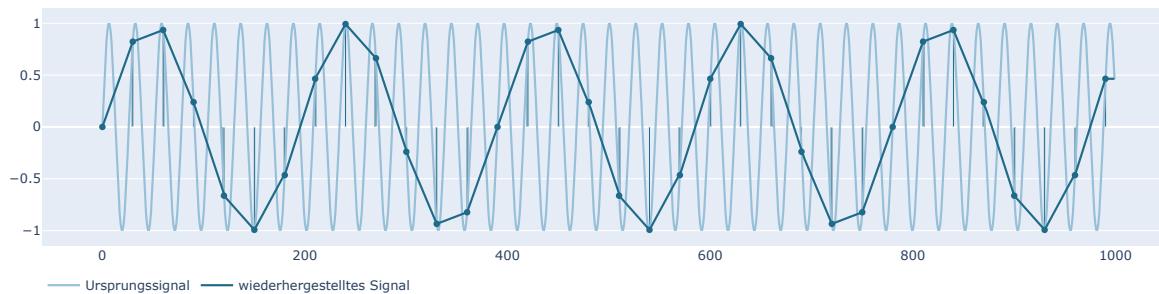


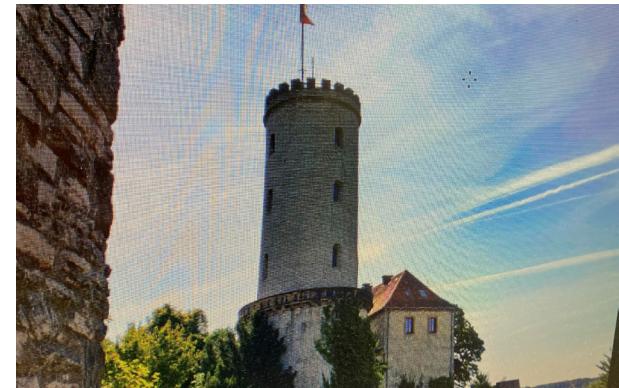
ABB. 2.4. Beispiel für die Entstehung des Alias-Effektes. Die verwendete Abtastrate ist unzureichend, wodurch das wiederhergestellte Signal eine deutlich andere Form annimmt als das Ursprungssignal.

Wird beispielsweise das Bild auf ein neues Pixelformat skaliert, so findet auch hier eine Abtastung statt. Schließlich werden Halbtonabbildungen vor dem Druck in Rasterpunkte zerlegt. Dieser Vorgang wird in Abs. 3.3 beschrieben. Hier erfolgt eine Abtastung mit der verwendeten Rasterweite als Abtastfrequenz. Auf die Abtastzeitpunkte im Laufe der Herstellung eines Druckproduktes wird in Abs. 4.1 im Detail eingegangen.

In Hinblick auf die in Abs. Abb. 2.1 beschriebene mathematische Beschreibung der Überlagerung zweier Raster gilt für Alias-Effekte das folgende: Das Originalbild kann mit $r_1(x, y)$ beschrieben werden. Die sich aus der Abtastfrequenz ergebenden Impulse werden mit $r_2(x, y)$ dargestellt. Die Abtastung kann durch das Produkt von $r_1(x, y)$ und $r_2(x, y)$ dargestellt werden. Daraus folgt, dass das Spektrum des abgetasteten Zielbildes durch Faltung von $R_1(u, v)$ und $R_2(u, v)$ berechnet werden kann[2](Abs. 2.13, S.48f). Diese Berechnung entspricht der Berechnung für die Überlagerung von Frequenzen (siehe: Abs. 2.1), woraus folgt, dass für so entstehenden Moiréeffekte angenommen werden kann, dass sich auch deren optisches Erscheinungsbild gleicht.



1. Originalbild



2. Kameraaufnahme
des Bildes vom Bildschirm

ABB. 2.5. Beispiel für das Wirken des Alias-Effektes in der Darstellung von Bildern. 1. zeigt das Originalbild. 2. zeigt eine Aufnahme des selben Bildes dargestellt am Bildschirm. Das Ursprungssignal ist in diesem Fall das Pixelraster des Bildschirms, die Abtastfrequenz wird durch die Auflösung des Pixelrasters des Kamerasensors bestimmt. Diese ist in der dargestellten Aufnahmesituation ungeeignet, um das Bildsignal verlustfrei wiederherzustellen.

3. Grundlagen zur Erzeugung von farbigen Druckprodukten

Zum Verständnis des in Abs. 1 beschriebenen Problems wird nachfolgend auf die notwendigen drucktechnischen Grundlagen und deren Relevanz für die Entstehung von Moiréstrukturen eingegangen. Dafür wird zunächst die Entstehung des Farbeindrucks bei nichtselbstleuchtenden Farbquellen beschrieben. Darauf aufbauend wird auf die Farübertragung im Offsetdruck mittels einer Druckform und Umwandlung der Abbildung in eine Rasterdarstellung eingegangen. Abschließend wird die Technologie Gray Component Replacement beschrieben. Diese ändert die Zusammenstellung der einzelnen Grundfarben und wirkt sich auf die im Rahmen dieser Arbeit angenommenen Prämissen aus.

3.1. Entstehung des Farbeindrucks im subtraktiven Farbsystem

Bei einem Druckprodukt handelt es sich um eine nichtselbstleuchtende Farbquelle. Der Farbeindruck entsteht durch eine subtraktive Farbmischung. Das bedeutet, zunächst treffen alle im Umgebungslicht vorhandenen Lichtwellen auf eine Oberfläche. Je nach Färbung des Materials beziehungsweise je nach aufgebrachter Farbe werden nur bestimmte Lichtwellenbereiche remittiert, während die übrigen absorbiert werden[8](Abs. 1.4.1) (siehe: ABB. 3.1). Aus diesem Grund werden im Druck nicht die Grundfarben der additiven Farbmischung, Rot, Grün und Blau (RGB), verwendet. Stattdessen werden als Grundfarben Cyan (C), Magenta (M) und Gelb (Y) genutzt. Aus weiteren drucktechnischen Gründen kommt Schwarz (K) als vierte Grundfarbe hinzu[10](Abs.1.3.1)[8](S.408ff). Einige Druckverfahren wie Inkjet[8](Abs.5.5.5) verwenden darüber hinaus weitere Grundfarben. Zudem ist es in vielen Druckverfahren möglich, Spezialfarben wie Neonfarben, Metalllacke etc. aufzubringen[10](Abs. 2.4.2)[11]. Im Kontext dieser Arbeit werden ausschließlich die vier Grundfarben Cyan, Magenta, Gelb und Schwarz betrachtet. Diese Grundfarben werden zusammengekommen mit CMYK oder 4c abgekürzt.

3.2. Übertragung von Farbe auf den Bedruckstoff

Die unterschiedlichen Druckverfahren werden dadurch voneinander abgegrenzt, auf welchem technischen Wege die Farübertragung stattfindet beziehungsweise wie die nicht druckenden und druckenden Stellen technisch voneinander separiert werden. In den druckformgebundenen Druckverfahren Tiefdruck, Flexodruck und Offsetdruck werden feste Druckformen verwendet. Sie unterscheiden sich durch das jeweilige Prinzip, dass zur Unterscheidung druckender und nicht druckender Stellen angewandt wird (siehe: ABB. 3.2). Für jede der im vorherigen Abschnitt genannten Grundfarben (CMYK) wird eine separate Druckform erzeugt. In der Druckmaschine werden nacheinander die Farbinformationen der einzelnen Grundfarben mit Hilfe der jeweils

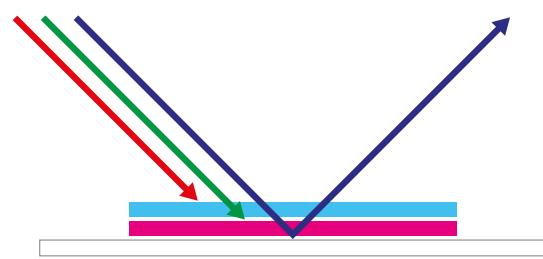


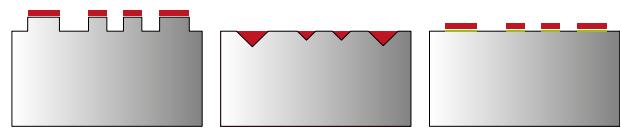
ABB. 3.1. Veranschaulichung der subtraktiven Farbmischung. Zunächst treffen alle im Licht vorhandenen Wellenlängen auf den Bedruckstoff. Die aufgebrachte Cyan-Farbfläche absorbiert die roten Farbanteile. Die Magenta-Farbfläche absorbiert die grünen Farbanteile. Lediglich die blauen Farbanteile werden remittiert, wodurch ein blauer Farbeindruck entsteht.

erstellten Druckform übertragen. In den nicht-druckformgebundenen Druckverfahren entsteht die Unterscheidung erst während des Druckvorganges in der Druckmaschine beziehungsweise im Drucker (siehe: [8](Abs. 1.3.1)). Allen genannten Druckverfahren ist gemein, dass sie für eine Stelle auf dem Bedruckstoff lediglich festlegen, ob für diesen Bereich eine Farübertragung erfolgen soll. Eine Intensität kann nicht definiert werden. Eine Farbe, die durch Addition oder Subtraktion der jeweiligen Grundfarben in jeweils kontinuierlichen Intensitäten entsteht, bezeichnet man als Halbtonfarbe. Um beim Betrachter einen Halbtonfarbeindruck zu erzeugen, werden spezielle Rastertechnologien verwendet, auf die in Abs. 3.3 näher eingegangen wird.

Die vorliegende Arbeit bezieht sich ausschließlich auf das Verfahren des Offsetdrucks. Ergeben sich in Abgrenzung zu den übrigen oben genannten Verfahren relevante Abweichungen wird an den entsprechenden Stellen darauf hingewiesen.

Der Offsetdruck ist eine Technologie aus der Gruppe der Flachdruckverfahren. Als Druckform dient in der Regel eine Aluminiumplatte. Diese ist im unbelichteten Zustand mit einem oleophilen Material beschichtet. Im Belichtungsprozess werden diejenigen Stellen, die im späteren Druckprozess Farbe übertragen sollen, mit einem Laser belichtet und damit ausgehärtet. Die Bereiche der Druckplatte, auf denen keine Farbe übertragen werden soll, werden nicht belichtet. Nach der Belichtung wird die Druckplatte entwickelt. Dabei wird in den nicht belichteten Bereichen die Beschichtung chemisch gelöst und abgewaschen. Schließlich wird die Druckplatte zur Erhöhung der Lebensdauer in einem Ofen eingebrannt[8](Abs. 2.1.1.2).

In der Druckmaschine entsteht der Farbeindruck indem zunächst die gesamte Druckplatte mit der jeweiligen Grundfarbe eingefärbt wird. Die Farbe haftet an den beschichteten und damit oleophilen Stellen, während sie an den übrigen Stellen abgestoßen wird. Nach der Einfärbung wird die Platte mit einem Feuchtmittel abgewaschen. Nur die Farbe an den belichteten Stellen verbleibt und wird zuerst auf einen Gummituchzylinder und von dort auf den Bedruckstoff übertragen[8](Abs. 2.1.1.3). Das Bauteil einer Druckmaschine, in dem die Farübertragung für eine der Grundfarben erfolgt, wird als Druckwerk bezeichnet. Üblicherweise verfügt eine Druckmaschine über vier oder acht Druckwerke. Im Falle von vier Druckwerken wird eines für jede der Grundfarben verwendet. Im Falle von acht Druckwerken erfolgt nach den ersten vier Druckwerken eine Wendung, sodass in den hinteren vier Druckwerken die Rückseite des Druckbogens ebenfalls mit jeder der vier Druckfarben bedruckt wird (siehe: ABB. 3.3).



1. Hochdruck 2. Tiefdruck 3. Flachdruck

ABB. 3.2. Übersicht über die relevantesten Farübertragungsprinzipien druckformgebundener Druckverfahren. Im Hochdruck (1.) sind die druckenden Stellen der Druckform erhaben. Beim Abdruck auf einen Bedruckstoff wird nur an diesen Stellen Farbe übertragen. Beispiele für Hochdruckverfahren sind der Flexodruck oder historisch der Buchdruck mit beweglichen Bleilettern. Im Tiefdruck (2.) sind die druckenden Stellen einer Druckform vertieft. Das relevanzeste Druckverfahren, dass auf dem Tiefdruckprinzip beruht, wird ebenfalls als Tiefdruck bezeichnet. Vor dem Abdruck auf den Bedruckstoff wird die Druckform flächig mit Farbe benetzt. Danach wird überschüssige Farbe mit Hilfe eines Rakels entfernt. Lediglich die Farbe in den Vertiefungen verbleibt und wird auf den Bedruckstoff übertragen. Im Flachdruck (3.) gibt es keine relevanten Höhenunterschiede auf der Druckform. Stattdessen sind die druckenden Bereiche mit einer Beschichtung versehen, welche die verwendete Farbe chemisch bindet (oleophil), während die übrigen Bereiche der Druckform die Farbe abstoßen (oleophob). Das relevanzeste Druckverfahren ist hier der Offsetdruck[8](S.31).

3.3. Verwendung von amplitudenmodulierten und frequenzmodulierten Rastern zur Simulation eines Halbtonfarbeindrucks

Wie zuvor dargestellt, ist es im Offsetdruck nicht möglich, echte Halbtonfarben zu erzeugen. Um optisch einen Halbton abilden zu können werden so genannte Rasterpunkte erzeugt. Hierfür wird die Druckform in Bereiche gleicher Größe geteilt. Diese Bereiche werden als Rasterzellen bezeichnet. Für jede dieser Rasterzellen wird der dort jeweils gewünschte Farbeindruck erzielt, indem ein Anteil der Fläche entsprechend der gewünschten Intensität der Farbe belichtet wird [8](Abs. 1.4.3) (siehe: ABB. 3.4). Durch den Abstand des Betrachters zum Druckprodukt sind die einzelnen Rasterpunkte für das Auge nicht mehr differenzierbar und optisch entsteht der Eindruck eines Halbtone.

Belichtungsmaschinen haben im Offsetdruck üblicherweise eine Auflösung von 2400 dots per inch (dpi), können also mit einer Feinheit von 1/2400 Inch Bereiche der Beschichtung belichten.

Die Größe der einzelnen Rasterzellen wird als Rasterweite bezeichnet. Diese wird in Form ihrer Frequenz als „Linien (entspricht: Wiederholungen) pro Zoll“ oder „lines per inch“ (lpi) angegeben. Im Offsetdruck sind 150 oder 175 lpi übliche Werte, es können jedoch auch höhere oder geringere Frequenzen verwendet werden. Die konkrete Wahl einer geeigneten Rasterweite hängt von drucktechnischen Parametern wie dem verwendeten Papier, der gewünschten Abbildungsqualität und ähnlichem ab.

Eine Software, mit welcher eine Halbtonabbildung in eine Rastergrafik umgewandelt werden kann, wird als Raster-Image Prozessor bezeichnet. Darüber hinaus übernimmt ein Raster-Image Prozessor weitere Aufgaben, wie die Umwandlung von Text und Vektorgrafiken in Pixelgrafiken oder die Reduzierung von Transparenzen. Diese sind im Rahmen dieser Arbeit jedoch nicht relevant [10](S.232ff, Abs. 4.4.3). Die Verteilung der belichteten Pixel innerhalb einer Rasterzelle kann nach einem der beiden folgenden Prinzipien erfolgen:

- als Amplitudenmoduliertes (AM) Raster
- als Frequenzmoduliertes (FM) Raster

Diese werden nachfolgend in Abs. 3.3.1 und Abs. 3.3.2 im Detail beschrieben. Darüber hinaus können auch Hybridraster verwendet werden, welche die Eigenschaften von AM- und FM-Rastern kombinieren. Diese werden im Rahmen dieser Arbeit nicht weiter betrachtet. Die Mehrzahl der herge-

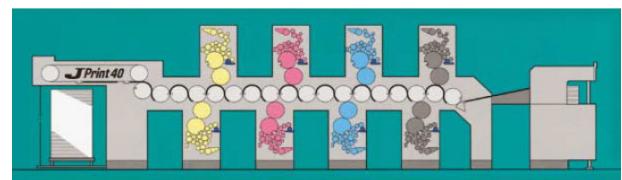


ABB. 3.3. Schematischer Querschnitt durch eine Bogenoffsetdruckmaschine. Das zu bedruckende Papier wandert von rechts nach links durch die Maschine. Die Grundfarben werden nacheinander auf das Papier übertragen. Die Reihenfolge ist üblicherweise von hell nach dunkel, also Schwarz, Cyan, Magenta und Gelb. Im gezeigten Beispiel sind jeweils vier Druckwerke ober- und unterhalb des zu bedruckenden Bogens angeordnet, sodass beide Seiten des Druckbogens ohne Wendung in einem Druckdurchgang bedruckt werden können.

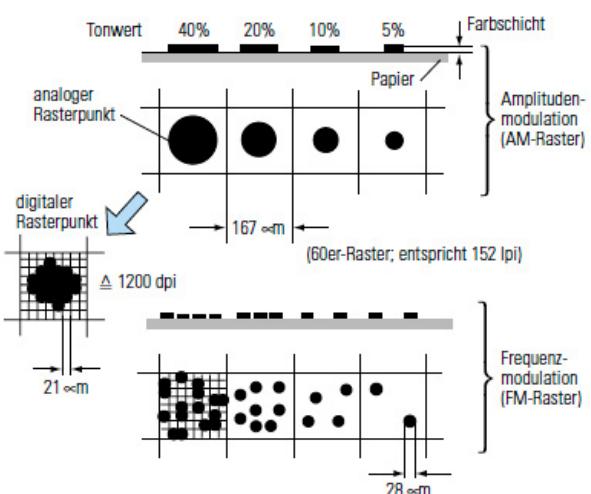
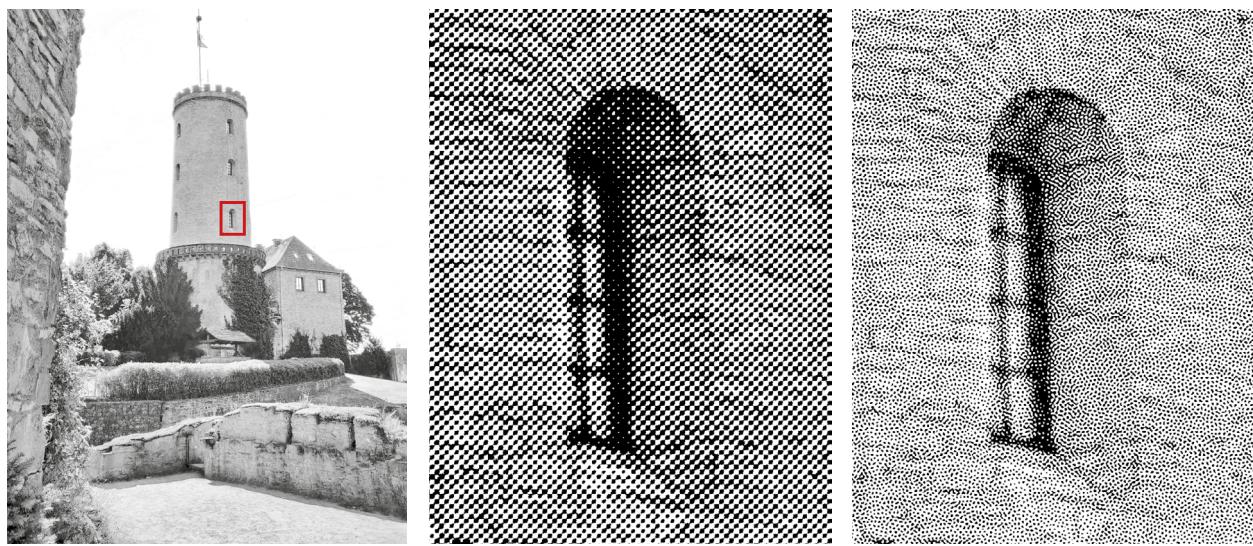


ABB. 3.4. Vergleich von amplituden- und frequenzmodulierten Rastern. Die Verteilung der Punkte eines frequenzmodulierten Rasters innerhalb einer Rasterzelle erfolgt zufällig. Dadurch soll die Bildung von regelmäßigen Strukturen und damit die Wahrscheinlichkeit für die Entstehung von Moirés verringert werden.



**1. gesamte Abbildung
(mit Markierung des
Ausschnitts in 2. und 3.)**

**2. markierter Ausschnitt aus
1. im AM-Raster**

**3. markierter Ausschnitt aus
1. im FM-Raster**

ABB. 3.5. Vergleich des optischen Erscheinungsbildes zwischen AM- und FM-Raster. 2. und 3. zeigen jeweils den selben Bildausschnitt des Schwarzkanals aus 1. 2. zeigt den Ausschnitt im AM-Raster mit 150 lpi und elliptischem Rasterpunkt. 3. zeigt den Ausschnitt im FM-Raster mit einer Korngröße von 40 μ . Der verwendete AM-Raster Algorithmus ist Maxtone von Kodak, der verwendete FM-Raster Algorithmus Staccato, ebenfalls von Kodak [9].

stellten Druckformen wird im AM-Rasterverfahren produziert. Dieses verwendet periodisch angeordnete Rasterpunkte zur Darstellung von Farbintensitäten. Insbesondere diese Eigenschaft macht das Verfahren anfällig für die Entstehung von Moiréstrukturen. Dies wird im Detail in Abs. 4.1.2 beschrieben. Die Verwendung von FM-Rasterverfahren reduziert die Gefahr der Entstehung von Moiréstrukturen erheblich. Aus anderen drucktechnischen Gründen eignen sich FM-Rasterverfahren nicht für eine Verwendung als Standardverfahren. Die Gründe hierfür werden in Abs. 3.3.2 beschrieben.

3.3.1. Amplitudenmoduliertes Raster

Bei Verwendung des amplitudenmodulierten Rasters werden die belichteten Pixel innerhalb einer Rasterzelle so angeordnet, dass sie einen einzelnen sogenannten Rasterpunkt bilden. Die Größe dieses Rasterpunktes richtet sich nach dem Flächendeckungsgrad. Damit bleibt die Anzahl der Rasterpunkte im amplitudenmodulierten Raster unabhängig vom Flächendeckungsgrad gleich, während die Größe der Rasterpunkte variabel ist [10](S.236 ff) (siehe: ABB. 3.5(2)). Die Rasterpunkte werden in einer gleichmäßigen periodischen Rasterform angeordnet.

Die Punktform wird in der Regel elliptisch gewählt. Dadurch wächst der Rasterpunkt bei ansteigender Flächendeckung in vertikaler Richtung stärker als in horizontaler Richtung. Ab einer bestimmten Flächendeckung ist der Rasterpunkt so weit angewachsen, dass er den Rasterpunkt der benachbarten Zelle berührt. Dies nennt man Punktschluss. Bei einer elliptischen Punktform gibt es zwei Punktschlüsse. Der erste Punktschluss findet in vertikaler Richtung statt, der zweite Punktschluss in horizontaler Richtung. Dies verringert den optisch wahrnehmbaren Sprung im Farnton beim Punktschluss [10](S.240).

Ein Übereinanderdruck der vier Farben (Cyan, Magenta, Gelb und Schwarz) ohne Versatz zueinander ist zur industriellen Druckproduktion nicht geeignet. Beim perfekten Übereinanderdruck der Punk-

te entsteht zwar der gewünschte Farbeindruck, allerdings können schon geringe Abweichungen in Positionierung und Winkelung der Raster zueinander zu Farbschwankungen sowie deutlich sichtbaren Moiréstrukturen führen. Die geringsten Interferenzen bilden sich bei einem Winkelabstand der Raster zueinander von 30° . Zudem ist das Auge am wenigsten empfindlich für Strukturen, die auf 45° gewinkelt sind [2](Abs.2.2). Daher sollte die dunkelste der vier Farben, das Schwarz, auf diesem Winkel platziert werden. Die Winkelungen der Farben werden als Rasterwinkel bezeichnet. Ausgehend von den genannten beiden Prämissen fällt auf, dass sich die vier Farben nicht mit einem gleichmäßigen Abstand von 30° platzieren lassen. Daher wird die hellste der Farben, das Gelb, nur im 15° Abstand zu den übrigen Farben platziert[8](S.498ff). In der DIN 16547 sind, entsprechend den beschriebenen Regeln, die folgenden Rasterwinkel als Standard definiert [10](S.242):

- Gelb (Y) 0°
- Cyan (C) 15°
- Schwarz (K) 45°
- Magenta (M) 75°

Diese gelten für in alle vier Richtungen gleichmäßig geformte Rasterpunkte. Bei diesen können die Farben auf den Winkelbereich von 0° bis 89° verteilt werden, da ein mit 90° gewinkeltes Raster einem mit 0° gewinkelten Raster entspricht. Bei Verwendung eines nicht gleichmäßig geformten, beispielsweise eines elliptischen, Rasterpunktes wird das Schwarz in der Regel auf einem Winkel von 135° platziert. Dies entspricht aufgrund der 90° -Periodizität dem 45° -Winkel.

Durch die Verwendung dieser Rasterwinkel entstehen Interferenzen der Raster der einzelnen Farben zueinander und damit per Definition immer Moiréstrukturen im Druckbild. Durch die beschriebene Optimierung der Rasterwinkel sowie die unterschiedlichen Helligkeiten der Farben haben diese Moirés sehr selten eine Intensität, die vom Auge als störend wahrgenommen wird, und werden daher in dieser Arbeit nicht berücksichtigt[8](S.94).

3.3.2. Frequenzmoduliertes Raster

Im Unterschied zum amplitudenmodulierten Raster wird in einem frequenzmodulierten Raster bei ansteigender Flächendeckung die Anzahl der belichteten Punkte innerhalb einer Rasterzelle erhöht (siehe: ABB. 3.5(3) und ABB. 3.4). Die Größe dieser Punkte hingegen ist fix. Die Verteilung der Punkte im FM-Raster erfolgt zufällig. Dadurch entstehen bei Verwendung eines FM-Rasters nahezu keine Moiréeffekte.

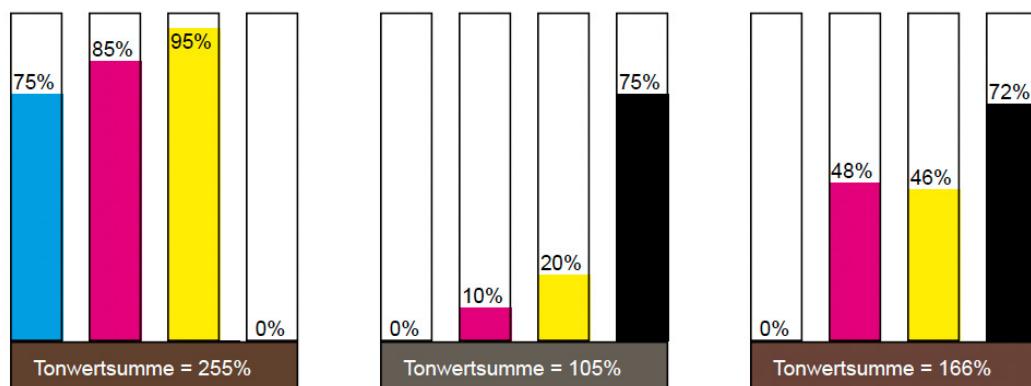


ABB. 3.6. Anpassung des Farbaufbaus durch Ersetzen des Grauanteils der CMY-Farben durch Schwarz. Links ist der Aufbau nur durch die CMY-Farben. In der Mitte die theoretische maximale Ersetzung. In der Praxis ist die Abweichung im Farbeindruck hier zu stark, so dass realistisch eher eine Anpassung wie rechts zu sehen verwendet wird.

Trotz dieser in Hinblick auf die Moiréentstehung sehr positiven Eigenschaften birgt die Verwendung von FM-Rastern eine Reihe von Nachteilen für die industrielle Druckproduktion. Dazu gehören eine geringere Repräsentation in den definierten Produktionsstandards der Industrie[12], höhere Tonwertzunahmen und eingeschränkte Möglichkeiten zur Anpassung der Tonwerte an der Druckmaschine sowie eine höhere mechanische Abnutzung der Druckplatten bei hohen Auflagen sowie eine erhöhte Beanspruchung der Gummitücher[13]. Diese Nachteile überwiegen häufig, sodass die Mehrzahl der Druckprodukte mit einem AM-Raster hergestellt wird.

3.3.3. Erzeugung eines Unbuntaufbaus durch Verwendung von GCR-Software

Im Rahmen der Aufbereitung von Druckvorlagen in der Druckvorstufe wird häufig eine GCR-Software verwendet, um den Farbaufbau der Dateien anzupassen. GCR steht für Gray Component Replacement. Farbtheoretisch erzeugt ein gleicher Anteil der drei Grundfarben Cyan, Magenta und Gelb einen grauen Farbeindruck. Eine GCR-Software ersetzt die Grauanteile der Farben durch Schwarz (siehe ABB. 3.6). Durch diese Anpassung kann der Farbauftrag auf dem Bogen reduziert werden, wodurch die Weiterverarbeitung der gedruckten Bogen erleichtert wird[10](S.74).

Wie in ABB. 3.7 exemplarisch zu sehen, sorgt dies dafür, dass ein Großteil des Kontrastes durch den Schwarzkanal entsteht.



1. Abbildung ohne GCR (Buntaufbau)



2. Abbildung mit GCR (Unbuntaufbau)

ABB. 3.7. Anpassungen der Farben im Bild durch Anwendung einer GCR-Software. Oben ist die ursprüngliche Abbildung zu sehen, unten die Variante nach der Optimierung durch eine GCR-Software. Jeweils von links nach rechts sind die vierfarbige Abbildung, der Cyan-, Magenta-, Gelb- und Schwarzauszug zu sehen. Deutlich zu sehen ist die Reduktion der Cyan, Magenta und Gelbanteile im Bereich der Mauern, des Turms und des Pflasters mit gleichzeitiger Zunahme des Schwarzanteils in diesen Bereichen. Die Zusammensetzung der Farbanteile des Himmels bleibt aufgrund des geringen Grauwerts des Farbtones hingegen nahezu unverändert.

4. Kategorisierung der im Druckkontext relevanten Moirés

Nachfolgend werden die im Druckkontext relevanten Moirés kategorisiert. Dafür werden zwei Taxonomien definiert. Die erste bezieht sich auf Rahmenbedingungen, unter denen Moiréstrukturen entstehen können. Die zweite kategorisiert die Moirés anhand der Eigenschaften der interferierenden Raster. Hierbei wird in drei grundlegende und zwei unterstützende Eigenschaften unterschieden, mit welchen Moirés im Druckkontext beschrieben werden können.

4.1. Kategorisierung von Moirés anhand der Rahmenbedingungen der Entstehung

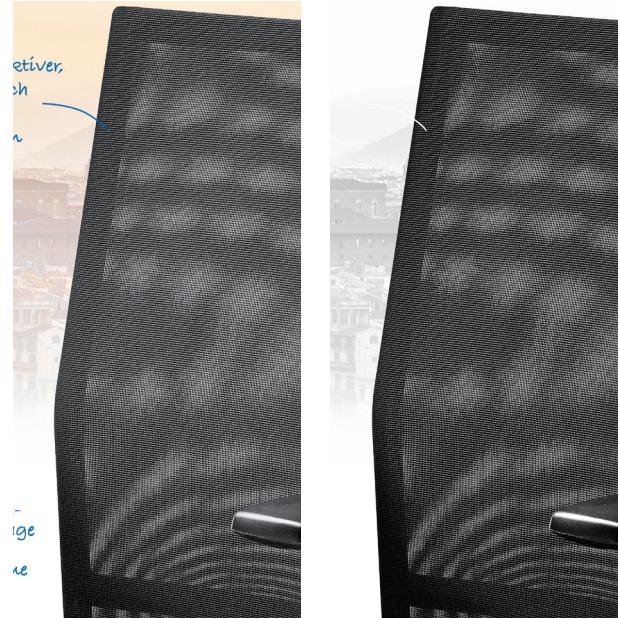
Die Rahmenbedingungen, die im Druck zu Entstehung von Moiréeffekten führen können, lassen sich in drei Gruppen einteilen.

1. Entstehung des Moiréeffekts durch Überlagerung mehrerer Strukturen im Motiv selbst
2. Entstehung des Moiréeffekts durch den Alias-Effekt, erzeugt durch Anpassungen des digitalen Halbtontbildes
3. Entstehung des Moiréeffekts durch Interferenzen zwischen dem Druckraster und Strukturen im Bild

Die ersten beiden Gruppen werden zusammengefasst in Abs. 4.1.1 beschrieben. Auf die dritte Gruppe wird in Abs. 4.1.2 eingegangen.

Zusätzlich zu den drei genannten Gruppen entstehen auch Interferenzen zwischen den Rastern der einzelnen Farbauszüge. Diese Gruppe wird im Rahmen dieser Arbeit nicht weiter betrachtet, da für diesen Fall die Entstehung von Moirés durch Optimierung der Prozessparameter stark eingeschränkt werden kann, wodurch sie in der Praxis nicht relevant sind. Die Möglichkeiten der Optimierung werden in Abs. 3.3.1 beschrieben.

Grundsätzlich gilt, dass sich auch mehrere Effekte aus den verschiedenen Gruppen in einem Motiv überlagern können. ABB. 4.1 zeigt ein Beispiel, in dem Moiréstrukturen bereits im Motiv, durch die Überlagerung der Netzstrukturen im Stoffbezug der Stuhllehne, entstehen. Die Entstehung weiterer Moiréeffekte, beispielsweise durch die Verwendung einer ungeeigneten Abtastrate beim Fotografieren des Motivs oder durch den skalierten Einbau des Bildes im Layout, sind möglich. Auch ein Moiréeffekt, der erst durch die Umwandlung des Bildes in Rasterpunkte auftritt, ist für das Motiv denkbar.



1. CMYK-Bild

2. Schwarzkanal

ABB. 4.1. Ein Beispiel für die Entstehung von Moiréeffekten bereits im Motiv. Sowohl die Vorder- als auch Rückseite der abgebildeten Stuhllehne sind mit einem gleichmäßigen Netzstoff bezogen. Durch die Perspektive der Aufnahme überlagern sich die beiden Stoffe sowohl versetzt als auch skaliert zueinander, wodurch ein Moiréeffekt entsteht. 1. zeigt das CMYK-Bild, 2. nur den Schwarzkanal.

4.1.1. Entstehung von Moiréstrukturen im Halbtontbild

In einigen Fällen ist ein Moiré bereits im nicht gerasterten Halbtontbild vorhanden. Moiréstrukturen entstehen hier durch die Überlagerung von periodischen Rastern in vorhergehenden Arbeitsschritten. Dabei können die folgenden Fälle unterschieden werden:

1. Entstehung von Moiréeffekten durch Überlagerung von Strukturen im Motiv
2. Entstehung von Moiréeffekten durch Wiederherstellung des Bildsignals mit einer ungeeigneten Abtastrate

ABB. 4.1 zeigt ein Beispiel für den ersten Fall. Die entsprechend der Beschreibung in Abs. 2 interferierenden Raster überlagern sich. Darüber hinausgehende Annahmen zu den Eigenschaften der Überlagerung oder der beteiligten Raster können allgemeingültig nicht getroffen werden.

Ein Beispiel für den zweiten beschriebenen Fall findet sich in ABB. 4.2. Wie Abs. 2.2 beschrieben, kann es durch Verwendung einer ungeeigneten Abtastrate zur Wiederherstellung eines Signals zum

Alias-Effekt kommen. Dieser äußert sich im Falle von Abtastungen eines Bildsignals in Moiréstrukturen. Im Prozess der Herstellung einer Druckvorlage wird das Bildsignal mehrfach abgetastet. Die erste Abtastung erfolgt durch die Aufnahme des Motivs mit einer Digitalkamera. Der Kamerasensor besteht aus rasterförmig angeordneten Elementen. Jedes dieser Elemente legt den Farbwert eines Pixel im erzeugten digitalen Bild fest[14](Abs. 2.2). Ist die Abtastrate des Kamerasensors in Bezug auf das Motiv ungenügend, beispielsweise durch eine ungünstige Wahl von Entfernung und Winkel der Kamera zum Motiv, genügt die Anzahl der Pixel nicht mehr, um das ursprüngliche Motiv adäquat im erzeugten Bild darstellen zu können und ein Moiréeffekt entsteht[2](Abs. 2.13). Gleiches gilt, wenn ein Motiv mit Hilfe eines Scanners digitalisiert wird.

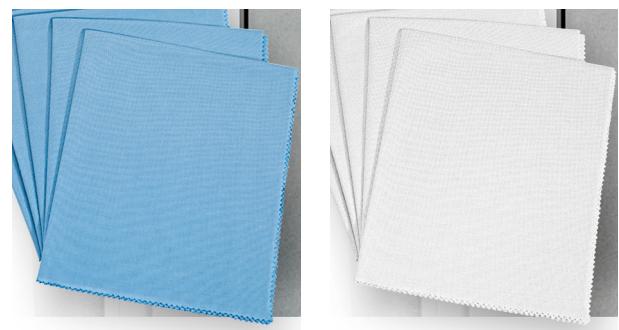
Weitere Abtastungen erfolgen, wenn ein Bild beispielsweise in einem Bildbearbeitungsprogramm skaliert oder die Auflösung des Bildes angepasst wird oder wenn das Bild um einen Faktor skaliert in einem Layoutprogramm eingebaut wird.

4.1.2. Entstehung einer Moiréstruktur durch Wechselwirkung von Bildstrukturen mit dem Druckraster

Moiréstrukturen dieser Gruppe entstehen durch Interferenzen zwischen im Bild vorhandenen Strukturen mit den periodischen Rasterstrukturen, die durch Umwandlung in ein AM-Raster entstehen. ABB. 4.3 zeigt ein Beispiel hierfür.

Dieser Fall ist aus mehreren Gründen besonders problematisch für die industrielle Druckproduktion:

1. Entsprechend den in Abs. 4.2 beschriebenen Eigenschaften von Moirés, können sich geringe Änderungen an der im Halbtontbild vorhandenen Struktur stark auf das optische Erscheinungsbild von Moirés auswirken.



1. CMYK-Bild

2. Schwarzkanal

ABB. 4.2. Ein Beispiel für die Entstehung von Moiréstrukturen durch den Alias-Effekt. Auf dem Motiv sind wellenförmige Strukturen zu erkennen. Diese entstehen durch Interferenz der Textilstruktur des Motivs mit dem Kamerasensor bei der Aufnahme oder durch eine ungeeignete Skalierung der Abbildung in der digitalen Nachbearbeitung des Bildes.

1. zeigt das CMYK-Bild. In 2. ist zur besseren Erkennbarkeit des Effektes nur den Schwarzkanal der Abbildung abgebildet.

2. Die Moirés entstehen erst durch die Rasterung der Auszüge. Dadurch sind die zu produzierenden Seiten nur schwer im Vorhinein auf diese Art von Moirés zu prüfen (siehe dazu: Abs. 7.2)

Nachfolgend werden zwei Spezialfälle aus dieser Gruppe beschrieben, die durch die speziellen Rahmenbedingungen der Druckproduktion zu Stande kommen können.

4.1.2.1. Entstehung von Moiréstrukturen durch Platzieren einer bereits gerasterten Vorlage

Häufig, insbesondere wenn keine digitalen Vorlagen oder analoge Originalbilder mehr vorhanden sind, werden gedruckte Vorlagen redigitalisiert und in einem neuen Layout eingebaut. Da hier durch den Scavorgang auch das in der gedruckten Vorlage enthaltene Druckraster übernommen wird, entstehen häufig besonders auffällige und großflächige Moirémuster. In ABB. 4.4 ist dieser Effekt zu sehen. ABB. 4.5 zeigt einen Detailausschnitt aus ABB. 4.4(1.). Hier ist eine periodische Struktur zwar sichtbar, die Stärke des Moirés kann jedoch aus der Abbildung nicht erahnt werden.

Die auf diese Art entstehenden Moirés haben häufig eine Reihe von besonderen Eigenschaften. Im Regelfall kann davon ausgegangen werden, dass sowohl das redigitalisierte Original als auch das neu erzeugte AM-Raster die gleiche Rasterwinkelung haben, nämlich beide den Standardwinkel für die jeweilige Farbe. Darüber hinaus kann davon ausgegangen werden, dass die redigitalisierte Vorlage (nahezu) proportional skaliert in das neue Layout eingebaut worden ist. Andernfalls wäre die Abbildung im neuen Produkt verzerrt.

Daraus ergibt sich ein Sonderfall der Moiréentstehung, in dem entsprechend [2](Abs. 2.4) gilt: $T_1 \neq T_2$, aber $\theta_1 = \theta_2$. Darüber hinaus ist die im Motiv enthaltene Struktur anders als bei vielen im Motiv enthaltenen Strukturen, wie zum Beispiel Textilstrukturen, nicht in sich unregelmäßig verzerrt sondern linear.

Der daraus resultierende optische Effekt ist ein Muster, dass ebenfalls auf dem Ursprungswinkel θ_1 beziehungsweise θ_2 liegt, bei dem aber $T_M > T_1 \wedge T_M > T_2$ gilt.



1. Halbtonebild

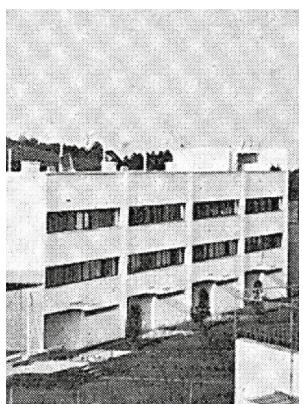


2. Rasterbild

ABB. 4.3. Beispiel für eine Interferenz zwischen Druckraster und Bildstruktur im Schwarzkanal. In 2. sind deutlich kreisförmige Strukturen zu erkennen, die in 1. nicht sichtbar sind. Das Moiré entsteht vermutlich durch die Interferenz zwischen den im Halbtonebild zu sehenden auf ca. 45° gewinkelten Linien und dem Rasterung des Schwarzkanals, das ebenfalls auf 45° gewinkelt wird.



1. Halbtonebild



2. Rasterbild

ABB. 4.4. Beispiel für die Verwendung einer redigitalisierten Vorlage. Im Beispiel wird ausschließlich der Schwarzkanal verwendet. 1. zeigt das Halbtonebild, 2. die Umwandlung in ein Rasterbild.

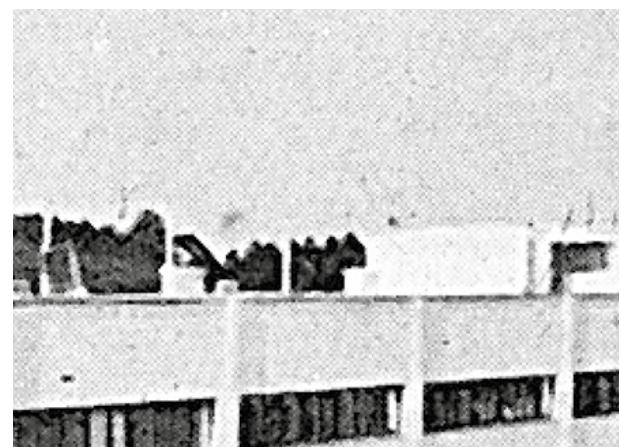


ABB. 4.5. Detailansicht des Halbtonebildes aus ABB. 4.4(1.).

2.6X

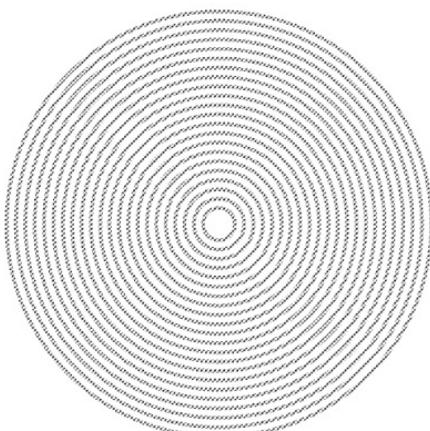


ABB. 4.6. Moiréstruktur durch Abrisse in der Rastergenerierung.

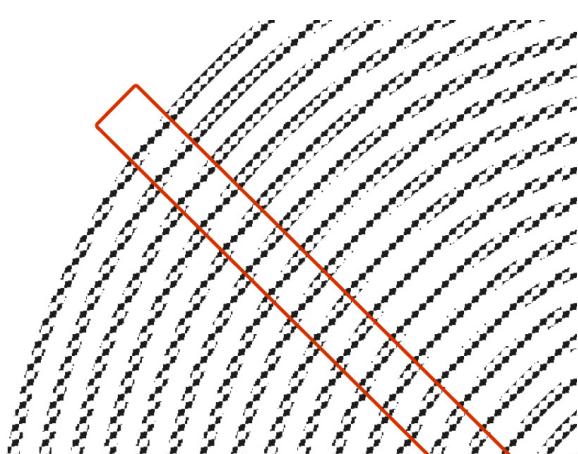


ABB. 4.7. Detailansicht der Abrissstruktur aus ABB. 4.6.

4.1.2.2. Entstehung eines Moirés durch Abrisseffekte in der Rastergenerierung

In ABB. 4.6 ist ein deutlich sichtbares Moirémuster vorhanden. Die Effekte sind in einem gleichmäßigen Abstand von 90° um den Mittelpunkt der Kreise zentriert, beginnend bei 45° . In ABB. 4.7 ist der Bereich des Moirémuster im Detail zu sehen. Ober- und unterhalb des Problembereiches wird die Rundung der Linien jeweils durch zwei gerade Reihen von Rasterpunkten modelliert. Im Problemreich selbst überlagern sich die Linie des Ursprungsbildes sowie die durch den Raster Image Prozessor erzeugten Linien so, dass die Rundung nur durch eine Reihe von Rasterpunkten modelliert wird. Dadurch wirkt die Linie optisch an dieser Stelle dünner.

4.2. Kategorisierung anhand der geometrischen Eigenschaften der beteiligten Strukturen

Nachfolgend soll ein Versuch unternommen werden, die für die vorliegende Arbeit relevanten Moiréstrukturen anhand der geometrischen Eigenschaften der interferierenden Raster zu kategorisieren. Dabei soll insbesondere geprüft werden, ob sich für die jeweiligen Gruppen charakteristische Erscheinungsbilder der entstehenden Moiréstrukturen feststellen lassen. Zudem soll geprüft werden, welche Parameter in den Eigenschaften der interferierenden Strukturen welchen Einfluss auf das optische Erscheinungsbild der entstehenden Moiréstrukturen haben.

Dafür wurden drei Hauptkategorien gebildet und untersucht:

- Winkelunterschied der interferierenden Raster
- Skalierung des interferierenden Rasters
- perspektivische Verzerrung des interferierenden Rasters

Dazu wurden zwei Kategorien für unterstützende Effekte identifiziert:

- kreisförmiges Zusammenziehen und Expandieren
- wellenförmige Verzerrung

Die Untersuchung erhebt keinen Anspruch auf Vollständigkeit. Wie beispielsweise in [1] dargestellt, sind die möglichen Formen und geometrischen Eigenschaften der interferierenden Strukturen sowie die optischen Eigenschaften der entstehenden Moiréstrukturen nahezu unbegrenzt. Im Rahmen dieses Abschnittes soll lediglich der Versuch unternommen werden, die wichtigsten geometrischen Eigenschaften für die in der Druckproduktion relevanten Formen der Interferenz zu untersuchen.

Für die Untersuchung wurde jeweils von einer Situation ausgegangen, bei der zwei ursprünglich gleiche Raster interferieren. Das erste Raster bleibt bei allen Versuchen unverändert. Dieses Raster wird nachfolgend als Basisebene bezeichnet. Auf das zweite wird einer der genannten Effekte mit spezifizierten Parametern angewandt. Dieses Raster wird nachfolgend als Effektebene bezeichnet. Die Raster sind in ihrer ursprünglichen Form jeweils auf 0° gewinkelt.

Für die Versuche wurden Graustufenbilder mit Rastern mit ein- und zweidimensional periodischen Strukturen erzeugt (siehe: ABB. 4.8). Diese haben jeweils eine Größe von 1001×1001 Pixeln. Für Breite und Höhe des Bildes wurde jeweils eine ungerade Zahl gewählt, damit das Bild einen eindeutigen Mittelpunkt hat. Die Färbung der Pixel wird definiert durch (4.1) mit x und y als Position des jeweils zu färbenden Pixels.

$$f(x, y, a) = \begin{cases} 0, & \sin\left(0, 5 \frac{2\pi(x \cos(a) + y \sin(a))}{l} + w\right) < 0 \\ 1, & \sin\left(0, 5 \frac{2\pi(x \cos(a) + y \sin(a))}{l} + w\right) > 1 \\ \sin\left(0, 5 \frac{2\pi(x \cos(a) + y \sin(a))}{l} + w\right), & \text{andernfalls} \end{cases}$$

$$(4.1) \quad f(x, y)_{1d} = f(x, y, 0)$$

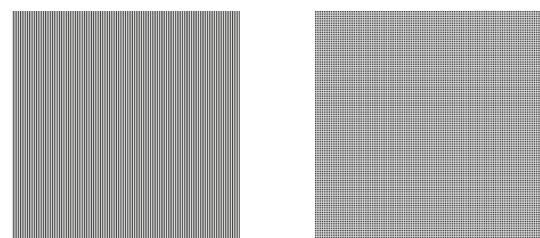
$$f(x, y)_{2d} = f(x, y, 0) \cdot f(x, y, \frac{\pi}{2})$$

Die Formel erzeugt sinusförmig verteilte Strukturen. Diese Verteilung wurde gewählt, damit die beteiligten Impulse in der erzeugten Fourier-Ansicht möglichst eindeutig zu identifizieren sind.

l steht für die gewünschte Wellenlänge in Pixeln. Für die Versuche wurde $l=20$ verwendet. w ist ein Gewicht zur Steuerung der Größe der erzeugten Strukturelemente. Im Falle der eindimensionalen periodischen Strukturen $f(x, y)_{1d}$ ist der Wert mit 0,5 definiert, wodurch helle und dunkle Bereiche eine gleiche Größe aufweisen. Im Falle der zweidimensionalen periodischen Strukturen $f(x, y)_{2d}$ wird 0,77 als Wert für w verwendet. Dadurch soll ein annähernd gleicher durchschnittlicher Tonwert für beide Bilder erreicht werden.

Im Druck entstehen Moiréstrukturen in den meisten Fällen durch den Alias-Effekt (vgl. Abs. 4.1). In Abs. 2.2 wird beschrieben, dass sich Interferenzen durch Überlagerung und Interferenzen entstehend durch den Alias-Effekt mit den gleichen mathematischen Formeln beschreiben lassen. Die Erzeugung von Moiréeffekten durch Überlagerung ist jedoch technisch einfacher umzusetzen. Zudem sind Moiréstrukturen bei Überlagerungen häufig optisch besser sichtbar. Daher wurde für die Versuche eine Interferenz durch Überlagerung gewählt.

Den Abbildungen der interferierenden Strukturen ist nachfolgend jeweils eine Abbildung der Frequenzansicht, erzeugt durch eine schnelle Fouriertransformation [3](S.475ff), beigestellt (siehe beispielsweise: ABB. 4.8). Die Frequenzansicht erlaubt, wie in Abs. 2.1 beschrieben, eine Einordnung der Eigenschaften der entstehenden Moiréstrukturen. Nachfolgend werden Winkel



1. Linien

2. Kreise

ABB. 4.8. Ansicht der mit (4.1) erstellten Basisraster.

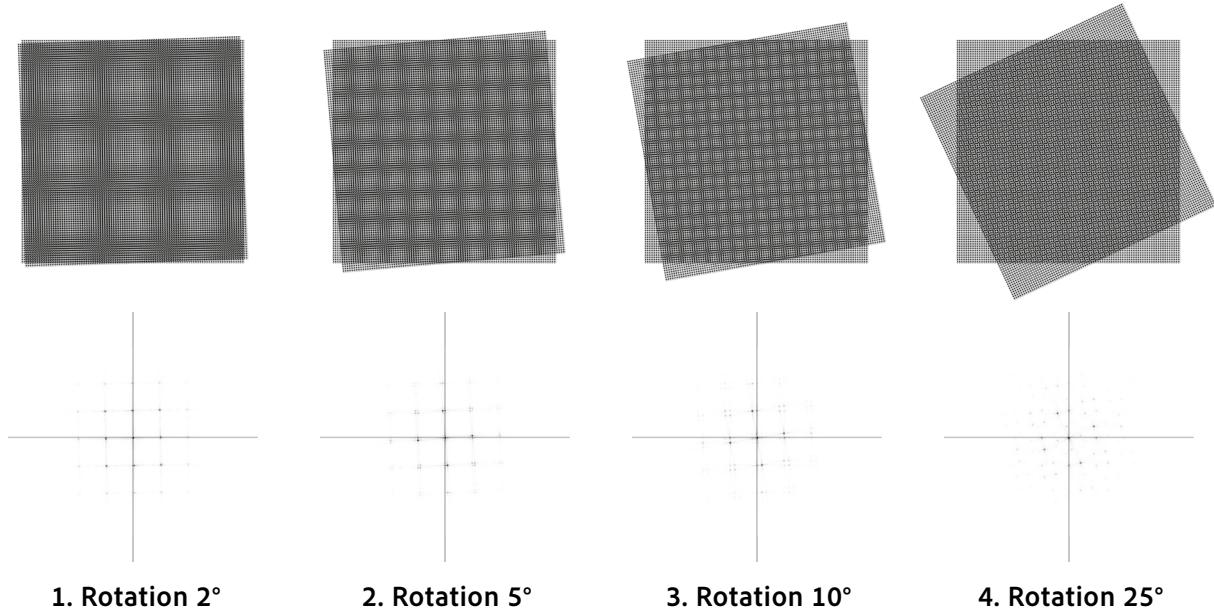


ABB. 4.9. Überlagerung von zwei 2-dimensionalen Rastern. Das untere Raster ist jeweils auf 0° gewinkelt, während beim überlagernden Raster der Winkel stufenweise ansteigt. Die Winkelung des entstehenden Moirémusters liegt jeweils zwischen den Rasterwinkeln der überlagernden Raster. Die Frequenz der Moirémuster nimmt mit steigendem Winkelunterschied zu.

von Basisebene, Effektebene und entstehender Moiréstruktur mit Θ_1, Θ_2 und Θ_M bezeichnet. Die Perioden werden entsprechend mit T_1, T_2 und T_M bezeichnet.

4.2.1. Winkelunterschied

Eine grundlegende Eigenschaft von interferierenden Rastern, welche zur Entstehung von Moiréeffekten führen kann, ist ein Winkelunterschied zwischen den interferierenden Strukturen. Ein Beispiel hierfür ist in ABB. 4.10 zu sehen. Mathematisch lässt sich dieser Fall beschreiben, indem man von einer Überlagerung ausgeht, bei der gilt: $T_1 = T_2$ und $\Theta_1 \neq \Theta_2$. ABB. 4.9 zeigt beispielhaft den entstehenden Moiréeffekt bei einer solchen Interferenz. Die Frequenz des Interferenzmusters steigt mit zunehmendem Winkelunterschied zwischen den interferierenden Rastern. Das bedeutet im Umkehrschluss, dass das störende Muster bei geringen Abweichungen im Winkel besonders stark auftritt und der störende Effekt mit zunehmender Abweichung abnimmt. Die Frequenz der entstehenden Moiréstruktur steigt bei einer eindimensionalen Struktur bis zu einem Winkelunterschied von ca. 45° bleibt dann optisch stabil und sinkt schließlich ab ca. 315° wieder (siehe: ABB. 4.12). Bei einem Winkel-



ABB. 4.10. Beispiel für ein Moiré entstehend durch den Winkelunterschied zwischen der Textilstruktur im Halbtontbild (1.) und dem auf 45° gewinkelten Druckraster im Schwarzkanal.

1./2. Halbtondarstellung mit 300 dpi.

3./4. Rasterabbildung mit 300 dpi.

unterschied von 0° beziehungsweise 360° ist aufgrund der perfekten Überlagerung der beteiligten Raster keine Moiréstruktur vorhanden. Bei der Verwendung einer zweidimensionalen Grundstruktur erstreckt sich der selbe Effekt auf den Wertebereich zwischen 0° und 90° , da sich hier schon bei einem Winkelunterschied von 90° beide Raster exakt überlagern. Die Periode sinkt dabei ebenfalls bis zu einem Winkelunterschied von 45° . Periode und Winkel der entstehenden Moiréstruktur kann bei eindimensionalen Grundstrukturen mit (4.2) beschrieben werden. Diese ist übernommen aus [2], Formel 2.10.

$$(4.2) \quad T_M = \frac{T}{2|\sin(\alpha/2)|}$$

$$\Theta_M = \begin{cases} \frac{1}{2}(\theta_1 + \theta_2) - 90, & \alpha > 0 \\ \frac{1}{2}(\theta_1 + \theta_2) + 90, & \alpha < 0 \end{cases}$$

Das optische Erscheinungsbild der Moiréstrukturen unterscheidet sich je nachdem ob die grundlegenden Elemente der beteiligten Raster ein- oder zweidimensional sind. Die Moiréstrukturen erscheinen in Form von Linien. Im eindimensionalen Raster verlaufen die Linien in einem Winkel, der zwischen der Winkelung der beteiligten Raster liegt und damit orthogonal zur Ausrichtung der Linien in den beteiligten Rastern (siehe: ABB. 4.11(1.)). Im Falle des zweidimensionalen Rasters verlaufen die Liniensstrukturen der Moirés sowohl in vertikaler als auch in horizontaler Richtung. Die Winkelung der Moiréstrukturen liegt ebenfalls zwischen den Winkelungen der beteiligten Raster (siehe: ABB. 4.11(2.)).

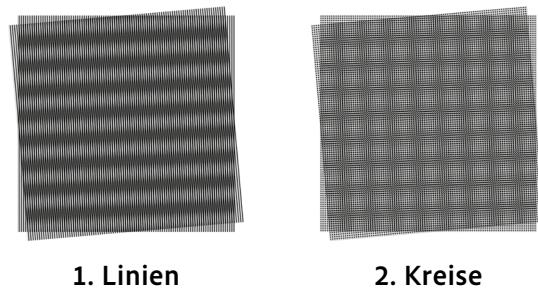


ABB. 4.11. Optisches Erscheinungsbild der entstehenden Moiréstruktur bei ein- (1.) und zweidimensionalem (2.) Grundmuster der interferierenden Raster. In beiden Abbildungen ist die Effektebene um 5° gedreht.

4.2.2. Skalierung

Die zweite betrachtete Kategorie ist die Skalierung eines der interferierenden Raster. Der Effekt lässt

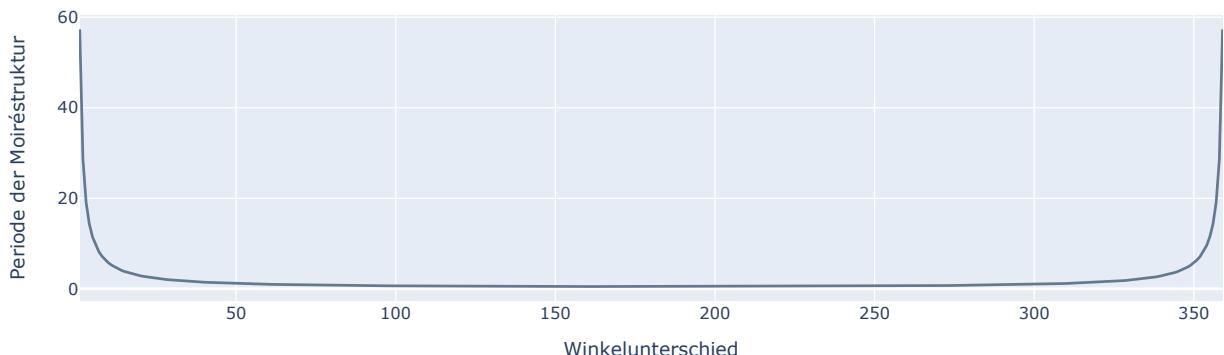
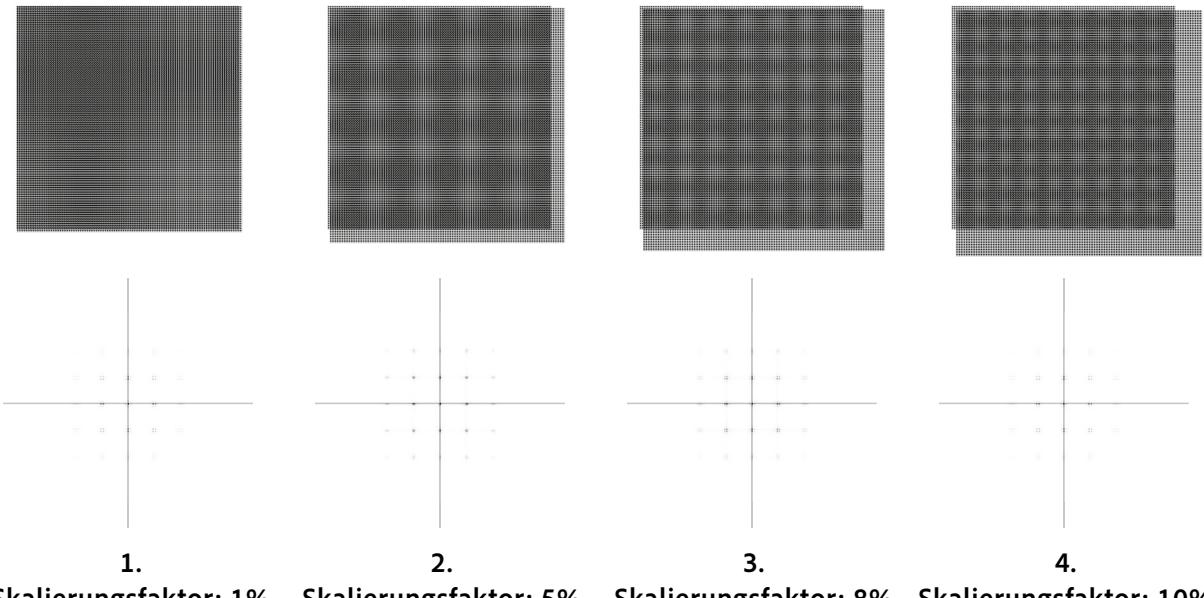


ABB. 4.12. Das Diagramm zeigt die Periode der entstehenden Moiréstruktur in Abhängigkeit von der Winkelung der Effektebene.



Skalierungsfaktor: 1% Skalierungsfaktor: 5% Skalierungsfaktor: 8% Skalierungsfaktor: 10%

ABB. 4.13. Optisches Erscheinungsbild und Fourier-Spektrum von Moiréstrukturen entstehend durch Skalierung der Effektebene.

sich mathematisch mit $T_1 \neq T_2$ und $\Theta_1 = \Theta_2$ beschreiben. Ein Beispiel für ein primär durch diese Eigenschaft entstehendes Moiré ist in ABB. 4.4 zu sehen.

ABB. 4.13 zeigt das optische Erscheinungsbild des beschriebenen Effektes. Dies ist dem optischen Erscheinungsbild aus Abs. 4.2.1 ähnlich, hat jedoch in jedem Fall eine Winkelung von 0° . Für die dort abgebildeten Skalierungsfaktoren lässt sich beobachten: je näher der Skalierungsfaktor der Effektebene an 1 liegt, desto geringer ist die Frequenz der Moiréstruktur.

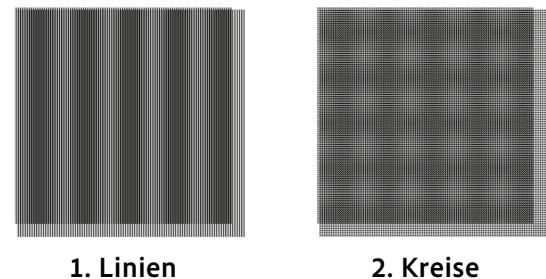


ABB. 4.14. Vergleich der Eigenschaften der entstehenden Moiréstruktur mit ein- und zweidimensionaler Grundstruktur.

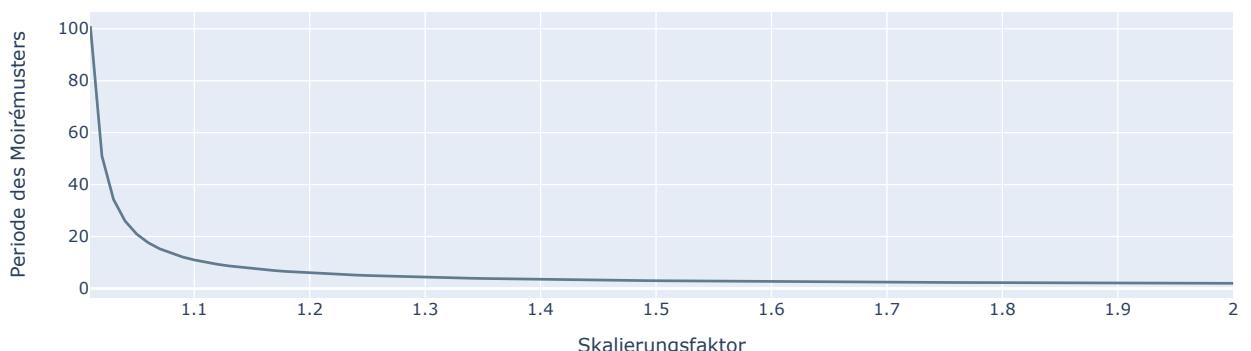
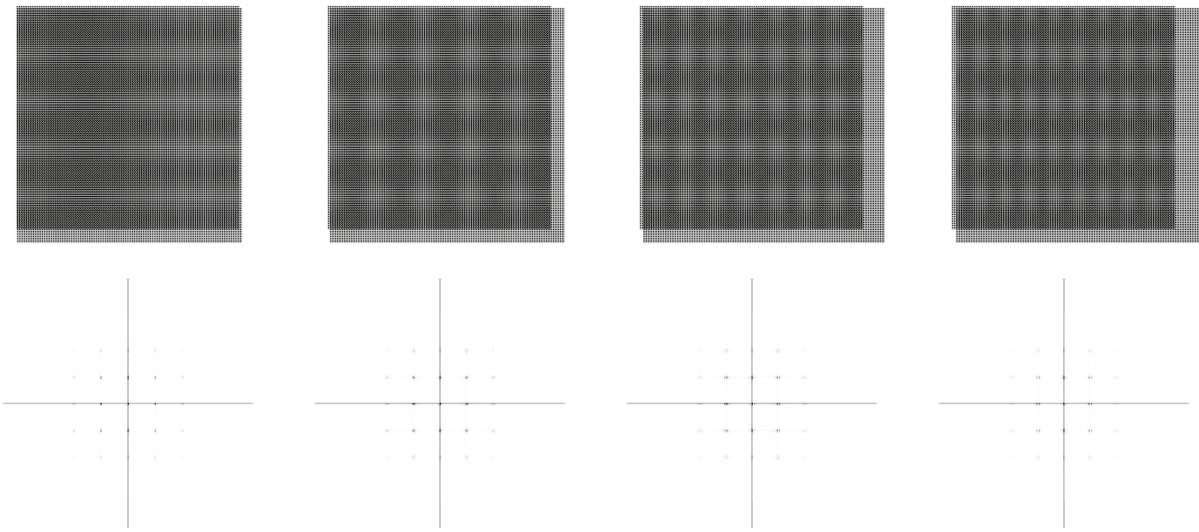


ABB. 4.15. Die Periode T_M einer entstehenden Moiréstruktur in Abhängigkeit des Skalierungsfaktors der Effektebene.



1. Skalierungsfaktor: 2. Skalierungsfaktor: 3. Skalierungsfaktor: 4. Skalierungsfaktor:
1%/5% 5%/5% 8%/5% 10%/5%

ABB. 4.16. Optisches Erscheinungsbild und Fourier-Spektren von Moiréstrukturen entstehend durch Skalierung bei nicht gleichmäßiger Skalierung in vertikaler und horizontaler Richtung. Der Skalierungsfaktor beschreibt relative Veränderung der Breite und Höhe der Effektebene im Vergleich zur Basisebene.

$$T_M = \frac{T_1 \cdot T_2}{|T_1 - T_2|}$$

(4.3)

$$\Theta_M = \begin{cases} \theta_1, & T_2 > T_1 \\ \theta_1 + 180^\circ, & T_2 < T_1 \end{cases}$$

(4.3) beschreibt das Verhalten von Periode T_M und Winkel Θ_M der durch Skalierung entstehenden Moiréstrukturen. Sie wurde übernommen aus [2], Formel 2.11.

ABB. 4.15 zeigt, dass die Periode der erzeugten Struktur bis zu einem Skalierungsfaktor von ca. 1,2 stark abnimmt, danach deutlich weniger stark weiter fällt und sich dabei dem Wert zwei annähert.

Die Intensität des Effektes sinkt demzufolge im vergleichbaren Maße wie bei Abs. 4.2.1, bleibt jedoch deutlicher sichtbar. Das beschriebene Verhalten ist auch in ABB. 4.13 zu erkennen.

Analog zu dem in Abs. 4.2.1 beschriebenen Eigenschaften entsteht der Moiréeffekt bei Verwendung eines eindimensionalen Grundmusters ebenfalls nur in einer Dimension, während es bei einem zweidimensionalen Grundmuster auch zweidimensional auftritt. Anders als in Abs. 4.2.1 entspricht der Winkel der Moiréstruktur Θ_M dem Winkel der zugrunde liegenden Muster Θ_1 und Θ_2 (siehe dazu: (4.3)).

Wird die Effektebene ungleichmäßig in der vertikalen und horizontalen Richtung skaliert, so ist auch die Periode der entstehenden Moiréstruktur T_M in vertikaler und horizontaler Ausrichtung nicht mehr identisch. Dieser Effekt ist in ABB. 4.16 dargestellt.

4.2.3. Perspektivische Verzerrung

ABB. 4.17 zeigt ein Beispiel für ein natürliches Moiré, dass durch eine Verzerrung der plan liegenden Struktur an mindestens drei Eckpunkten entsteht. Diese Art der Verzerrung entsteht häufig aus der Dreidimensionalität der Positionierung des Objektes in der Aufnahmesituation. Da eine solche Aufnahmesituation für die Mehrzahl der abgebildeten Objekte anzunehmen ist, kann davon ausgegangen

werden, dass eine Vielzahl der natürlichen Moirés mindestens anteilig auf diese Form der Verzerrung zurückzuführen sind.

Wie in ABB. 4.18 gezeigt, äußert sich das optische Erscheinungsbild von Moiréstrukturen, die durch eine Verzerrung der überlagernden Struktur entstehen, in Form von Kurven. Bei einseitiger Verzerrung (siehe: ABB. 4.18(2.)) sind diese Kurven durchgängig. Ist die überlagernde Struktur beidseitig verzerrt, so sind die entstehenden Kurven vertikal mittig gespiegelt (siehe: ABB. 4.18(4.)). Die in ABB. 4.18(3.) zu sehende Überlagerung bildet eine Ausnahme. Hier sind die obere linke und die untere rechte Ecke gleichmäßig verzerrt. Die entstehenden Moiréstrukturen sind nicht kurvenförmig sondern gerade. Da in diesem Fall der Winkel der Elemente der Effektebene für alle Elemente der Effektebene gleich ist, ist dieser Fall identisch mit dem in Abs. 4.2.1 beschriebenen Fall des Winkelunterschiedes.

Mathematisch kann die perspektivische Verzerrung als eine spezielle Form der Überlagerung durch Rotation und durch Skalierung betrachtet werden. Zur Beschreibung dieser Überlagerung wird der Faktor, um den, in Relation zur ursprünglichen Länge der Kante, die erste Ecke und die zweite Ecke einer Kante verschoben werden, als s_1 und s_2 bezeichnet. Nachfolgend wird in (4.4) und (4.5) exemplarisch der Fall der Verzerrung in horizontaler Richtung an einer Ecke (ABB. 4.18(2.)) beschrieben. (4.5) ist eine angepasste Variante der Formel 2.9 aus [2]. Die Herleitung für (4.4) findet sich in ANHANG 1. Hier gilt: $s_1 = 1$ und $s_2 > 1$. Die Werte für T_2 und Θ_2 werden mit Hilfe von $t_2(x)$ und $\theta_2(x)$ festgelegt.

$$(4.4) \quad t_2(x) = x \frac{(s_2 - 1)T_1}{s_2} + T_1$$

$$\theta_2(x) = x \cdot \frac{\tan^{-1}\left(\frac{s_2-1}{1}\right)}{s_2} + \Theta_1$$

x bezeichnet die Position entlang der oberen Kante. Es gilt $0 \leq x \leq 1$. $x = 0$ entspricht der ersten Ecke, $x = 1$ der zweiten Ecke.

$$(4.5) \quad t_M(x) = \frac{T_1 t_2(x)}{\sqrt{T_1^2 + t_2(x)^2 - 2T_1 t_2(x) \cos(\theta_2(x))}}$$

$$\theta_M(x) = \arctan\left(\frac{t_2(x) \sin \theta_1 - T_1 \sin \theta_2(x)}{t_2(x) \cos \theta_1 - T_1 \cos \theta_2(x)}\right)$$

Der Winkel des Moirémusters sinkt linear, was sich optisch auch in ABB. 4.18(2.) erkennen lässt. Die Periode sinkt zunächst stark und sinkt dann geringer Stärke weiter. Dies lässt sich in ABB. 4.19 und ABB. 4.20 erkennen.

Eine besondere Eigenschaft, auch in Abgrenzung zu den Kategorien Rotation und Skalierung, ist, dass das optische Erscheinungsbild der Moiréstruktur nahezu unabhängig davon ist, ob die sich überla-



1. CMYK

2. Schwarzkanal

ABB. 4.17. Die Abbildung zeigt ein natürliches Moiré, dass primär durch die perspektivische Anordnung des fotografierten Motives entsteht.

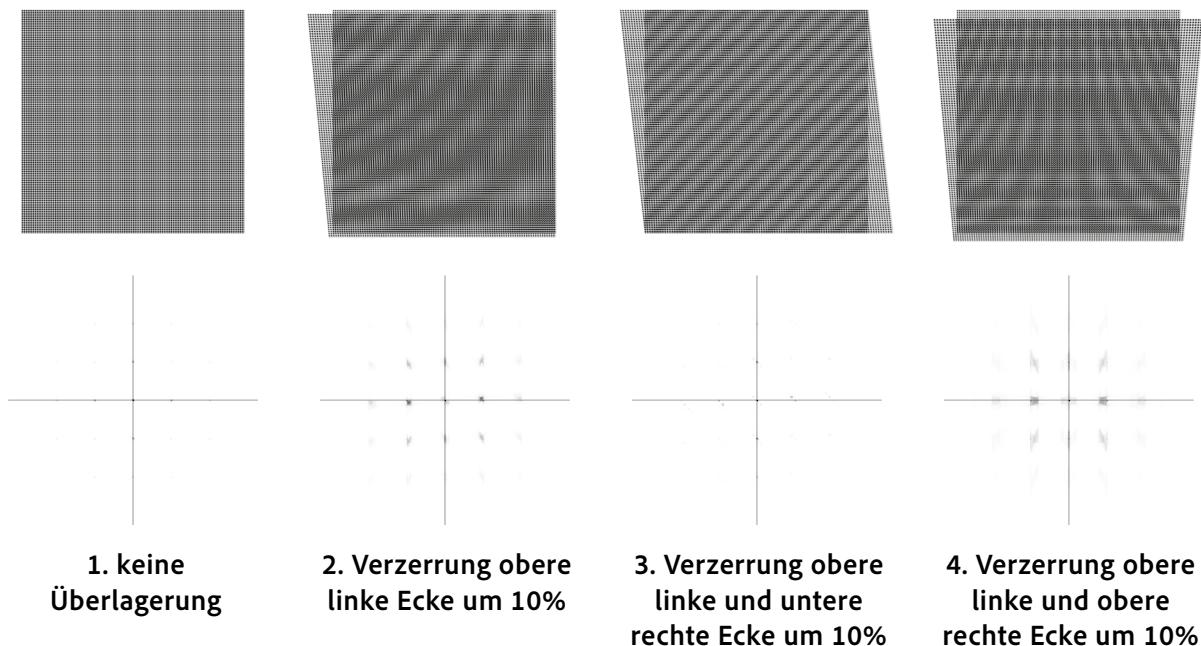


ABB. 4.18. Übersicht über verschiedene verzerrte Überlagerungen von Rastern. Oben jeweils die Überlagerung, unten die jeweiligen Fourier-Spektren der Überlagerungen. Ein positiver abgebildeter Prozentwert beschreibt eine Verschiebung der Ecke nach außen, ein negativer Wert nach innen.

gernden Muster ein- oder zweidimensional sind. ABB. 4.22 zeigt eine Überlagerung mit einer Verzerrung gleicher Stärke, einmal mit Linien und einmal mit Kreisen als grundlegendes Muster. Das optische Erscheinungsbild der Moiréstrukturen ist nahezu identisch.

ABB. 4.20 zeigt die geometrische Veränderung der Moiréstrukturen bei ansteigendem Grad der Verzerrung. Es ist zu erkennen, dass sich die grundsätzliche Form der Moiréstrukturen nicht ändert. Die wesentliche optische Veränderung ist die ansteigende Frequenz der Moiréstrukturen.

ABB. 4.21 zeigt eine Anzahl an Moirés, die durch komplexere Verzerrungen der einzelnen Ecken entstehen.

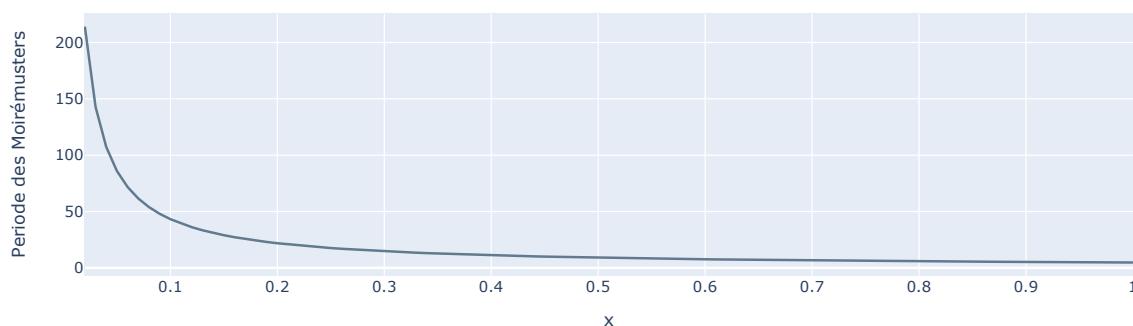


ABB. 4.19. Periode des entstehenden Moirémusters in Abhängigkeit von x , errechnet durch Anwendung von (4.5). Es gilt $s_2 = 1,2$.

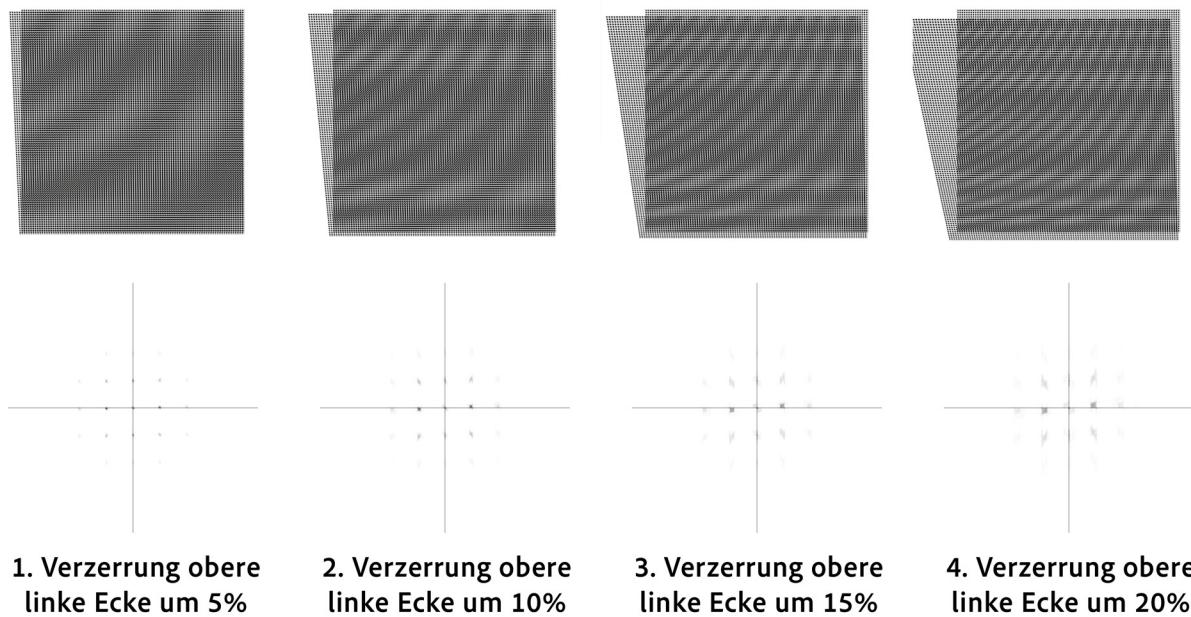


ABB. 4.20. Verzerrung an der oberen linken Ecke der überlagernden Rasters mit ansteigender prozentualer Verzerrung.

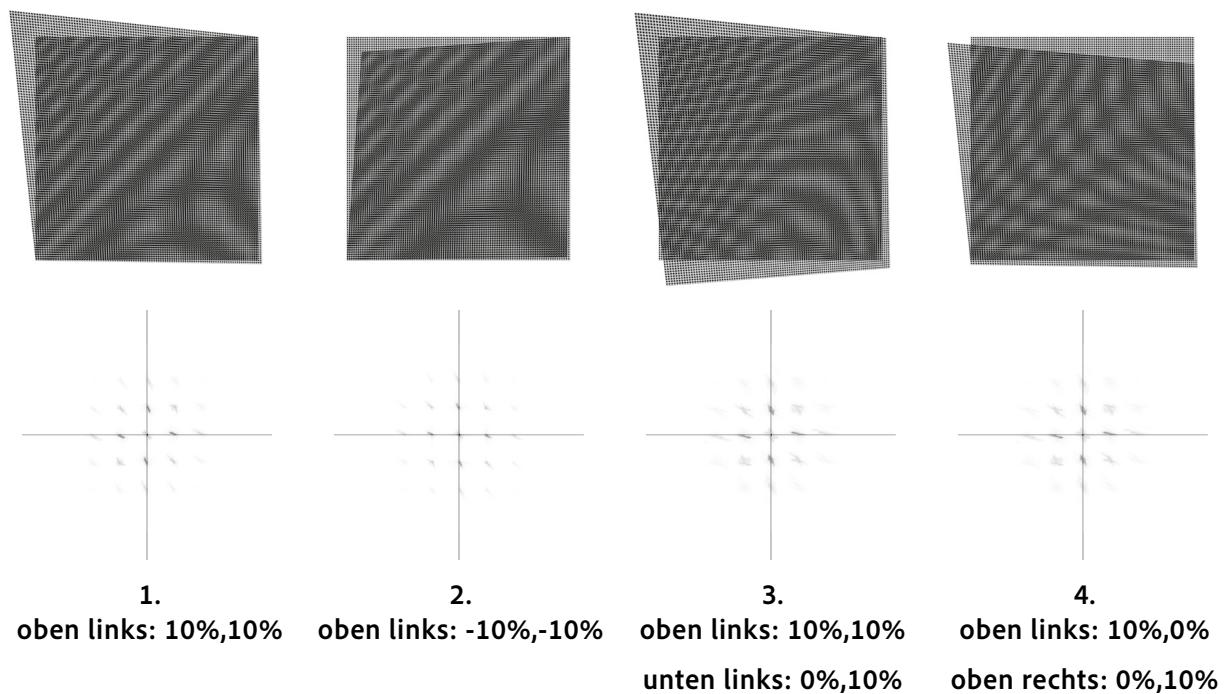


ABB. 4.21. Auswahl an Moirés entstehend durch die Verzerrung der Ecken in x- und y-Richtung. Bei den abgebildeten Paaren von Prozentwerten beschreibt der erste Wert jeweils die Verzerrung in x-Richtung, der zweite Wert die Verzerrung in y-Richtung. Ein positiver Wert verschiebt die Ecke nach außen, ein negativer Wert zieht sie nach innen.

4.2.4. Kreisförmiges Zusammenziehen und Expandieren

Insbesondere in Abbildungen von Kleidungsstücken beziehungsweise von Personen, welche Kleidungsstücke tragen, wird das Erscheinungsbild von Moiréstrukturen durch eine kugelförmige Verzerrung beeinflusst. Da davon ausgegangen wird, dass die Abbildung von Personen eine häufig vertretene Gruppe von Motiven darstellt, wird gesondert auf diesen Effekt eingegangen. Im Kern entsteht in diesen Fällen das Moiré durch eine Mischung der drei genannten Haupteigenschaften aus Abs. 4.2.1, Abs. 4.2.2 und Abs. 4.2.3. Das kreisförmige Expandieren und Zusammenziehen verändert jedoch das optische Erscheinungsbild der Moirés. Ein Beispiel ist in ABB. 4.3 dargestellt. Deutlich erkennbar bildet sich die Moiréstruktur kreisförmig um einen Mittelpunkt. Dieser entspricht annähernd der Position der Fingerspitzen der in der Hosentasche befindlichen Hand. Die Verzerrung des Hosenstoffs ist vergleichbar der Form einer Kugel (siehe: ABB. 4.23(1)). Das Gegenstück des kreisförmigen Expandierens ist das kreisförmig Zusammenziehen. Dieser Effekt entspricht optisch einer kissenförmigen Verzerrung (siehe: ABB. 4.23(2)).

4.2.5. Wellenförmige Verzerrung

Die meisten in der Realität vorkommenden regelmäßigen Muster sind nicht exakt gleichmäßig sondern weisen leichte Unregelmäßigkeiten auf (siehe: ABB. 8.7). Dies gilt insbesondere für textile Strukturen.

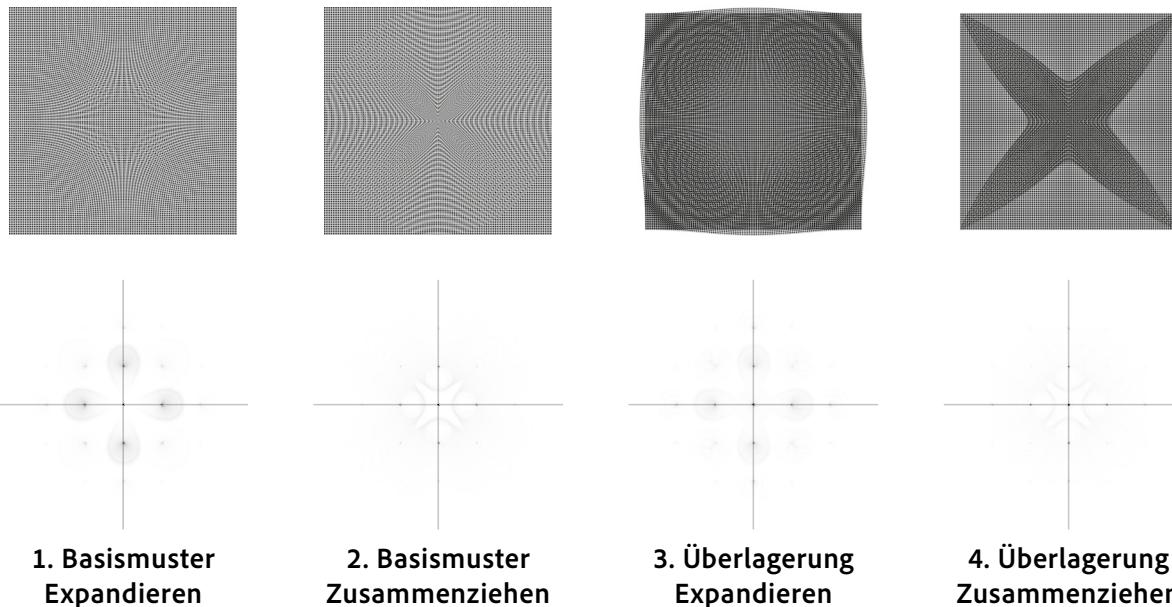


ABB. 4.23. Beispiele für die Effekte des kreisförmigen Expandierens und Zusammenziehens. 1. und 2. zeigen die Effekte bei Verwendung eindimensionaler Grundstrukturen, 3. und 4. bei Verwendung zweidimensionaler Grundstrukturen

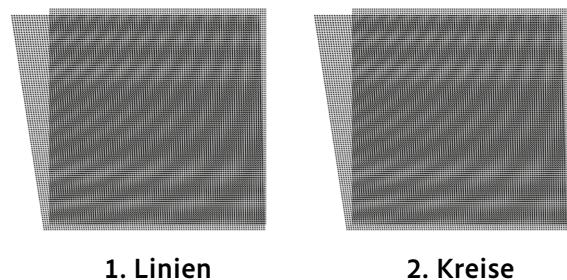


ABB. 4.22. Vergleich des optischen Erscheinungsbildes von Moiréstrukturen ausgelöst durch Überlagerung mit einer verzerrten Struktur in Hinblick auf den Unterschied zwischen eindimensionalen und zweidimensionalen grundlegenden Mustern. 1. zeigt eine Überlagerung von eindimensionalen Mustern (Linien). 2. zeigt eine Überlagerung von zweidimensionalen Mustern (Kreise).

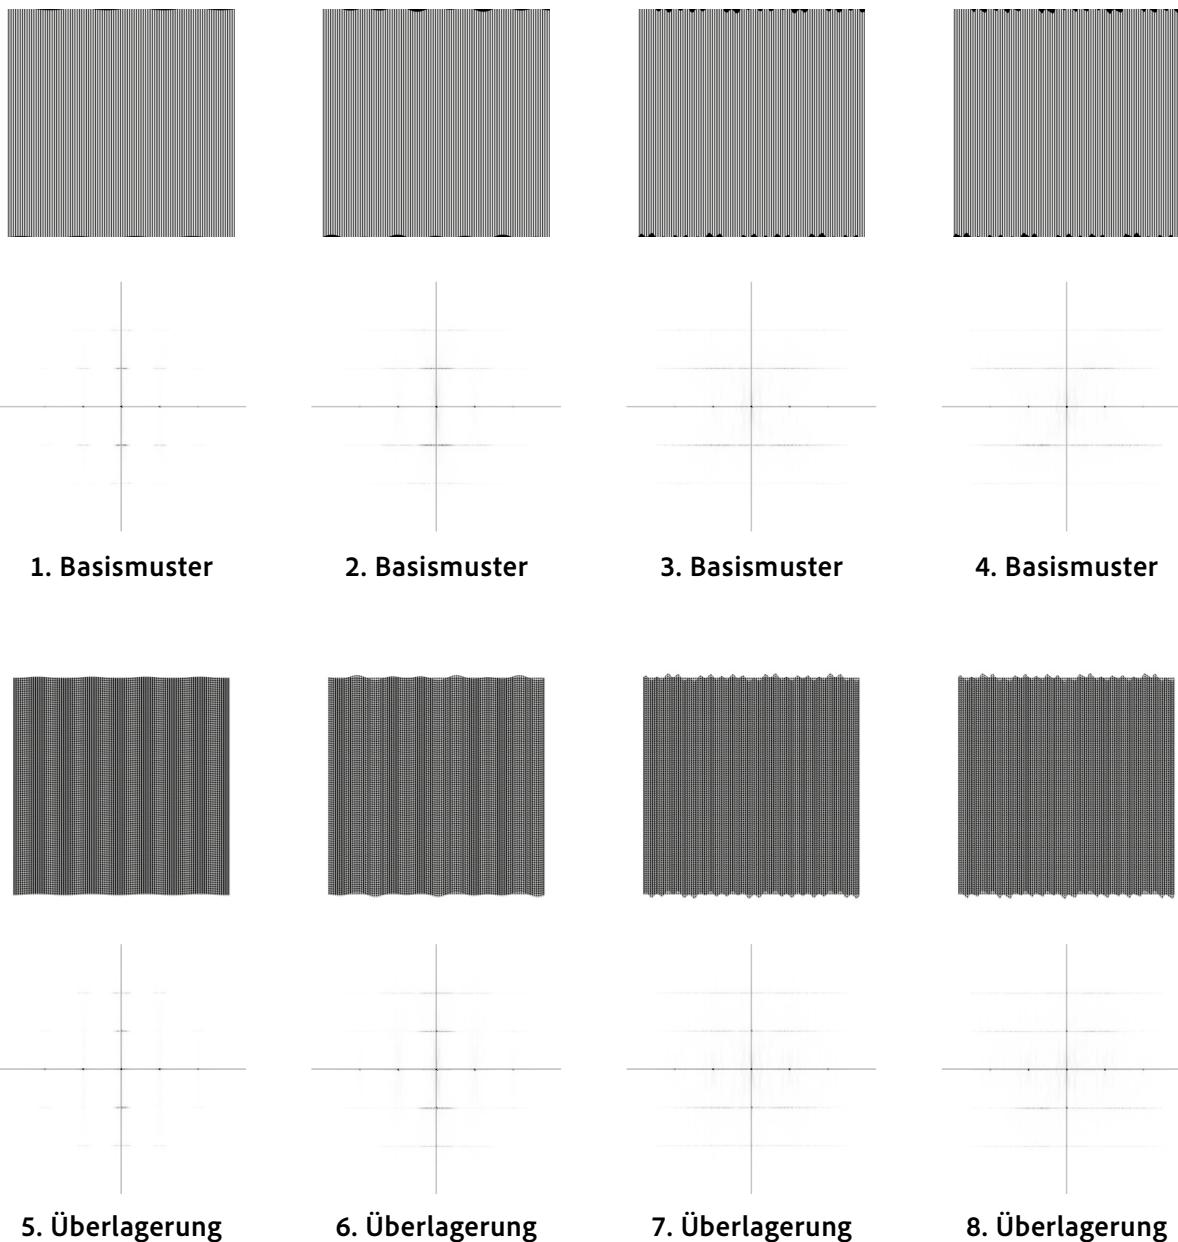


ABB. 4.24. Beispiele für wellenförmig verzerrte Raster und deren Überlagerungen. Die folgenden Überlagerungen wurden verwendet: 1. und 5. (500,10), 2. und 6. (500,10), (300,15), 3. und 7. (500,10), (300,15), (100,20), 4. und 8. (500,10), (300,15), (100,20),(50,5). Der erste Wert bezeichnet die Wellenlänge, der zweite die maximale Wellentiefe in Pixeln. Die Einzelwellen werden multipliziert, um eine Gesamtverzerrung zu erhalten.

ABB. 4.24 zeigt Beispiele für wellenförmige Verzerrung jeweils mit und ohne Überlagerung. Auffällig ist hierbei die optische Veränderung der Fourierspektren. Es zeichnen sich Impulse ab, die linienförmig mit einer fixen Entfernung zur y-Achse entstehen. Je mehr Kurven sich überlagern, desto breiter werden diese Linien. Bedenkt man, dass der beschriebene Effekt hier durch Überlagerung von gleichmäßigen sinusförmigen Wellen mit unterschiedlicher Wellenlänge und -tiefe erzeugt wird, erklärt sich dieses Phänomen.

5. Aktueller Forschungsstand in der Moiréerkennung

Wie bereits in Abs. 2 beschrieben, ist das Moiréphänomen ein umfangreich erforschtes Themengebiet. Auch rund um das Spezialthema der Behandlung des Moiréphänomens mit Methoden der Bildverarbeitung und des maschinellen Lernens existiert aktuelle Forschung. Die Mehrzahl aktueller Veröffentlichungen konzentriert sich auf die Entfernung anstatt die Erkennung von Moirés. Zudem stehen im Zentrum der Forschung Moirés, die durch die Aufnahme von Bildschirmen mit Digitalkameras entstehen. Für dieses Problem existieren Ansätze, die ohne die Verwendung von maschinellem Lernen auskommen. So beschreibt [6] eine Methode zur Absicherung von Gesichtserkennungssoftware gegen Täuschungsversuche. Dazu wird in Bildern anhand von Moiréstrukturen erkannt, ob es sich bei einem Bild und einer direkten Aufnahme eines Gesichtes oder um die Aufnahme eines Gesichtes von einem Bildschirm handelt. Dafür wird das zu klassifizierende Bild in der Frequenzdomäne auf hochfrequente Anteile untersucht. Dieser Ansatz lässt sich nicht auf das hier bearbeitete Problem übertragen, da eine Druckvorlage durch die Umwandlung in eine Rastergrafik stets hochfrequente Anteile beinhaltet. Im Kontext der Druckproduktionen existieren ältere Veröffentlichungen wie [15], welche durch Optimierung der Druckparameter die Entstehung von Moiréstrukturen minimieren. Veröffentlichungen, die sich mit der Erkennung von Moiréstrukturen auf Grundlage von Rasterabbildungen auseinandersetzen, konnten nicht gefunden werden.

Viel aktuelle Forschung existiert hingegen im Bereich der Moiréentfernung. Es kann angenommen werden, dass sich Herausforderungen und Herangehensweise für beide Probleme in gewissem Umfang überschneiden. Daher wird nachfolgend dargelegt, welche Ansätze im Bereich der Moiréentfernung existieren und ob diese auf das in dieser Arbeit beschriebene Problem übertragen werden können.

5.1. Aktueller Forschungsstand in der Moiréentfernung

Im Rahmen der *Computer Vision and Pattern Recognition Conference (CVPR) 2020* wurde, neben anderen, die *NTIRE 2020 Challenge on Image Demoiréing* durchgeführt. Die Ergebnisse dieses Wettbewerbes werden in [16] beschrieben. Dort wird auf die Erzeugung des im Rahmen des Wettbewerbes verwendeten Datensatzes eingegangen und ein Überblick über eingereichten Ergebnisse und verwendeten Ansätze gegeben. Für die vorliegende Arbeit wurden die relevantesten Teilnehmer des Wettbewerbes sowie weitere besonders relevante oder aktuelle Veröffentlichungen analysiert und verglichen. Die Einreichungen [17], [18] und [19] erzielten im beschriebenen Wettbewerb die besten Ergebnisse. Die Mehrzahl der aktuellen Veröffentlichungen zur Entfernung von Moirés aus Bildern beziehen sich auf [20]. Zudem ist nach Ablauf des Wettbewerbes [21] mit gleicher Thematik veröffentlicht worden. Zusätzlich zu den genannten Veröffentlichungen werden nachfolgend auch [22] und [23] betrachtet. [22] wurde zur *NTIRE 2019 Challenge on Image Demoiréing* eingereicht. [23] ist neben [21] die einzige neuere Veröffentlichung, die gefunden werden konnte, welche sich explizit mit der Erkennung von Moirés mit Hilfe von Computer Vision beschäftigt. Aus der Analyse dieser Veröffentlichungen ergeben sich drei Strategien, die in verschiedenen Formen in der Mehrzahl der Veröffentlichungen angewandt werden:

1. Verfolgen einer Multi-Scale Strategie.
2. Nutzung der geometrischen Eigenschaften von Moiréstrukturen
3. künstliche Generierung von Bildern mit Moiréstrukturen

Diese drei Strategien wurden in abgewandelter Form auch in der vorliegenden Arbeit angewandt. Nachfolgend werden die in den Veröffentlichungen verwendeten Ansätze zur Behandlung der drei genannten Strategien beschrieben.

5.1.1. Multi-Scale Strategie

In Abs. 4.2 wird dargelegt, dass eine typische Eigenschaft von Moiréstrukturen ist, dass sie bei minimaler Veränderung der Eigenschaften der interferierenden Raster ihr grundlegendes optisches Erscheinungsbild beibehalten, während Winkel Θ_M und Periode T_M der Moiréstruktur sich deutlich ändern. Insbesondere die Änderung der Periode sorgt dafür, dass ein Moiréeffekt mit gleichem optischen Erscheinungsbild in vielen unterschiedlichen Skalierungen auftreten kann.

Die vorgestellten Veröffentlichungen aus dem Bereich der Moiréentfernung enthalten sämtlich Komponenten und Strategien, um diesem Effekt zu begegnen.

Im in [20] beschriebenen Modell wird zur Entfernung eines Moirés zunächst das Eingangsbild in fünf unterschiedliche Auflösungen herunterskaliert. Die Eingabe wird auf jedem dieser parallelen Verarbeitungswege verarbeitet und zuletzt wieder zusammengefügt. Die unterschiedlichen parallel verarbeiteten Auflösungen sollen dazu dienen, Moirémuster unterschiedlicher Frequenzen effektiv entfernen zu können.

[22] verwendet zur Verarbeitung der Eingabe in mehreren Skalierungen Kombinationen aus Komponenten, die als *Multi-Scale Extractor* und *Squeeze-and-Excitation Block* bezeichnet werden. Ersterer basiert auf einer in [24] beschriebenen Architektur und erstellt Feature-Maps unterschiedlicher Auflösung. Der Squeeze-and-Excitation Block fügt diese in gewichteter Form wieder zusammen.

[17] verwendet eine Architektur, die an die in [25] beschriebene U-Net-Architektur angelehnt ist. Das dieser Architektur innewohnende Down- und Upsampling der Eingabe kann als Multi-Scale Strategie verstanden werden.

In [18] wird als relevante Neuerung ein *Attentive Fractal Network* basierend auf Attentive Fractal Blocks (AFB) vorgestellt. Diese AFBs sind rekursiv aufgebaut. Dass bedeutet, jeder AFB einer höheren Ordnung besteht wiederum aus einer Anzahl von AFBs niedriger Ordnung und so weiter. Ein AFB der untersten Ordnung besteht schließlich aus einer Anzahl von Convolutional und LeakyReLU Layern. Die rekursive Anordnung gleich aufgebauter Blöcke dient unter anderem der Verfolgung einer Multi-Scale Strategie.

[19] verwendet eine *Multi-Scale Feature Encoding Module* (MFSE) genannte Architektur. Diese erstellt Encodings der Eingabe in drei verschiedenen Skalierungen und fügt diese wieder zusammen.

[21] übernimmt zur Erkennung von Moiréstrukturen in mehreren Auflösungen die sogenannte BiFPN-Architektur aus [26] zum Encoding von High-Level-Features in verschiedenen Auflösungen. Die Low-Level Features, wozu Moiréstrukturen meist zählen, werden erkannt, indem die ersten beiden Blöcke eines ResNet18[27] erzeugten Feature Maps verarbeitet werden. Lediglich [23] verwendet keine Multi-Scale Strategie.

5.1.2. Nutzung der geometrischen Eigenschaften von Moiréstrukturen

Wie in Abs. 2 beschrieben, lassen sich Moiréstrukturen durch Darstellung in der Frequenzdomäne beschreiben. Daher liegt es nahe, sich dies auch in Modellen zur Entfernung von Moiréstrukturen zu Nutzen zu machen.

[17] verwendet eine diskrete Wavelet-Transformation zur Transformation des Eingabebildes in die Waveletdomäne. [22] nutzt eine Edge Predictor zur Erkennung von Kanten. Dies ist zwar keine Nutzung der Frequenzdomäne, wird aber mit einem ähnlichen Ziel angewandt. [20], [18], [19] und [21] betrachten die geometrischen Eigenschaften der Moiréstrukturen nicht gesondert. Es bleibt weiterhin festzustellen, dass eine Transformation in Frequenzdomäne mit Hilfe einer Fourier-Transformation in keinem der betrachteten Veröffentlichungen verwendet wird. [23] verwendet eine Wavelet-Dekomposition, um das Eingabebild anhand seiner Wavelet-Eigenschaften aufzutrennen.

5.1.3. Künstliche Generierung von Moirés

In [20] wird eine Methode beschrieben, bei der aus einem beliebigen Ausgangsbild ohne Moiré ein entsprechendes Zielbild mit Moiré zu erstellt werden kann. Dafür werden die Ausgangsbilder auf einem Bildschirm dargestellt und diese Darstellung mit Hilfe einer Kamera aufgenommen. Durch die Überlagerung der Rasterstruktur von Bildschirm und Kamerasensor entsteht ein Moiréeffekt. [21] beschreibt eine Weiterentwicklung der künstlichen Generierung von Moirémustern aus [19]. Zur Erzeugung von künstlichen Moirés werden hier isolierte Moiréstrukturen mit moiré-freien Bildern kombiniert. Die Moiréstrukturen werden erzeugt, indem entsprechend des Vorgehens in [28] Aufnahmen eines weißen Bildschirms erzeugt werden. Die dazu verwendete Aufnahmesituation ist in ABB. 5.1 dargestellt.

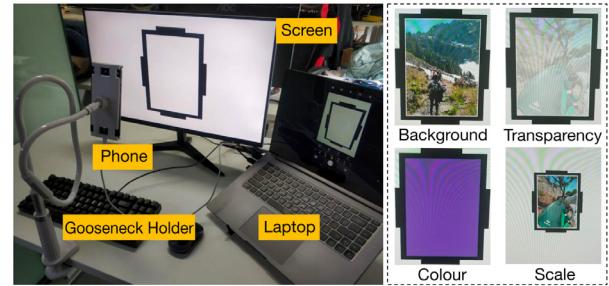


ABB. 5.1. *Aufnahmesituation aus [21] zur Generierung von Moiréstrukturen ohne Bildinhalt. Die Aufnahmesituation in [19] ist vergleichbar. Die schwarze Umrundung dient der Entzerrung der Aufnahme in einem nachgelagerten Verarbeitungsschritt.*

5.1.4. Übertragbarkeit auf die vorliegende Arbeit

Die beschriebenen Lösungen lassen sich aus mehreren Gründen nur begrenzt auf das in dieser Arbeit beschriebene Problem übertragen. Zunächst wird hier ein anderes Problem bearbeitet. Es kann zwar angenommen werden, dass es Schnittmengen zwischen den Herausforderungen der Moiréerkennung und der Moiréentfernung gibt. Bis auf [21] und [23], welche insbesondere die Erkennung und nicht die Entfernung von Moiréstrukturen bearbeiten, verwenden die untersuchten Veröffentlichen Architekturen, dem Autoencoder Prinzip entlehnt sind [28](S.296f). Diese sind für Klassifizierungsaufgaben ungeeignet. Zudem ist die Aufgabe der Klassifizierung von Moiréstrukturen einfacher als die Entfernung selber, weshalb in dieser Arbeit zunächst simplere Architekturen erprobt werden. Auch die beschriebenen Methoden zur künstlichen Erzeugung von Moiréeffekten lassen sich nicht unmittelbar auf das hier zu bearbeitende Problem übertragen. Auf diesen Punkt wird im Detail in Abs. 7 eingegangen.

6. Verwendete Technologien

Nachfolgend wird auf die relevantesten in dieser Arbeit verwendeten Technologien eingegangen. Die beschriebene Software ist in Python[29] implementiert. Insbesondere werden dabei die folgenden Bibliotheken benutzt:

- Pillow 10.2.0
- Numpy 1.24.3
- PyTorch 2.3.0

Für die Erzeugung und Manipulation von Bildern wird die Softwarebibliothek Pillow verwendet[30]. Die Verwendung von Pillow anstatt der ebenfalls weit verbreiteten Bibliothek OpenCV[31] liegt vor allem darin begründet, dass Pillow in der Lage ist, Bilder im CMYK-Farbmodus zu öffnen und zu schreiben. OpenCV hingegen öffnet CMYK-Bilddateien automatisch im RGB-Farbmodus. Die Verwendung des CMYK-Farbmodus ist für die verwendete Software, wie in *Abs. 3* und *Abs. 9.1* beschrieben, unverzichtbar.

Für einige Bildoperationen konnten keine geeigneten Pythonbibliotheken gefunden werden. Dies betrifft insbesondere die Umwandlung der gesammelten PDF-Seiten in CMYK-Halbtonebilder. Diese erfordert, wie in *Abs. 7.1* beschrieben, die Erhaltung der CMYK-Farbwerte. Im Rahmen dieser Arbeit konnte keine Pythonbibliothek gefunden werden, die diesen Anforderungen genügt. Stattdessen wurde die Anforderung in Adobe Photoshop[32] umgesetzt. Zudem wurde Adobe Photoshop in dieser Arbeit als Raster Image Prozessor eingesetzt, welcher die erzeugten Halbtoneabbildungen in Rasterabbildungen umwandelt. Dies ist im Prozess der Datengenerierung zweimal notwendig. Zuerst zur Umwandlung von Halbtonebildern aus dem natürlichen Moirédatensatz und dem Generierungsdatensatz in Rasterabbildungen (siehe: *Abs. 7*) sowie zur Umwandlung der synthetischen Moirés in Rasterabbildungen (siehe: *Abs. 8.4*).

Obwohl es sich bei Photoshop um eine Desktopanwendung handelt, konnten die beschriebenen Prozesse automatisiert werden. Zur Automatisierung können in Photoshop unter anderem Aktionen[33], Skripte und ein Command Line Interface[34] verwendet werden. Für diese Arbeit wurde über ein Python-Script das Command Line Interface für Photoshop angesteuert. Über diese Schnittstelle werden in Photoshop erstellte Aktionen ausgeführt.

Zur Manipulation einzelner Farbkanäle, den Effekt zum kreisförmigen Expandieren und Zusammenziehen (siehe: *Abs. 8.3.1.4*) sowie die Berechnung der schnellen Fourier-Transformation wurde die Pythonbibliothek Numpy eingesetzt[35].

Die Implementierung des Trainingsprozesses der verwendeten Klassifizierungsmodelle wurde in Pytorch umgesetzt[36]. Diese Wahl lässt sich darauf zurückführen, dass es sich um ein weit verbreitetes Framework handelt, welches häufig in aktueller Forschung eingesetzt wird. So verwenden sowohl alle in *Abs. 5.1* betrachteten Veröffentlichungen als auch das in *Abs. 8.1* verwendete Modell aus [37] Pytorch zu Implementierung der Modelle. Zudem enthält Pytorch bereits die in *Abs. 10.2* beschriebenen Modellarchitekturen, wodurch die Implementierung erleichtert wird.

Die Auszeichnung der natürlichen und synthetischen Moirés wurde in LabelStudio durchgeführt[38]. LabelStudio ist eine OpenSource Software, über die Projekte mit spezifischen Auszeichnungsbedingungen erstellt und konfiguriert werden können. So können die zu vergebenden Kategorien sowie die Form der Auszeichnung, beispielsweise durch rechteckige Boxen oder Polygone, definiert werden.

7. Erstellung eines geeigneten Datensets

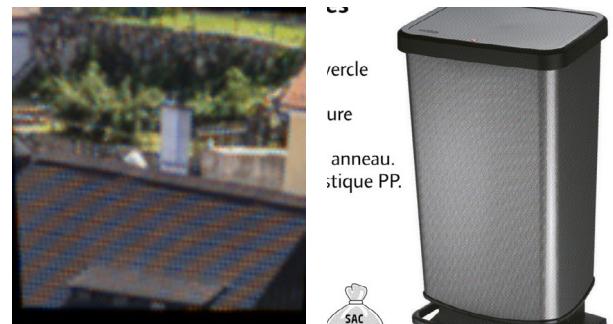
Wie bereits in Abs. 5 beschrieben, konzentriert sich die aktuelle Forschung insbesondere auf Moiréstrukturen, die durch die Foto- oder Videoaufnahme von Bildschirmen entstehen. Beispiel dafür sind das in [16] beschriebene CFAMoire Dataset oder das in [21] beschriebene MoireScape Dataset. Die Eigenschaften der so entstehenden Moirés unterscheiden sich in einigen Punkten von denen, die im Druckkontext entstehen:

- Die Kategorien der Überlagerung (vergleiche: Abs. 4.2) sind hier im Kern auf eine Kategorie eingeschränkt. Der wesentliche Effekt, der auf die abgetastete Struktur wirkt, ist für die Situation der Fotoaufnahme eines Bildschirmes die der Verzerrung. Anteile von Rotation und Skalierung sind enthalten, unterstützende Eigenschaften wie kreisförmiges Zusammenziehen und Expandieren hingegen sind nicht enthalten. Darüber hinaus sind Pixelraster von Bildschirmen als abzutastende Struktur im Vergleich zu beispielsweise textilen Strukturen sehr gleichförmig.
- Im Falle der Druckproduktion sind Moiréstrukturen auf einzelne Objekte, beispielsweise Kleidungs- oder Möbelstücke, begrenzt. Bei der Aufnahme von Bildschirmen hingegen reichen Moiréstrukturen über einzelne Objekte hinaus und betreffen insbesondere auch weiße Flächen (siehe: [21](Fig.7)).
- Dateien, die für die Druckproduktion verwendet werden, sind im CMYK-Farbmodus aufgebaut. Die genannten existierenden Datensets verwenden hingegen den RGB-Farbmodus.
- Die zur Abtastung verwendeten Strukturen, im Falle der Bildschirmaufnahmen der Kamerasensor, im Falle der Druckproduktion eine Raster Image Prozessor Software, haben abweichende Eigenschaften. Die relevanteste Abweichung ist hier, dass im Falle von Druckprodukten die Druckraster je nach Farbauszug in unterschiedlichen Winkeln angeordnet ist. Die Anordnung der Pixel im Kamerasensor liegt hingegen auf einem 0° Winkel.
- Das optische Erscheinungsbild von Seiten für die Druckproduktion unterscheidet sich relevant von den in den genannten Datensets verwendeten Bilddateien.

ABB. 7.1 zeigt jeweils ein Beispiel aus dem CFA Moire Dataset und eine beispielhafte Abbildung aus der Druckproduktion. In dieser Abbildung können einige der genannten Unterschiede beobachtet werden.

Aus diesen Gründen ist es notwendig, ein neues, speziell auf die Anforderungen der Druckproduktion zugeschnittenes Datenset zusammenzustellen. Dazu wurden Beispiele mit Moiréstrukturen aus der Druckproduktion gesammelt.

Wie in Abs. 1 erwähnt, findet im Regelfall keine gesonderte Kontrolle auf Moiréeffekte vor der dem Druck statt. Wird während des Drucks ein störender Moiréeffekt entdeckt, wird die Produktion gestoppt, eine Korrektur der Daten und neue Druckplatten angefordert. Diese Fehlermeldungen werden unternehmensintern erfasst. Auf dieser Basis wurden, sofern vorhanden, die zugehörigen Druckdaten



1. Beispiel aus dem CFAMoire Dataset

2. Beispiel für ein reales Moiré aus der Druckproduktion

ABB. 7.1. Beispiele für Daten aus dem CFAMoire Dataset (1.) und Daten aus der Druckproduktion (2.). Wie deutlich zu sehen, unterscheiden sich die Abbildungen zwar wenig in Hinblick der geometrischen Form aber stark in Hinblick auf die Farbigkeit der Moiréstrukturen und das optische Erscheinungsbild.

gesammelt und ausgewertet. Die Druckdaten werden unternehmensintern nur für einen begrenzten Zeitraum nach der Druckproduktion archiviert. In einigen Fällen waren zudem die fehlerhaften Druckdateien nicht mehr vorhanden, da sie kundenseitig durch neue, moiréfreie Druckdateien ersetzt wurden. Der so zusammengestellte Datensatz wird nachfolgend als natürlicher Moirédatensatz bezeichnet. Insgesamt konnten so 117 Moirés gefunden werden. Diese verteilen sich auf 37 einzelne Seiten und stammen aus 10 unterschiedlichen Druckprodukten. 74 Moirés des Datensatzes stammen aus einem einzelnen Druckprodukt. Die Moirés in diesem Produkt resultieren aus der Redigitalisierung und skalierten Montage eines vorherigen Druckproduktes (siehe: Abs. 4.1.2.1). Die unterschiedlichen möglichen Ausprägungen von Moiréeffekten (siehe: Abs. 4) sind demzufolge nicht gleichmäßig im Datensatz vorhanden. Aufgrund des geringen Umfangs sowie der ungleichmäßigen Verteilung der Ausprägungen im Datensatz kommt dieser nicht als Grundlage zum Training eines Klassifizierungsmodells in Frage. Daher ist es notwendig, synthetisch Moiréstrukturen zu erzeugen, um einen Datensatz mit geeignetem Umfang und Varianz zu erhalten. Das dazu verwendete Modell wird in Abs. 8 beschrieben. Nachfolgend werden die durch dieses Modell erzeugten Moiréstrukturen zur Unterscheidung als synthetische Moirés bezeichnet. Die gesammelten realen Beispiele aus der Druckproduktion werden nachfolgend als natürliche Moirés bezeichnet.

Zur Erstellung von Trainingsdaten mit synthetischen Moirés wurde ein weiterer Datensatz mit moiréfreien Druckvorlagen in Form von PDF-Seiten zusammengestellt. Dieser wird nachfolgend als Generierungsdatensatz bezeichnet. Er umfasst 2000 PDF-Seiten. Die Seiten wurden zufällig aus allen archivierten Produktionsdaten ausgewählt und sind damit repräsentativ. Der Datensatz wurde manuell bereinigt. Dabei wurden Seiten aus dem Datensatz entfernt, für die mindestens eine der folgenden Bedingungen gilt:

- Der druckende Bereich der Seite ist leer.
- Der druckende Bereich der Seite enthält ausschließlich Text und einfache grafische Elemente wie Linien, einfarbige Flächen oder geometrische Formen, aber keine Bilder oder komplexen Grafiken (siehe: ABB. 7.2(2.)).
- Die Seite enthält ausschließlich Inhalte, die technisch nicht dazu geeignet sind, Moiréstrukturen zu erzeugen. Beispiele sind PDF-Seiten, die Formen für Stanzen, Perforationen oder das Aufbringen von Lacken enthalten (siehe: ABB. 7.2(1.)).
- Die Seite ist inhaltlich für den Test nicht geeignet. Beispiele sind Testdrucke, die Marken und Formen für die Auswertung von Produktionsparametern enthalten (siehe: ABB. 7.2(3.)).
- Die Seite ist technisch ungeeignet, beispielsweise weil sie beschädigt und nicht zu öffnen ist.



ABB. 7.2. Beispiele für Seiten, die aus dem Generierungsdatensatz entfernt wurden. 1. dient als Vorlage für das flächige Auftragen von Lack auf die Seite. 2. hat keinen relevanten Inhalt, der ein Moiré erzeugen könnte. Bei 3. handelt es sich um einen Testdruck, der zur Optimierung der Prozessparameter dient.

Die nicht geeigneten PDF-Dateien wurden zuvor aus einem größeren Datensatz entfernt, aus dem dann der kleinere, 2000 Seiten umfassende Datensatz zufällig ausgewählt wurde.

Nachfolgend wird auf die durchgeführten Vorverarbeitungsschritte und die Auszeichnung der gesammelten Daten eingegangen. Zudem wird beschrieben, welche besondere Herausforderung die Einrichtung einer geeigneten Bewertungssituation für die Bewertung von Moiréstrukturen am Bildschirm darstellt.

7.1. Vorverarbeitung und Auszeichnung der Druckseiten

Für alle Dateien der genannten drei Datensätze ist eine Vorverarbeitung notwendig. Beispiele für die in den Zwischenschritten erstellten Bilddateien finden sich in ABB. 7.3.

Dafür erfolgt zunächst eine Umwandlung der PDF-Seite in eine JPG-Datei. Diese JPG-Datei ist im CMYK-Farbmodus aufgebaut. Die Umwandlung wurde mit der Software Adobe Photoshop durchgeführt. Aufgrund der in Abs. 3.3.3 beschriebenen Eigenschaften des Farbaufbaus ist es notwendig, dass bei der Umwandlung die CMYK-Farbwerte erhalten bleiben. Neuberechnung der Farbwerte beispielsweise über Umwandlung in den Lab-Farbmodus und Rückwandlung in CMYK-Farbwerte muss vermieden werden[39](3.2, S.40). In diesem Fall wird häufig der Farbwert einzelner Pixel verändert, sodass die drei Buntfarben C,M und Y verstärkt und das Schwarz (K) verringert wird.

Für die vorliegende Arbeit hat nur Photoshop dies sichergestellt. Für zukünftige Anwendungen sind auch andere Technologie zur Umwandlung denkbar, die zum aktuellen Zeitpunkt nicht zur Verfügung stehen oder im Rahmen dieser Arbeit nicht getestet werden konnten. Auf die technische Umsetzung dieses Prozesses wird in Abs. 6 eingegangen.

Als Auflösung der erzeugten Dateien wurde 600 dpi gewählt. Niedrigere Auflösungen sind nicht geeignet, um die Strukturen der in Abs. 8.2.1 beschriebenen Patternvorlagen in einer ausreichenden Qualität darstellen zu können. Die erzeugten 600 dpi JPG-Dateien werden nachfolgend als Halbtonseiten bezeichnet.

Da Moiréstrukturen im Druck häufig durch Interferenzen mit dem Druckraster entstehen, ist die



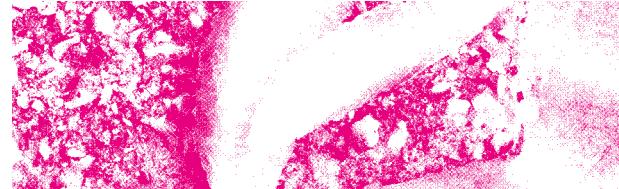
6. Rasterbild 600dpi



5. 1-bit Black 2400dpi



4. 1-bit Gelb 2400dpi



3. 1-bit Magenta 2400dpi



2. 1-bit Cyan 2400dpi



1. Halbtontonbild 600dpi

ABB. 7.3. Die verschiedenen im Laufe der Vorverarbeitung erstellten Dateien.

1. Halbtontonbild in 600 dpi
- 2.-5. 1-bit Rasterbilder in 2400 dpi für Cyan, Magenta, Gelb und Schwarz
6. zusammengefügte Rastergrafik in 600 dpi

Umwandlung in eine Rasterabbildung mit Hilfe eines Raster-Image Prozessors notwendig. In dieser Arbeit wurde dafür eine Funktion von Adobe Photoshop verwendet. Photoshop erlaubt es, eine Halbtongraustufenabbildung in eine 1-Bit Abbildung zu konvertieren, indem, analog zur Funktionsweise eines in Abs. 3.3 beschriebenen Raster-Image Prozessors, die Halbtoneabbildung in Rasterpunkte umgewandelt wird. Zur Umwandlung wurden die einzelnen Farbkanäle der Halbtone Seite als Halbtongraustufenbilder entnommen und in Rasterbilder umgewandelt. Die Pixelauflösung des Zielbildes wurde, analog zur Belichterauflösung, auf 2400 dpi festgelegt. Als Rasterweite wurde 150 lpi und als Rasterpunktform die Ellipsenform verwendet. Dies entspricht einer typischen Konfiguration in der Druckproduktion.

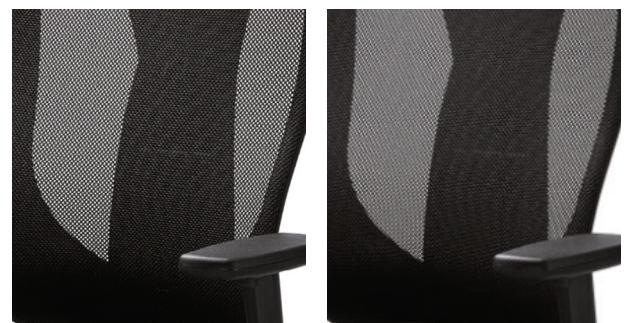
Die so erstellten 1-Bit Rasterabbildungen wurden in einem weiteren Schritt wieder zu einem CMYK-Bild zusammengeführt und auf 600 dpi heruntergerechnet. Die Verringerung der Auflösung wirkt wie ein Tiefpassfilter und entfernt oder dämpft hohe Frequenzen. Dies verringert Alias-Effekte bei der Betrachtung der gerasterten Seiten am Bildschirm (siehe: Abs. 7.2). Die so erstellten Dateien werden nachfolgend als Rasterseiten bezeichnet.

Die erstellten Rasterseiten werden manuell ausgezeichnet. Die Auszeichnung erfolgt am Bildschirm unter den in Abs. 7.2 beschriebenen Bedingungen. Die erkannten Moirés werden in Form von Polygonen in den Seiten markiert. Dies erlaubt einen exaktere Aufteilung in Klassifizierungskacheln zum Training und zur Validierung des Klassifikationsmodells. Die Erstellung von Klassifizierungskacheln wird in Abs. 9 beschrieben.

7.2. Einrichtung einer geeigneten Bewertungssituation zur Bewertung von Moiréstrukturen

Wie in Abs. 2 beschrieben, entstehen Moiréeffekte durch die Überlagerung von zwei oder mehr periodischen Strukturen. Die für die Druckproduktion relevanten Kategorien von Überlagerungen werden in Abs. 4.1 beschrieben. Für die optische Bewertung von möglichen Moiréstrukturen ergeben sich hierdurch Herausforderungen. Bei der Bewertung einer potenziellen Moiréstruktur am Bildschirm kommen als zusätzliche Faktoren der Vergrößerungsfaktor der Abbildung am Bildschirm sowie die Interferenz mit dem Pixelraster des Bildschirms hinzu. Ein Beispiel für die Auswirkungen dieser zusätzlichen Faktoren ist in ABB. 7.4 zu sehen. Auch eine Bewertung anhand von Ausdrucken auf einem Inkjet- oder Laserdrucker fügt weitere periodische Strukturen hinzu, da auch diese Drucker Raster-Image-Prozessor Software verwenden, um Abbildungen auf dem Ausdruck darzustellen [8](S.747f). Einzig das industriell gedruckte Produkt fügt keine weiteren periodischen Strukturen hinzu. Die Herstellung von industriellen Druckprodukten für zur Bewertung einer großen Anzahl an Beispielen ist jedoch realistisch nicht umsetzbar.

Daher wurde für diese Arbeit untersucht, inwiefern eine potenzielle Moiréstruktur am Bildschirm



1. Skalierung: 30,5% 2. Skalierung: 12,8%

ABB. 7.4. Der selbe Bildausschnitt in der Bildschirmbetrachtung in verschiedenen Skalierungsstufen. Bei einer Skalierung von 100% entspricht ein Pixel des dargestellten Bildes einem Pixel des Bildschirms. Es ist erkennbar, dass in 2. ein Moiré in den äußeren Bereichen der Stuhllehne vorhanden ist, welches in 1. nicht sichtbar ist. Das Moiré im mittleren Teil der Stuhllehne ist hingegen in beiden Skalierungsstufen sichtbar.

bewertet werden kann. Dafür wurden für 12 Seiten mit echten Moirés mit der in Abs. 7.1 beschriebenen Methode Rasterabbildungen erzeugt. Rasterweite sowie verwendete Rasterwinkel entsprachen hierbei denjenigen, die zur Druckproduktion verwendet wurden. Für diese 12 Seiten lagen jeweils gedruckte Exemplare aus der Druckproduktion bereit. Diese gedruckten Exemplare wurden mit den erzeugten Rasterabbildungen optisch abgeglichen. Um Moiréstrukturen, die durch eine Interferenz mit dem Bildschirmraster entstehen, von den übrigen, in den Druckvorlagen enthaltenen, Moiréstrukturen zu unterscheiden, wurden die Rasterabbildungen in verschiedenen Vergrößerungsstufen am Bildschirm betrachtet. Moiréstrukturen, die durch eine Interferenz mit dem Bildschirmraster entstehen, müssen sich durch das veränderte Verhältnis zwischen den sich überlagernden Strukturen optisch verändern oder gänzlich verschwinden. Die im Druckraster enthaltenen Moiréstrukturen hingegen bleiben in ihrem optischen Erscheinungsbild gleich, da sich das Verhältnis zwischen den interferierenden Strukturen nicht verändert. Die einzige Ausnahme dazu ist, wenn durch den gewählten Vergrößerungsfaktor die Darstellung Moiréstruktur zu klein wird, um vom Pixelraster des Bildschirms adäquat dargestellt werden zu können. Sie dazu auch Abs. 4.1.1.

Für die 12 verglichenen Seiten konnten jeweils alle im Druckprodukt vorhandenen Moiréstrukturen auch in der Rasterabbildung am Bildschirm beobachtet werden. Dabei wurde nicht nur das Vorhandensein der Moiréstrukturen sondern auch deren optische Erscheinungsform verglichen.

Für die Bewertung von potenziellen Moiréstrukturen am Bildschirm wird dabei nachfolgend von folgendem ausgegangen: Ist eine Moiréstruktur in der Rasterabbildung am Bildschirm in mehreren unterschiedlichen Vergrößerungsstufen in gleicher geometrischer Form sichtbar, so resultiert diese nicht aus einer Interferenz zwischen dem Pixelraster des Bildschirms und Bildelementen sondern ist in der Druckvorlage enthalten und damit auch in einem eventuell herzustellenden Druckprodukt sichtbar.

8. Algorithmus zur künstlichen Erzeugung von Moiréstrukturen

Wie bereits in Abs. 7 beschrieben, konnte nur ein kleiner Datensatz von natürlichen Moirés zusammengestellt werden, der zudem in Hinblick auf die in Abs. 4.2 beschriebenen Kategorien von Moirés nicht ausgeglichen ist. [20] beschreibt ein Vorgehen zur künstlichen Erzeugung von Moiréstrukturen in zuvor moiréfreien Bildern. Dafür werden diese moiréfreien Bilder auf einem Bildschirm angezeigt und durch eine Kamera aufgenommen. Hierbei entstehen Moiréeffekte durch die Überlagerung Rasterstruktur des Bildschirms und des Kamerasensor (siehe: Abs. 2.2). [21] entwickelt diese Methode weiter, indem Moiréstrukturen durch die Aufnahme eines weißen Bildschirmes erzeugt und in zuvor moiréfreie Bilder montiert werden. Beide Verfahren sind jedoch aufgrund ihrer Ausrichtung auf die Erkennung von Moiréeffekten, die durch die Aufnahme vom Bildschirmen entstehen, nicht auf die in dieser Arbeit untersuchte Problemstellung übertragbar. Die Gründe hierfür werden in Abs. 7 beschrieben. Daher wurde im Rahmen der vorliegenden Arbeit ein neuer Algorithmus zur Erzeugung von synthetischen Moirés entwickelt.

Die Idee des Modells ist es, künstlich erzeugte Störstrukturen in existierende, moiréfreie Objekte zu montieren und so dort künstlich Moiréeffekte zu erzeugen. Zudem entstehen so Paare aus moiréfreien und moirébehafteten Objekten, was für das Training eines Klassifizierungsmodells sehr vorteilhaft ist. Dafür wird eine Auswahl an periodischen Rasterstrukturen bereitgestellt, die als Grundlage der zu montierenden Störstrukturen dienen. Diese werden nachfolgend als Patternvorlagen bezeichnet. Auf die Erzeugung und Auswahl der Patternvorlagen wird in Abs. 8.2.1 im Detail eingegangen. Auf diese Patternvorlagen werden jeweils individuelle, in einem festgelegten Wertebereich zufällig parametrisierte Effekte, wie Rotation, Skalierung und so weiter angewandt. Diese Effekte werden nachfolgend als Patterneffekte bezeichnet. Auf die implementierten Patterneffekte und ihre Eigenschaften wird in Abs. 8.3 eingegangen. Dabei werden pro Seite stets mehrere Objekte ausgewählt und jeweils unabhängig voneinander in diese Objekte Störstrukturen montiert. Die Ausschnitte nach Montage eines erzeugten Patterns werden nachfolgend als Objektkacheln bezeichnet. Die Ausschnitte vor der Montage des Patterns werden als unveränderte Objektkacheln bezeichnet. Der Ablauf der Erzeugung gliedert sich in die folgenden Abschnitte

1. Erkennung von Objektmasken
2. Montage von künstlichen Störstrukturen in moiréfreie Seiten
3. Umwandlung in eine Rasterabbildung
4. manuelle Auszeichnung

Auf die einzelnen Schritte wird nachfolgend im Detail eingegangen. ABB. 8.1 zeigt den kompletten Ablauf der Erzeugung von synthetischen Moirés. Im Rahmen dieser Arbeit wurde sich auf die Montage von Moiréstrukturen ausschließlich in den Schwarzkanal der jeweiligen Objektkachel beschränkt. Schwarz ist die dunkelste der Druckfarben, daher ist davon auszugehen, dass sich Moiréstrukturen im Schwarzkanal deutlich stärker auf die Qualität des erstellten Druckproduktes auswirken, als Moiréstrukturen in den übrigen Farbkanälen. Darüber hinaus wurde in Abs. 3.3.3 beschrieben, dass in der Druckproduktion im Regelfall der Farbaufbau einer Seite angepasst wird, sodass wesentliche Kontraste und Formen im Schwarzkanal abgebildet sind. Der entwickelte Algorithmus ist in der Lage, Moiréstrukturen auch in die übrigen Farbkanäle zu montieren. Daher kann es Teil von zukünftiger Bearbeitung des Themas sein, die Anwendung des vorliegenden Modells auf die übrigen Farben auszuweiten.

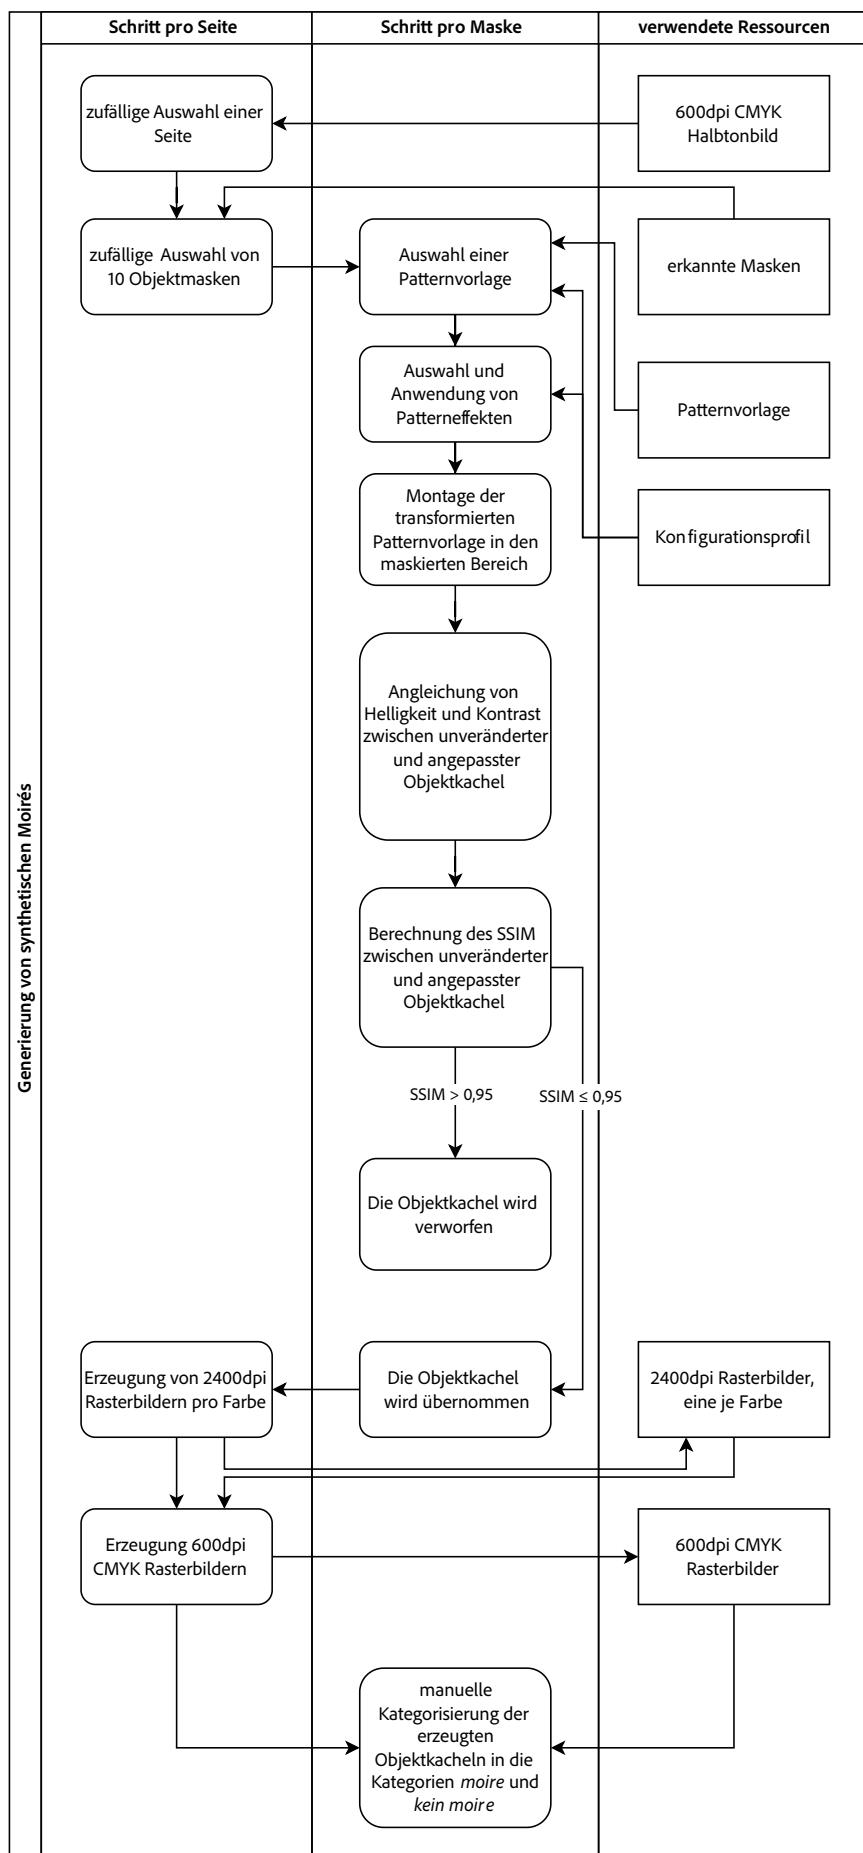


ABB. 8.1. Der gesamte Workflow von der Auswahl einer Seite bis zur Auszeichnung der generierten synthetischen Moiréstrukturen.

8.1. Erkennung von Objektmasken

Als Dateibasis verwendet das Modell die entsprechend der Beschreibung in Abs. 7 erzeugten 600 dpi Halbtonbilder der Seiten. In einem vorbereitenden Schritt vor der eigentlichen Erzeugung der synthetischen Moirés werden in diesen Halbtonbildern Objekte erkannt und segmentiert. Dazu wird die Technologie *Segment Anything* [37] mit dem Modell *ViT-H SAM* [40] verwendet. Segment Anything erkennt Objekte in der Seite und liefert pro erkanntem Objekt neben anderen Eigenschaften die Boundingbox des erkannten Objekts, den Stability Score der Maske (siehe: [37]) und eine Pixelmaske in Form einer 1-Bit Matrix. Die Auswahl der erkannten Masken wird anhand der folgenden Filterkriterien eingeschränkt:

- Die Größe der Maske liegt relativ zur Größe der Gesamtseite unterhalb eines definierten Schwellwertes. Dieser Schwellwert wurde mit 25% festgelegt. Die Größe ist als relativer Wert definiert, da das Modell häufig strukturierende Seitenelemente wie ganze Textblöcke, farbliche abgesetzte Seitenspalten und ähnliches erkennt. In ABB. 8.2 wird beispielsweise der Hintergrund der Seite als zusammenhängendes Objekt erkannt. Die Größe dieser Elemente ist abhängig von der Größe der Seite, weshalb die maximal zulässige Größe einer Box als relativer Wert formuliert ist.
- Die Größe der Maske liegt oberhalb einer definierten Minimalgröße. Für diese Arbeit wurde dieser Wert mit 105x105 Pixel beziehungsweise 11025 Pixel festgelegt. Im Unterschied zur maximal zulässigen Größe ist die minimal zulässige Größe als absoluter Wert formuliert. Anders als bei den größten strukturierenden Seitenelementen ändert sich Größe der kleinsten Elemente nicht. Wie in ABB. 8.2 zu sehen, sind dies beispielsweise einzelne Wörter oder technische Marken, die beim Exportprozess aus einem Layoutprogramm entstehen.
- Der Anteil des Inhalts des maskierten Bereiches, der Text beinhaltet, liegt unterhalb eines definierten Schwellwertes. In Text kommen sehr selten Moirés vor, da dieser meist negativ weiß oder mit einem Tonwert von 100% in einer der vier Grundfarben aufgebaut ist. Zudem sind die einzelnen Zeichen zu filigran, um ein Moirémuster mit einer für den Druck typischen Frequenz zu enthalten. Aus diesen Gründen sind Masken, deren maskierter Inhalt zum Großteil aus Text besteht, sowohl nicht repräsentativ für reale Moiréstrukturen und haben eine geringe Wahrscheinlichkeit, dass in diesen Bereichen künstlich ein Moiréeffekt entsteht. Daher sollen diese Masken herausgefiltert werden. Dafür wird auf dem maskierten Bereich eine Texterkennung durchgeführt. In dieser Arbeit wurde dafür die Software tesseract[41] genutzt. Für jeden erkannten Textabschnitt wird die Boundingbox dieses Textabschnittes zurückgegeben. Boundingboxen, bei denen der Confidence-Score der Erkennung unterhalb eines definierten Schwellwertes liegt, werden dabei herausgefiltert. Für diese Arbeit wurde der Schwellwert mit 50% definiert. Für alle übrigen Boxen wird wiederum eine Boundingbox errechnet. Liegt die Fläche dieser Boundingbox im Verhältnis zur Gesamtfläche der Maske oberhalb eines definierten Schwellwertes wird die Maske herausgefiltert. Dieser Schwellwert wurde für diese Arbeit mit 80% definiert.
- Überschneidet sich eine Maske zu mindestens einem bestimmten Anteil mit einer anderen Maske, so wird letztere aus der Auswahl entfernt. Das Segment-Anything Modell erkennt teilweise Objekte doppelt oder erkennt zwei Masken, die nur sehr geringe Unterschiede aufweisen. Um diese Dopplungen zu entfernen, wird für jede Kombination von Masken die Intersection over Union[28](Abs. 6.3.3) berechnet. Liegt diese oberhalb eines definierten Schwellwertes, wird die zweite der verglichenen Masken aus der Auswahl entfernt. Für diese Arbeit wurde der Schwellwert mit 0,9 definiert.

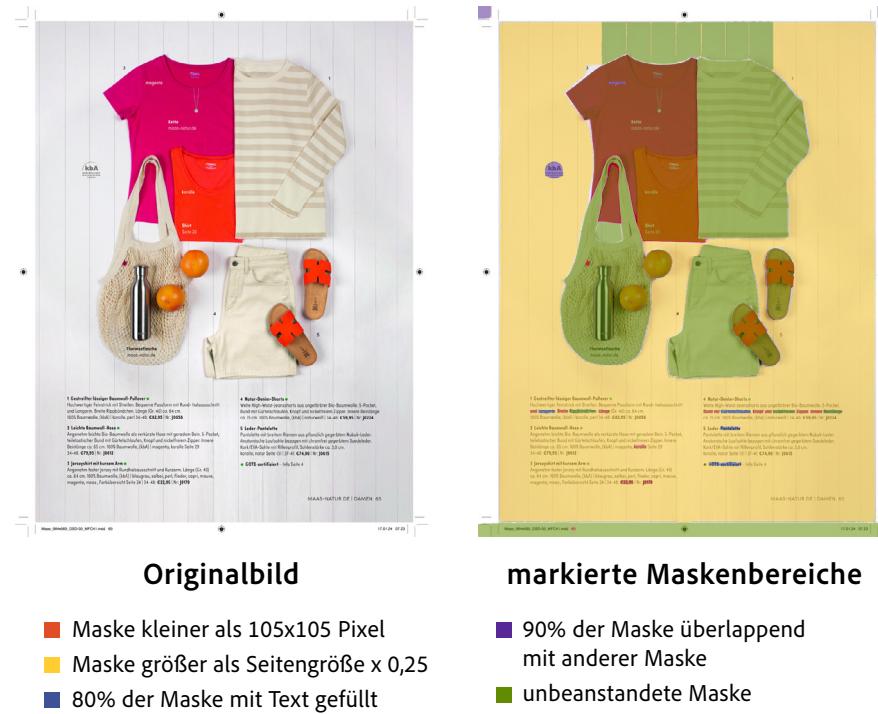


ABB. 8.2. Links ist eine beispielhafte Seite zu sehen, rechts die Markierung aller von Segment-Anything Modell erkannten Masken. Die Farbe der Maske gibt Auskunft darüber, ob die Maske für die weitere Verarbeitung ausgewählt oder aufgrund ihrer Eigenschaften entfernt wurde.

8.2. Montage von künstlichen Störstrukturen in moiréfreie Seiten

Den Kern des beschriebenen Modells bildet die Montage von künstlichen Störstrukturen in zuvor moiréfreie Objekte und Seiten. Dafür wird zunächst eine Seite ausgewählt. Die Auswahl erfolgt zufällig, wobei die Seiten jedoch ein Gewicht w erhalten, welches die Auswahl der Seite beeinflusst.

$$(8.1) \quad w_{\text{seite}} = s_{\max} - s_{\text{seite}} + 1$$

(8.1) beschreibt die Berechnung von w für jede Seite. s bezeichnet die Anzahl der synthetisch erzeugten Seiten, die bereits auf Basis der jeweiligen Seite erzeugt wurden. Es werden also Seiten, die bisher selten verwendet worden sind, bevorzugt. Durch das Hinzufügen des konstanten Wertes 1 wird sicher gestellt, dass jede Seite in jedem Durchgang ausgewählt werden kann.

Für die ausgewählte Seite wird darauf folgend eine Anzahl der in Abs. 8.1 beschriebenen Masken zufällig ausgewählt. Die Auswahl der Masken erfolgt anhand von Gewichten. Das Gewicht einer Maske ergibt sich aus der Fläche der Maske multipliziert mit ihren Stability Score. Als Fläche der Maske wird nicht die Fläche der Boundingbox sondern die Anzahl der nicht maskierten Pixel in der Maske verwendet. Durch die Gewichtung der Auswahl werden bevorzugt große und vom Segment Anything Algorithmus als präzise eingeschätzte Masken ausgewählt. In dieser Arbeit wurden pro Seite 10 Masken zur weiteren Verarbeitung ausgewählt.

Pro Seite werden die folgenden Schritte ausgeführt:

1. Auswahl einer Patternvorlage
2. Auswahl von Patterneffekten und deren Parametern
3. Anwendung von Patterneffekten



ABB. 8.3. Ablauf und verwendete Objekte in der Generierung von Objektkacheln mit synthetischen Moirémustern. Die ausgewählte Patternvorlage ist Perlin Noise mit Oktaven: 5, Seed: 33, 50% des maximalen Tonwertumfanges, Dehnungsfaktor X: 10, Dehnungsfaktor Y: 1. Die ausgewählten Patterneffekte sind: globales Zusammenziehen mit c: 10, Rotation mit Winkel: 45°, ungleichmäßige perspektivische Verzerrung mit einer Verzerrung in horizontaler Richtung an der oberen linken Ecke um -0,184 und an der oberen rechten Ecke um 0,178.

4. Montage des Patterns in den ausgewählten Bildausschnitt
5. Zusammenführen von Objektkachel und Vorlage
6. Bewertung der erzeugten Objektkacheln

Die Auswahl der Patternvorlage, der Patterneffekte sowie deren Parameter erfolgen anhand von Konfigurationsprofilen. In diesen sind die folgenden Parameter spezifiziert:

- die auswählbaren Patternvorlagen
- Zielauflösung der zu erzeugenden Bilddateien
- Anzahl der auszuwählenden Masken beziehungsweise der zu montierenden Störstrukturen pro Bild
- Konfiguration der Erzeugung von Patternvorlagenmasken (siehe: Abs. 8.2.1)
- Konfiguration der Nachbearbeitung der erzeugten Objektkacheln (siehe: Abs. 8.2.1)



ABB. 8.4. Das Ergebnis der Anwendung der verschiedenen Mischmodi. Unter den Abbildungen ist jeweils der SSIM-Wert im Vergleich zum Originalbild (1.) vermerkt. Der Modus multiply (2.) verdunkelt das Bild. Der Modus screen (3.) hellt es auf. Der Modus Soft-Light (4.) erhält im Vergleich am besten die Helligkeit und den Kontrast des Ursprungsbildes. Die Abweichung zum Ausgangsbild bleibt jedoch signifikant.

- Konfiguration der Bewertung der Objektkacheln (siehe: Abs. 8.5)
- Konfiguration des Algorithmus zur Auswahl der anzuwendenden Patterneffekte (siehe: Abs. 8.3.1)
- die auswählbaren Patterneffekte sowie deren Auswahlwahrscheinlichkeit und das Spektrum der jeweiligen Parameter dieser Patterneffekte

Im Rahmen dieser Arbeit wurden fünf Konfigurationen erstellt. Je eine dieser Konfigurationen bildet eine der in Abs. 4 genannten Gruppen nach. Dazu kommen eine Konfiguration, welche die Stoffstruktur von Textilien nachbildet und eine Konfiguration die den sinnvollen Wertebereich aller Parameter ausschöpft und so möglichst zufällige Strukturen erzeugt. Pro ausgewählter Objektmaske werden zunächst eine Patternvorlage und eine Anzahl anzuwendender Patterneffekte sowie deren individuelle Parameter ausgewählt. Diese Auswahlen erfolgen jeweils zufällig unter Berücksichtigung der Vorgaben des gewählten Konfigurationsprofiles. Auf die zur Verfügung stehenden Patternvorlagen wird in Abs. 8.2.1 näher eingegangen. Die verfügbaren Patterneffekte sowie deren Parameter sind in Abs. 8.3 beschrieben. Der Algorithmus, der die Auswahl der anzuwendenden Patterneffekte auswählt, ist in Abs. 8.3.1 beschrieben. Das so erstellte Pattern wird in den ausgewählten Seitenbereich montiert, indem die entsprechenden Farbkanäle beider Bilder mit Hilfe des Soft-Light Mischmodus[42] zusammengeführt werden. Dieser Mischmodus basiert auf den Mischmodi Multiplizieren (multiply) und Negativ Multiplizieren (screen). Der Mischmodus Multiplizieren führt zwei Bildebenen unter Verwendung von (8.2) zusammen. Die Formeln (8.2), (8.3) und (8.4) gehen von einem Wertebereich von 0 bis 1 für das Ursprungsbild a und das überlagernde Bild b aus. Die Verwendung von (8.2) sorgt dafür, dass sich das Originalbild durch die Überlagerung abdunkelt (siehe: ABB. 8.4(2.))

$$(8.2) \quad f(a, b) = ab$$

Der Mischmodus Negativ Multiplizieren nutzt die Formel (8.3). Sie hat den gegenteiligen Effekt zu (8.2) und sorgt dafür, dass sich das Originalbild aufhellt (siehe: ABB. 8.4(3.)).

$$(8.3) \quad f(a, b) = 1 - (1 - a)(1 - b)$$

Der Mischmodus Soft-Light wendet eine Mischung der beiden genannten Mischmodi an. Das Mischverhältnis ergibt sich aus dem Tonwert des Pixels im Ursprungsbild. Die verwendete Formel (8.4) wurde aus [43] übernommen.

$$(8.4) \quad f(a, b) = (1 - a)ab + a(1 - (1 - a)(1 - b))$$

Dieser Mischmodus überlagert die beiden Abbildungen sanfter als die beiden zuvor genannten Modi und beeinträchtigt zudem weniger stark Helligkeit und Kontrast der erzeugten Objektkachel (siehe: ABB. 8.4(4.)).

Wie in ABB. 8.4 zu sehen, ist die Abweichung in Helligkeit und Kontrast zwischen Ursprungsbild und dem mit Überlagerung unter Verwendung des soft-light Mischmodus erzeugtem Bild zwar geringer als im Falle von multiply und screen aber nach wie vor deutlich sichtbar.

Um diese optische Abweichung auszugleichen und um zu verhindern, dass ein KI-Modell im Trainingsprozess die Helligkeit der erzeugten Kachel als signifikantes Merkmal erlernt, wird die Helligkeit des Bildes in einem zweiten Schritt angepasst.

Der dazu verwendete Algorithmus gleicht die Helligkeit von Original- und erzeugtem Bild dazu iterativ an. Auch hier wird für die unveränderte Objektkachel a und die erzeugte Objektkachel b ein Wertebereich von 0 bis 1 angenommen.

Für jede Iteration werden folgende Schritte durchgeführt:

1. Berechnung der Abweichung in der Helligkeit zwischen beiden Bildern
2. Anpassung der Tonwerte im erzeugten Bild anhand des errechneten Faktors

Für die Berechnung der Abweichung Δ_{ab} wird (8.5) verwendet. \bar{a} und \bar{b} sind hier jeweils der durchschnittliche Tonwert der unveränderten Objektkachel a und der Objektkachel b .

$$(8.5) \quad \Delta_{ab} = |\bar{a} - b|$$

Für die Berechnung der Abweichung ist nur der Bereich relevant, der sich im nicht maskierten Bereich der Objektmaske befindet. Liegt die Abweichung unterhalb eines definierten Schwellwertes, in dieser Arbeit 0.01, wird die Iteration beendet. Ebenso wird sie beendet, wenn eine bestimmte Anzahl von Wiederholungen ausgeführt wurden, in dieser Arbeit sind dies drei Wiederholungen.

Wird die Verarbeitung nicht abgebrochen, wird mit Hilfe von (8.6) der Faktor s_{ab} berechnet. Würde man alle Tonwerte in b mit diesem Faktor multiplizieren, erhielte man den gleichen durchschnittlichen Tonwert wie in a .

$$(8.6) \quad s_{ab} = -\frac{\bar{a} - \bar{b}}{\bar{a}}$$

Zur Anpassung der Helligkeit werden die Tonwerte der Objektkachel mit s_{ab} multipliziert. Um den Kontrast der Vorlage zu erhalten, wird nach der Anpassung der Wertebereich von b' wieder auf den Bereich 0 bis 1 gestreckt (8.7). Dieser Schritt macht die iterative Natur des Algorithmus notwendig, andernfalls wäre die reine Anpassung der Helligkeit im ersten Schritt vollzogen.

$$(8.7) \quad \begin{aligned} b' &= b \cdot s_{ab} \\ b' &= (b' - b'_{min}) \cdot b'_{max} \end{aligned}$$

Die so erzeugte Objektkachel wird als letzter Schritt in den entsprechenden Kanal der erzeugten Seite eingebaut. Dafür werden zwei Werte aus der Konfiguration verwendet: Die Überlagerungsintensität i des jeweiligen Kanals sowie das Überlagerungsgewicht w . Beide haben einen Wert zwischen 0 und 1. Sie steuern die Intensität der Überlagerung. Während i einzeln für jeden Kanal festgelegt werden

kann, gilt w für alle vier Kanäle gleichermaßen. Die Montage erfolgt anhand von (8.8) mit a als Ursprungsbild und b als Objektkachel.

$$(8.8) \quad a' = (1 - i \cdot w) \cdot a + i \cdot w \cdot b$$

Bei der Montage werden nur diejenigen Pixel aus der Objektkachel übernommen, die sich im Bereich der Objektmaske befinden. Die übrigen Pixel im Ursprungsbild bleiben unverändert.

8.2.1. Erstellung und Auswahl von Patternvorlagen

Neben dem ursprünglichen Bild kommt als zweite Komponente zur Erstellung künstlicher Moiréuster die zu montierende Rasterstruktur hinzu. Hierfür wurden eine Reihe von Bildern erzeugt, die im Rahmen dieser Arbeit als Patternvorlagen bezeichnet werden. Aus diesen Patternvorlagen wird für die Generierung von synthetischen Moirés jeweils zufällig eine ausgewählt.

Die Bilder haben jeweils eine Größe von 24000 x 24000 Pixeln und eine Auflösung von 2400 dpi, also entsprechend der Zielauflösung des Raster Image Prozessors (siehe: Abs. 3.3). Sie sind im Bitmapfarbmodus angelegt. Die Strukturen haben jeweils eine Frequenz von 150 lpi. Zudem sind die regelmäßigen Muster auf 0° Grad ausgerichtet, verlaufen also vertikal auf dem Bild. Anpassungen an Frequenz und Rotation der Muster werden erst in einem eventuellen zusätzlichen Schritt auf Basis der für dieses synthetische Moiré ausgewählten Patterneffekte durchgeführt, siehe dazu: Abs. 8.3.

Die folgenden Muster wurden als Grundform der Raster verwendet:

- Linien
- Kreise
- Karos

Für jedes dieser Muster wurden Varianten mit unterschiedlicher Flächendeckung erstellt. Die Varianten umfassen die Flächendeckungen zwischen 10% und 90% in 10%-Schritten.

Grundlage für diese Auswahl an Grundformen ist die Form der Expansion bei sich erhöhender Flächendeckung. Die Linie ist ein eindimensionales Muster. Sie expandiert bei ansteigender Flächendeckung gleichmäßig im 90° Winkel zu ihrer Ausrichtung. Der Kreis hingegen ist eine zweidimensionale Struktur. Im Unterschied zur Linie ist der Kreis bei geringer bis mittlerer Flächendeckung sowohl in vertikaler als auch in horizontaler Richtung nicht mit den benachbarten Elementen verbunden. Mit ansteigender Flächendeckung expandiert das Element gleichmäßig in jede Richtung, bis bei ca. 70% Flächendeckung in beiden Richtungen gleichzeitig der Punktschluss zu den vier benachbarten Elementen stattfindet.

Das Karo schließlich verhält sich vergleichbar zum Kreis, expandiert allerdings bei ansteigender Flächendeckung stärker in der vertikalen als in der horizontalen Richtung. Dadurch kommt es anders als beim Kreis zunächst bei ca. 37% Flächendeckung in der vertikalen und erst bei ca. 55% Flächendeckung in der horizontalen zum Punktschluss. Die Form der drei verwendeten Grundformen bei ansteigender Flächendeckung ist in ABB. 8.5 dargestellt.

Bildstrukturen, auf deren Basis im Rasterungsprozess natürliche Moirés entstehen, sind häufig nicht gleichmäßig, sondern haben eine ungleichmäßige Dicke und einen ungleichmäßigen Verlauf (siehe dazu: ABB. 8.7). Der Verlauf des Musters kann in einem folgenden Schritt durch eine geeignete Auswahl von Patterneffekten beeinflusst werden. Die ungleichmäßige Dicke der Muster wird durch zwei weitere Varianten der oben genannten Raster berücksichtigt.

Als Basis für diese Varianten dienen zufällig erstellte Graustufenbilder. Diese wurden unter Verwendung des Perlin-Noise-Algorithmus erstellt [46]. Im Vergleich zu anderen zufällig erstellten Bildstrukturen, wie Gaussian Noise [3](S.319f), erzeugt der Perlin-Noise Algorithmus harmonischere Zufalls-

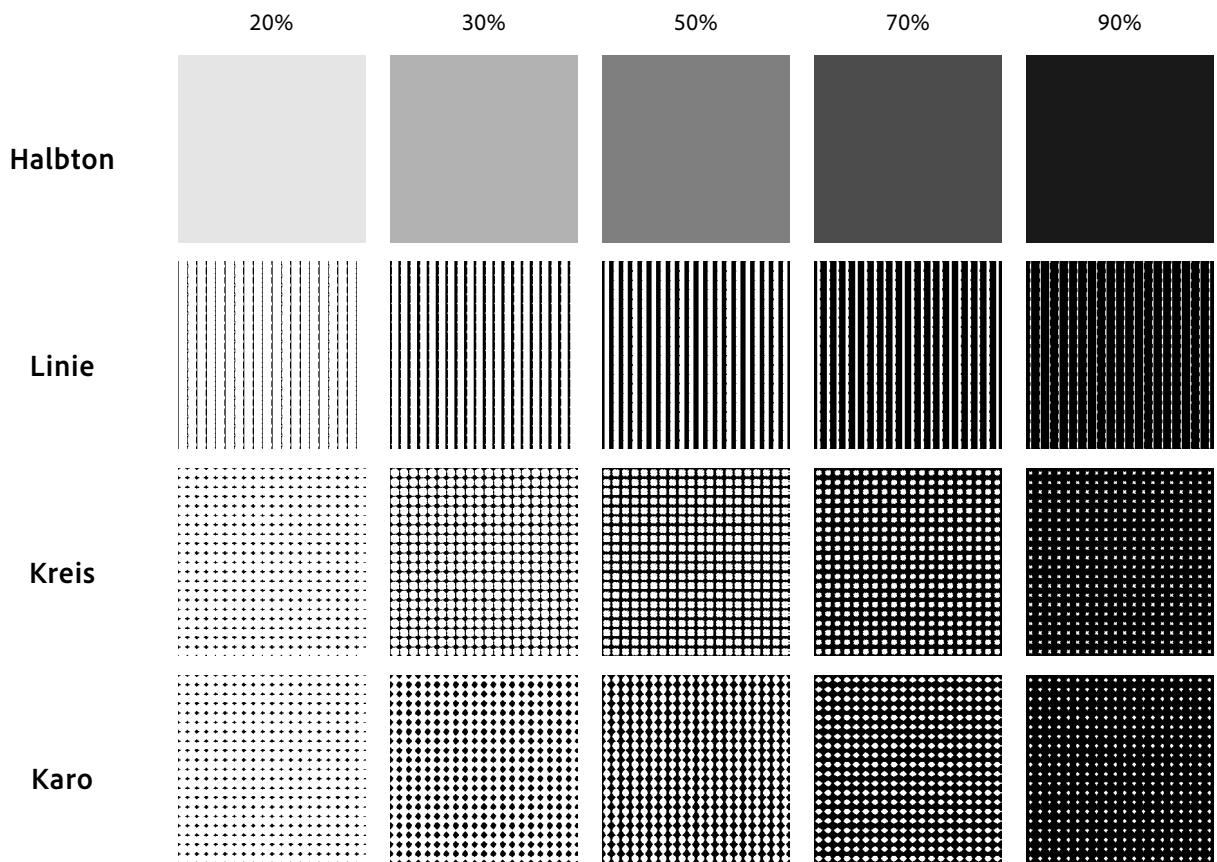


ABB. 8.5. Dargestellt sind Flächendeckungen zwischen 10% und 90% jeweils als Halbtonbild und als Rasterbild unter Verwendung der drei beschriebenen Grundformen Linie, Kreis und Karo.

strukturen mit größeren Flächen und weicheren Übergängen und ist damit besser zur Simulation natürlicher Schwankungen in der Dicke der Rasterstrukturen geeignet.

Als zusätzliche Variante wurde beim mit Perlin-Noise erstellten Zufallsmuster das Bild in horizontaler Richtung um den Faktor 10 gestreckt. Dies soll insbesondere die Dickeverläufe der Muster in Abbildungen von Textilien simulieren (siehe: ABB. 8.7).

Sowohl für die nicht gestreckte als auch für die gestreckte Variante der Perlin-Noise Bilder wurden Varianten in verschiedenen Kontraststufen erstellt. Diese reichen in Schritten von -0,1 von der vollen Ausnutzung des Tonwertumfangs bis zur Nutzung von 1/10 des maximalen Tonwertumfangs.

Für diese Halbtонabbildungen wurden wiederum nach den für die gleichmäßigen Flächendeckungen beschriebenen Methoden für jede der beschriebenen Grundformen Rasterabbildungen erstellt.

8.2.1.1. Technische Umsetzung der Erzeugung von Patternvorlagen

Für die Erzeugung der Patternvorlagen wurde ein Algorithmus implementiert, der sich an der Funktionsweise von Raster Image Prozessoren orientiert[10](S.238ff). Für jede der drei Rasterpunktformen wurde eine Schwellwertmatrix definiert. Dabei handelt es sich um eine Matrix der Größe 16x16. In dieser Matrix sind die Werte von 1 bis 256 verteilt. Zur Umsetzung eines Halbtонbildes in eine Bitmapabbildung wird mit einem Fenster über das Ursprungsbild iteriert. Die Seitenlänge des Fensters entspricht der Auflösung des Ursprungsbildes geteilt durch die Rasterweite, im Kontext dieser Arbeit 600 dpi / 150 lpi, woraus sich eine Seitenlänge des Fensters von vier Pixeln ergibt. Die Schrittgröße entspricht in x- und y-Richtung jeweils der Kantenlänge des Fensters. Aus jedem Fensterausschnitt ergibt sich ein Rasterpunkt im Zielbild mit einer Größe von 16x16 Pixeln (2400 dpi Bildauflösung / 150 lpi).

Zur Umsetzung eines Fensterausschnittes in einen Rasterpunkt wird der durchschnittliche 8-bit Grauwert des Fensterausschnittes errechnet. Entsprechend der Schwellwertmatrix werden alle Pixel in der Zielkachel ausgefüllt, für die der in der Schwellwertmatrix eingetragene Werte kleiner oder gleich dem 8-bit Grauwert ist. Die erstellten Schwellwertmatrizen für die drei Rasterpunktformen finden sich in ANHANG 2.

8.3. Anwendung von Patterneffekten

Im Abschnitt Abs. 4.2 wurden verschiedene Kategorien von Verformungen und daraus resultierende Moiréeffekte vorgestellt.

Um diese Kategorien in künstlich erzeugten Moirémustern darstellen zu können, wurden die folgenden Anpassungen implementiert.

- Rotation
- Skalieren und Verzerren
- perspektivische Verzerrung
- gleichmäßige perspektivische Verzerrung
- wellenförmige Verzerrung
- globales kreisförmiges Zusammenziehen und Expandieren
- mehrfaches regionales kreisförmiges Zusammenziehen und Expandieren

Die ersten vier dieser Effekte sind grundlegende Effekte, die jeweils einer der Kategorien in Abs. 4 entsprechen. Die letzten drei Effekte sind unterstützende Effekte, die primär dazu dienen, die generierten Bilder durch Anpassung näher an Störstrukturen in natürlichen Moirés anzunähern.

Jeder der Effekte kann über spezifische Parameter individualisiert werden. Die Effekte werden nachfolgend vorgestellt.

8.3.1.1. Rotation

Die ursprüngliche Patternvorlage wird um einen festgelegten Winkel gedreht. Als Parameter kann der gewünschte Winkel mitgegeben werden.

Wie in Abs. 4.2.1 beschrieben, entstehen Moirés einer Kategorie durch Überlagerung gleicher oder ähnlicher Raster in leicht unterschiedlicher Winkelung.

8.3.1.2. Skalieren und Verzerren

Die Patternvorlage wird neu skaliert. Im Falle der Variante Verzerren kann der Skalierungsfaktor in horizontaler und vertikaler Richtung jeweils einzeln als Parameter festgelegt werden. In der Variante Skalieren wird in beide Richtungen gleichmäßig verzerrt. Aufgrund des in Abs. 5.1.2.1 beschriebenen Sonderfalls wird die Skalierung als einzelner Effekt implementiert, um den Effekt angemessen im Datensatz zu repräsentieren. Auch die Überlagerung von zwei gleichen oder ähnlichen Mustern, die unterschiedlich skaliert sind, bilden eine Kategorie von Moirés, siehe dazu Abs. 4.2.2.

8.3.1.3. Gleichmäßige und ungleichmäßige perspektivische Verzerrung

Dieser Effekt bildet die in Abs. 4.2.3 beschriebenen Eigenschaften nach. Dafür wird eine Patternvorlage verzerrt, indem die Eckpunkte in vertikaler und horizontaler Richtung verschoben und der Bildinhalt entsprechend transformiert wird.

Die implementierte Umsetzung dieses Effektes kann pro Ecke mit zwei Parametern angepasst werden.

- Verzerrung in horizontaler Richtung
- Verzerrung in vertikaler Richtung

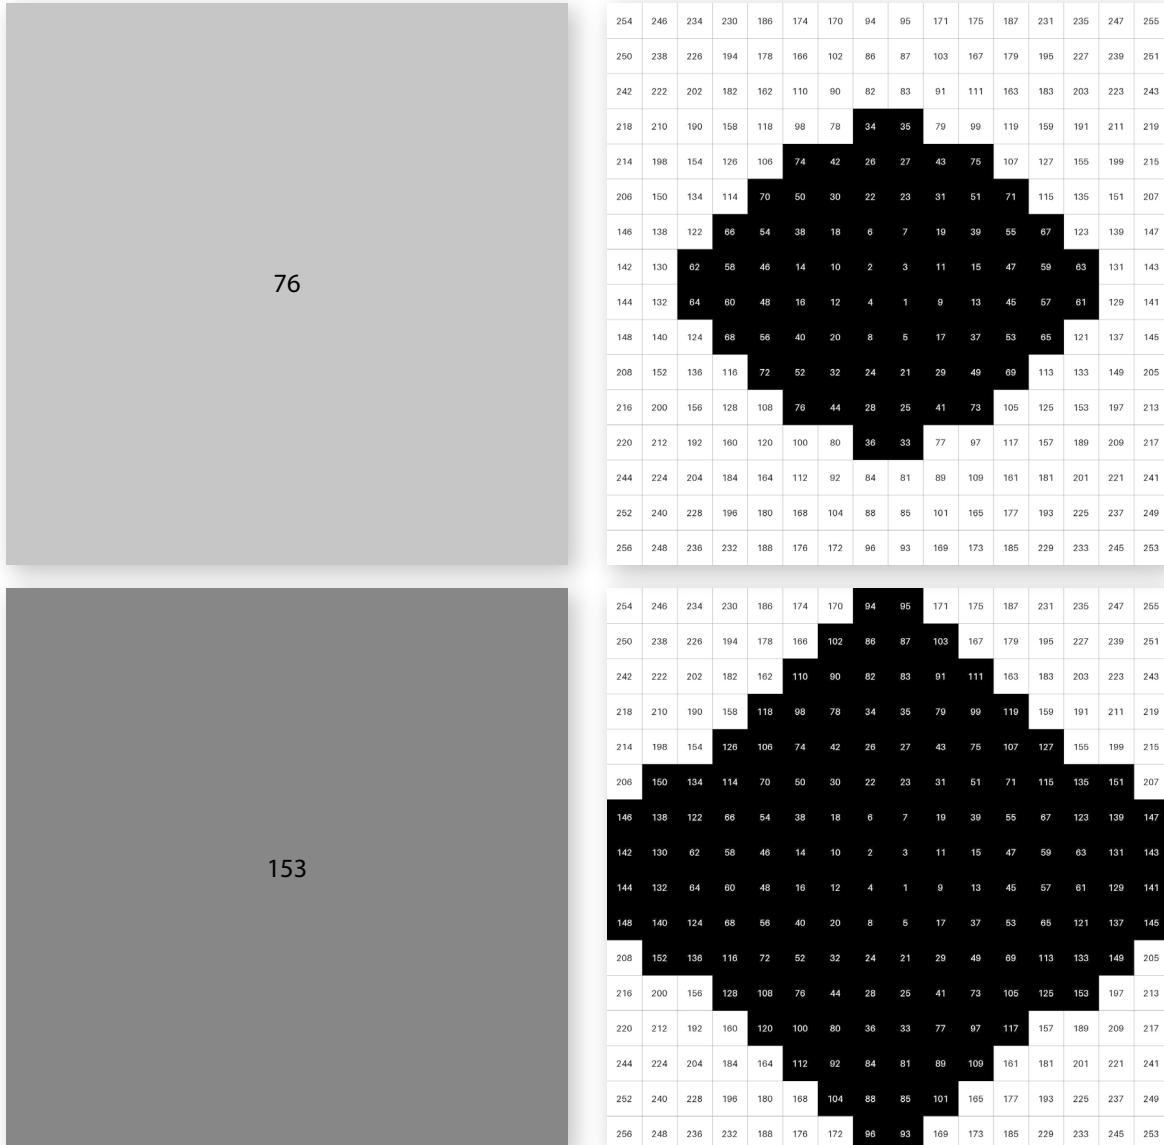


ABB. 8.6. Beispiele für die Umsetzung eines Halbtontonfarbwertes in einen Rasterpunkt. Links jeweils der Halbtongraustufenwert, rechts die zugehörige Schwellwertmatrix. Die entsprechend dem Grauwert einzufärbenden Pixel sind markiert. Exemplarisch wird die Schwellwertmatrix der Karoform dargestellt.

Die Parameter können Werte zwischen -1 und 1 annehmen. Der Wert 1 entspricht einer Verzerrung um 50% der Länge der angrenzenden Kante. Ist der Faktor größer als null, wird das Muster nach außen verzerrt, ist dieser kleiner als null, nach innen. In der gleichmäßigen Variante des Effektes können nur ein Faktor sowie die anzupassende Kante als Parameter übergeben werden. Der Faktor wird gleichermaßen auf beide an die übergebene Kante angrenzenden Eckpunkte angewandt.

8.3.1.4. Kreisförmiges Zusammenziehen und Expandieren

Die Effekte kreisförmiges Zusammenziehen und kreisförmiges Expandieren sind unterstützende Effekte. Sie sollen die in Abs. 4.2.4 beschriebenen Eigenschaften von Störstrukturen nachbilden. Der nachfolgend beschriebene Algorithmus orientiert sich an der Umsetzung in [47].

Der Effekt ist algorithmisch folgendermaßen umgesetzt: In der Patternvorlage wird ein Bereich definiert, auf dem die Anpassung durchgeführt werden soll. Bei den globalen Varianten des Effektes wird die komplette Patternvorlage als Bereich definiert. Bei den regionalen Varianten jeweils nur Teile der

Patternvorlage. Über die Pixel des ausgewählten Bereiches wird iteriert. Für jeden Pixel wird die Polarkoordinate mit dem Mittelpunkt des ausgewählten Bereiches als Mittelpunkt errechnet. Der Inhalt des Pixels des Ursprungsbildes wird anhand einer Formel entlang des errechneten Radius auf dem selben Winkel an anderer Stelle in das Zielbild übernommen.

Die Berechnung des Radius des Pixels im Zielbild $f(r)$ wird anhand von (8.9) auf Basis des ursprünglichen Radius des Pixels r berechnet.

$$p = \frac{r}{r_{\max}}$$

$$(8.9) \quad d = \begin{cases} 1, & \text{expandieren} \\ -1, & \text{zusammenziehen} \end{cases}$$

$$f(r) = (p \cdot r + (1 - p) \cdot c \cdot \sqrt{r}) \cdot d$$



ABB. 8.7. Die Abbildung zeigt ein Beispiel für Strukturen in Textilien. Die Struktur ist regelmäßig, weiß jedoch, im Vergleich zu einem digital erzeugten Raster, leichte Unregelmäßigkeiten auf.

Der Interpolationsfaktor p entspricht der relativen Entfernung zum Mittelpunkt in Relation zum maximal möglichen Radius r_{\max} . Der Richtungsfaktor d steuert, ob der Effekt das eingegebene Bild expandieren oder zusammenziehen soll. Der konstante Faktor c steuert die Stärke des Effektes. ABB. 8.8 zeigt beispielhaft die errechneten Verschiebungen für den Radien 0 - 1000. Ausschlaggebend für das Design der Formel ist, dass sowohl für den niedrigsten als auch den höchsten Wert der Radiusspanne eine Verschiebung von 0 erreicht wird. Zudem soll die Verschiebung nicht linear steigen und die Kurve eine abgerundete Form haben, um für weiche Übergänge im erzeugten Bild zu sorgen. Als Parameter wird ein Wert für den Faktor c eingegeben. Im Falle der mehrfachen regionalen Anwendung des Effektes wird zusätzlich ein Array von Tuples übergeben, wobei jedes den Mittelpunkt und den maximalen Radius eines zu verzerrenden Teilbereiches der Patternvorlage enthält. ABB. 8.9(4.) zeigt ein Beispiel für die Anwendung des Effektes.

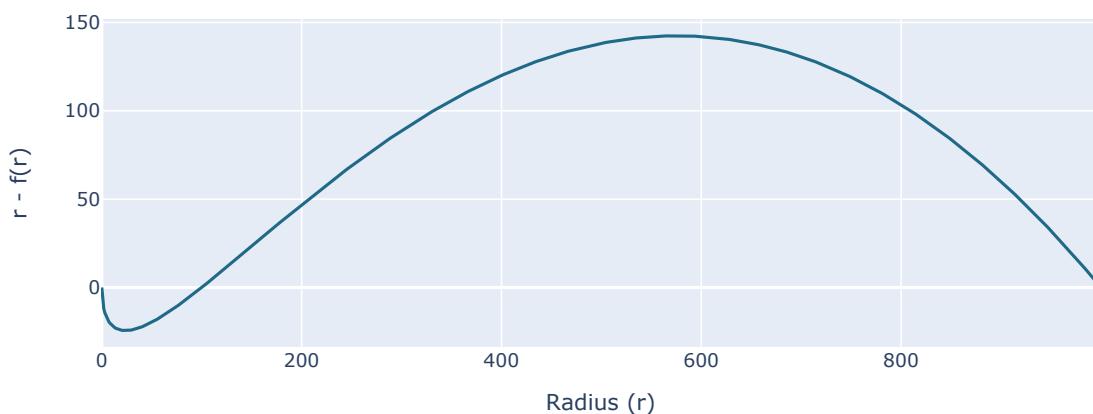


ABB. 8.8. Anwendung von (8.9) auf den Wertebereich 1 - 1000 für r . Auf der y-Achse ist der Wert für $r - f(r)$ dargestellt. Dies entspricht der relativen Verschiebung des Pixels auf dem entsprechenden Winkel. Es gilt zudem $c = 10$.

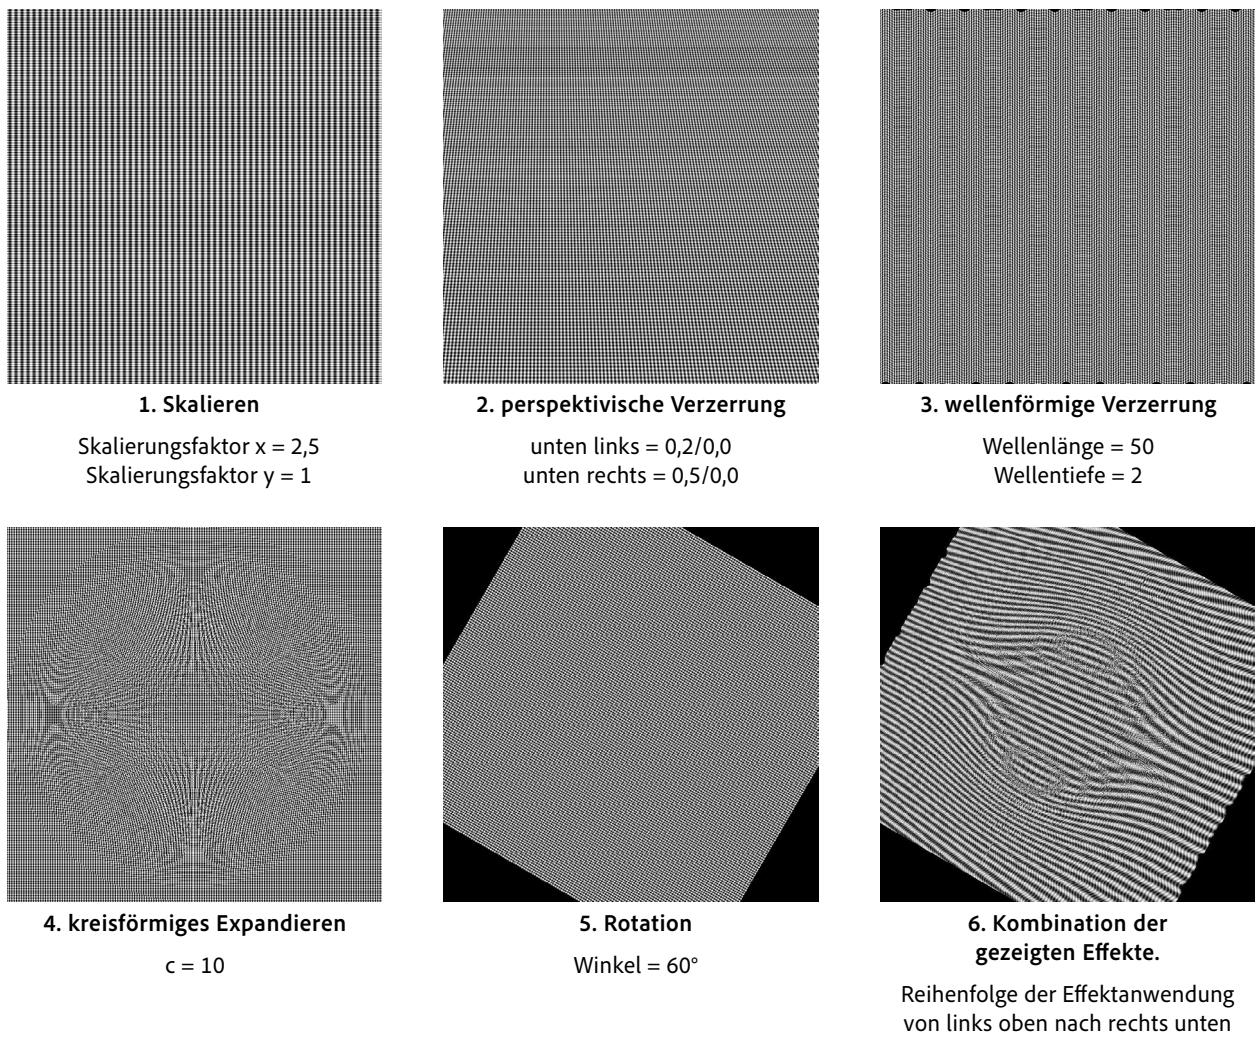


ABB. 8.9. Beispiele der implementierten Patterneffekte sowie deren Parametrisierung. 6. zeigt ein Pattern unter Anwendung der übrigen dargestellten Beispiele. Die Reihenfolge der Anwendung der Effekte entspricht der Nummerierung der Beispiele in aufsteigender Reihenfolge.

8.3.1.5. Wellenförmige Verzerrung

Die wellenförmige Verzerrung ist ebenfalls ein unterstützender Effekt. Sie fügt der eingegebenen Patternvorlage ein oder mehrere sich überlagernde sinusförmige Verzerrungen hinzu. Die Idee hinter diesem Effekt ist, dass periodische Muster in natürlichen Moirs häufig nicht perfekt gerade, sondern leicht unregelmäßig verlaufen (siehe: ABB. 8.7). Als Eingabeparameter wird ein Array von Tuples übergeben. Jedes Tuple besteht aus einer Information über eine gewünschte Wellenlänge und maximale Wellentiefe. Die Wellenlänge legt den Abschnitt fest, der von einem Intervall der Welle eingenommen wird. Die maximale Wellentiefe legt den höchsten und tiefsten y-Wert fest, denn die Funktion annnehmen darf. Der niedrigste Wert entspricht dabei der maximalen Wellentiefe multipliziert mit -1. Die errechneten y-Werte der einzelnen übergebenen Tuples werden miteinander multipliziert.

8.3.1. Algorithmus zur Auswahl der anzuwendenden Patterneffekte

Nicht nur die Auswahl und Ausprägung der anzuwendenden Effekte soll pro erstelltem synthetischen Moiré schwanken. Auch die Anzahl der angewandten Effekte soll in einem gewissen Wertebereich zufällig ausgewählt werden. Gleichzeitig soll über die Konfigurationsprofile der Effekte auch gesteuert

werden, welche Effekte mit welcher Wahrscheinlichkeit angewandt werden.

Der Algorithmus zur Auswahl der anzuwendenden Patterneffekte wurde wie folgt gestaltet: In der Konfiguration ist für jeden Effekt ein Gewicht zwischen 0 und 1 hinterlegt. Effekte mit dem Gewicht 1 sind in jedem Fall in der Auswahl enthalten. Effekte mit der Wahrscheinlichkeit 0 sind in keinem Fall enthalten. Für alle übrigen Effekte werden rekursiv die folgenden Schritte ausgeführt:

1. Ein Liste der übrigen anwendbaren Effekte wird erstellt. Dafür werden aus der Liste aller verfügbaren Effekte diejenigen entfernt, die ein Gewicht von 0 haben oder die sich bereits in der Liste der verwendeten Effekte befinden.
2. Diejenigen ausgewählten Effekte, deren Gewicht 1 ist, werden in die Liste der verwendeten Effekte eingefügt
3. Ist die Liste der verfügbaren Effekte leer, wird die Liste der verwendeten Effekte zurückgegeben und die Rekursion beendet.
4. Andernfalls wird mit Hilfe von (8.10) ein zufälliger Wert zwischen 0 und 1 ausgewählt.
5. Ist dieser Wert kleiner als die Anzahl der bereits ausgewählten Patterneffekte geteilt durch die Anzahl der insgesamt verfügbaren Patterneffekte, wird ein weiterer Effekt ausgewählt und die Rekursion fortgesetzt.
6. Andernfalls wird die Rekursion beendet und die ausgewählten Patterneffekte zurückgegeben.

(8.10) ist eine angepasste Form der Normalverteilung. Abweichend zur Originalformel aus [44] entfällt der Wert μ , da die Verteilung um den mittleren Wert 0 zentriert sein soll. Von dem so errechneten Wert wird der absolute Wert genutzt $p_{\text{norm}}(x)$. Ist dieser größer als 1, wird stattdessen 1 verwendet. So wird der Wert für die zufällig erzeugte Zahl $p(x)$ auf den Wertebereich 0 bis 1 eingeschränkt. Als Parameter wird der Wert σ in den Algorithmus eingegeben. Dieser steuert die Zielstandardabweichung der Zufallswerte und damit mittelbar, wie sich die Häufigkeit der Anzahl der ausgewählten Effekte verteilt (siehe dazu: ABB. 8.10).

$$p_{\text{norm}}(x) = \left| \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{x^2}{2\sigma^2}} \right|$$

(8.10)

$$p(x) = \begin{cases} p_{\text{norm}}(x) & p_{\text{norm}}(x) < 1 \\ 1 & \text{andernfalls} \end{cases}$$

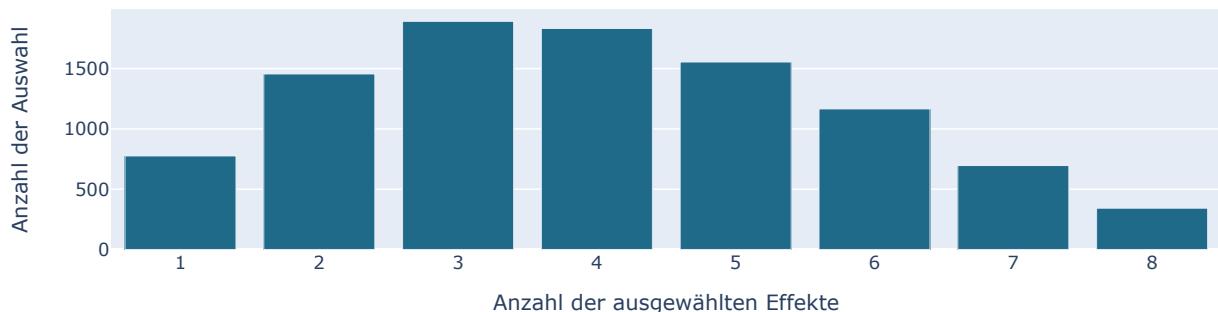


ABB. 8.10. Der beschriebene Algorithmus wurde 10.000 mal ausgeführt. Als σ wurde exemplarisch 1 verwendet. Dargestellt ist, wie häufig in diesen 10.000 Ausführungen welche Anzahl an Patterneffekten ausgewählt wurde.

8.4. Umwandlung Rasterabbildung

Um Moiréeffekt zu erzeugen, die aus der Überlagerung von Druckraster und künstlich montierter Störstruktur entstehenden, werden die erzeugten Seiten in Rasterabbildungen konvertiert. Die Konvertierung verläuft analog zum in Abs. 7.1 beschriebenen Verfahren für die Originalseiten.

8.5. Auszeichnung der erzeugten Objektkacheln

Die Entstehung von Moirémustern ist stark abhängig von Bildaufbau und Motiv. Zudem können, wie in Abs. 2 beschrieben, auch sehr kleine Unterschiede in den Eigenschaften der beteiligten Strukturen die Eigenschaften der entstehenden Moiréstrukturen beeinflussen. Daher ist es notwendig, die erzeugten Objektkacheln im Nachgang zu prüfen und in die Kategorien *Moiré* und *kein Moiré* einzuteilen.

Je nach Sujet der ausgewählten Objektmaske kann der Effekt der montierten Störstruktur deutlicher oder weniger deutlich erkennbar sein. Sind die Tonwerte der Objektmaske beispielsweise im Durchschnitt sehr niedrig oder sehr hoch, ist die montierte Störstruktur optisch nur schlecht erkennbar. Um die manuelle Auszeichnung zu erleichtern, werden daher Objektkacheln, bei denen nur eine sehr geringe optische Veränderung zwischen Originalbild künstlich erzeugtem Bild erreicht werden konnte, entfernt. Dafür wird für jedes Paar aus Objektkachel in der Originalseite und Objektkachel in der erzeugten Seite die structural similarity (SSIM)[45] berechnet. Liegt dieser für eine Objektkachel bei 0,95 oder höher wird die Maske automatisch in die Kategorie *kein Moiré* eingesortiert. Die übrigen Masken werden manuell ausgezeichnet. Der Schwellwert von 0,95 wurde manuell ausgewählt. Exemplarisch wurden 100 zufällige Objektkacheln mit einem SSIM-Wert oberhalb von 0,95 manuell ausgezeichnet. Keine dieser manuell geprüften Objektkacheln enthielten Moirés.

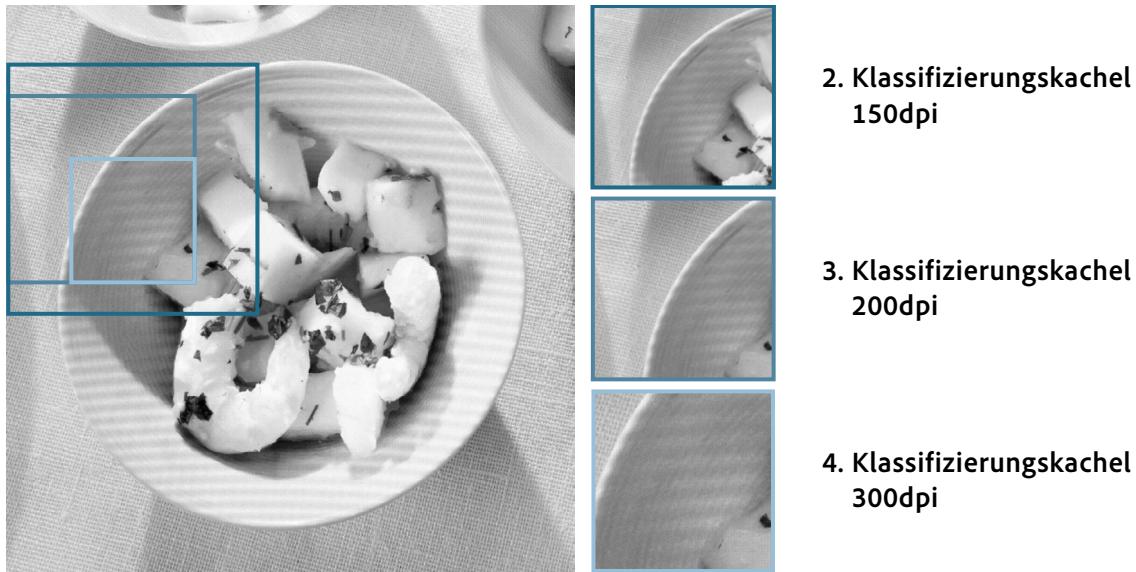
9. Erstellung eines Klassifizierungsdatensatzes

Abs. 7 beschreibt, welche realen Daten gesammelt wurden. In Abs. 8 wird darauf eingegangen, wie auf diesen Daten eine Anzahl von synthetischen Moirés erzeugt wurde. Nachfolgend soll dargelegt werden, wie auf Basis dieser synthetischen und natürlichen Moirés ein Trainingsdatensatz zum Training eines Deep-Learning Modells erstellt wurde.

9.1. Erstellung von Klassifizierungskacheln auf Basis erzeugter synthetischer Moirés

Die zu verarbeitende Objektkachel wird in Ausschnitte gleicher Größe aufgeteilt. Diese Ausschnitte werden nachfolgend in Abgrenzung zu den in Abs. 8 beschriebenen Objektkacheln als Klassifizierungskacheln bezeichnet. Zur Erstellung der Klassifizierungskacheln wird mit einer festen Fenstergröße, ausgehend von der oberen linken Ecke, von links nach rechts und von oben nach unten über die Objektkachel gewandert. Das Fenster wird dabei in horizontaler beziehungsweise vertikaler Richtung um jeweils die Kachelgröße vorgeschoben. Für die vorliegende Arbeit wurde entschieden, die Trainingsdaten in Klassifizierungskacheln fixer Größe zu teilen anstatt beispielsweise die Objektkacheln auf ein fixes Format zu skalieren. Das optische Erscheinungsbild von Moiréeffekten hängt stark von den Eigenschaften der dem Effekt zugrunde liegenden periodischen Struktur ab. Würde eine Objektkachel mit einer Moiréstruktur beispielsweise skaliert oder verzerrt, um ihre Pixelgröße der als Eingabe in ein Klassifizierungsmodell benötigten Pixelgröße anzupassen, so würde auch die geometrische Form sowie die Frequenz und Winkelung der Moiréstruktur beeinträchtigt. Als Kachelgröße wurde 224x224 Pixel gewählt, da dies eine weit verbreitete Eingabegröße für Deep-Learning Modelle zur Bildverarbeitung ist. Insbesondere verwenden sowohl die ResNet- als auch die MobileNet-Architektur dieses Größe für Eingabedateien (siehe: Abs. 10.2). Jede Seite beziehungsweise jede Objektkachel wird drei Mal in Klassifizierungskacheln umgewandelt. Dabei wird das Bild jeweils auf eine neue Auflösung skaliert und danach erneut mit dem beschriebenen Fenster in Kacheln geteilt. Die Kachelgröße in Pixeln dieses Fensters bleibt bei jedem der Durchgänge identisch. Durch diese Verarbeitung entstehen mehrere Kacheln, die denselben Bildausschnitt in unterschiedlichen Vergrößerungsstufen abbilden. Als Auflösungen wurden 300 dpi, 200 dpi und 150 dpi gewählt. Wie in ABB. 2.1(2. - 4.) zu sehen, haben Moirés teilweise die Eigenschaft, in einer verkleinerten Ansicht deutlich erkennbar zu sein, während sie in größeren Ansicht kaum mehr wahrnehmbar sind. Um diesem Effekt entgegenzuwirken werden Kacheln in der kleineren Vergrößerungsstufe 150 dpi erzeugt. Wie in ABB. 2.1(2.) zu sehen, ist der abgebildete Bildausschnitt in dieser Auflösung sehr groß. Dadurch besteht die Gefahr, Moirés in kleineren Elementen der Seite nicht zu erkennen, da sie durch den großen Bildausschnitt in der 150 dpi Auflösung nicht mehr sichtbar sind oder nur einen kleinen Anteil der Klassifizierungskachel ausmachen. Daher wird zusätzlich die im Vergleich hohe Auflösung von 300 dpi verarbeitet, um diese Details abbilden zu können. Zudem wird bei einer Rasterweite von 150 lpi, dem Nyquist-Shannon-Theorem folgend (siehe: Abs. 2.2), idealerweise eine Auflösung von 300 dpi für Bilder die in Druckdaten verwendet. Damit kann angenommen werden, dass 300 dpi in vielen Fällen der ursprünglichen Auflösung der verarbeitenden Seite entspricht. Zusätzlich zu 150 dpi und 300 dpi wird 200 dpi als mittlere Auflösung verwendet.

Für die Klassifizierungskacheln wird ausschließlich der Schwarzkanal der Rasterabbildung übernommen. Die Buntfarbenkanäle Cyan, Magenta und Gelb werden verworfen. Die Gründe dafür werden in Abs. 8 dargelegt. Da sowohl die ResNet- als auch die MobileNet-Architektur ein RGB-Bild als Eingabe erwarten wurden die so erzeugten Graustufenbilder in den RGB-Farbmodus konvertiert.



1. Objektkachel im Schwarzkanal mit Moiré

2. Klassifizierungskachel
150dpi

3. Klassifizierungskachel
200dpi

4. Klassifizierungskachel
300dpi

ABB. 9.1. Beispiel für die Extraktion von Klassifizierungskacheln aus einer Objektkachel. 1. zeigt die gesamte Objektkachel, 2. - 4. die jeweils extrahierten Ausschnitte der selben Position bei 150, 200 und 300 dpi.

9.2. Umfang, Zusammenstellung und definierte Klassen des Klassifizierungsdatensatzes

Der erzeugte Datensatz wird in die Klassen *moiré* und *kein moiré* aufgeteilt. Unter Verwendung des in Abs. 8 beschriebenen Modells wurden 1034 Seiten mit insgesamt 9493 Objektkacheln erzeugt. Nach manueller Auszeichnung wurde so ein Datensatz von 1917 synthetisch erzeugten Moirés zusammengestellt. Aus diesen Moirés wurden entsprechend der Beschreibung in Abs. 9.1 191156 Klassifizierungskacheln erzeugt. Dafür wurde, wie oben beschrieben, mit einem Fenster der Größe 224x224 Pixel über die Objektkachel gewandert. Gehören mindestens 25% des aktuellen Fensterausschnittes zum nicht maskierten Bereich der Objektkachel, wird diese für das Training des Modells übernommen. Andernfalls wird sie verworfen. Für jede der so erzeugten Beispiele wurde der selbe Bildausschnitt aus der moiréfreien Originalseite extrahiert und ebenfalls für das Training des Modells übernommen. So entsteht ein Paar von zwei Klassifizierungskacheln, die jeweils den selben Ausschnitt einer Seite zeigen. Eine dieser Kacheln enthält eine unerwünschte Moiréstruktur, die andere ist moiréfrei. Beispiele für die erzeugten Kacheln sind in ABB. 9.2 zu sehen. Durch das Bilden dieser Paare soll erreicht werden, dass beim Trainieren eines Modells nicht die abgebildeten Objekte sondern die erzeugte Störstruktur erlernt wird. Wie im vorherigen Abschnitt beschrieben, können Moiréeffekte in bestimmten Auflösungen optisch nur schwer erkennbar sein. Zudem treten beim Aufteilen der Seite in Klassifizierungskacheln teilweise Ungenauigkeiten auf. Aus diesen Gründen werden so auch Klassifizierungskacheln erzeugt, die der Klasse *moiré* zugeordnet werden, jedoch keine optisch erkennbaren Moiréstrukturen enthalten. Diese Kacheln sollen aus den Datensätzen entfernt werden, um die Genauigkeit des Trainingsdatensatzes und die Aussagekraft des Test- und Validierungsdatensatzes zu verbessern. Auf die dazu verwendete Methodik wird in Abs. 9.3 eingegangen.

Eine Druckseite enthält in der Regel viele Objekte, in denen nur mit sehr geringer Wahrscheinlichkeit Moirés auftreten. Dazu gehören Textabschnitte, einfarbige Flächen oder technische Marken. Da diese Objekte, aufgrund ihrer Eigenschaften sowie der in Abs. 8.1 beschriebenen Filterung, nicht oder nur in sehr geringem Umfang in dem zuvor beschriebenen Datensatz vorkommen, wurde für jedes

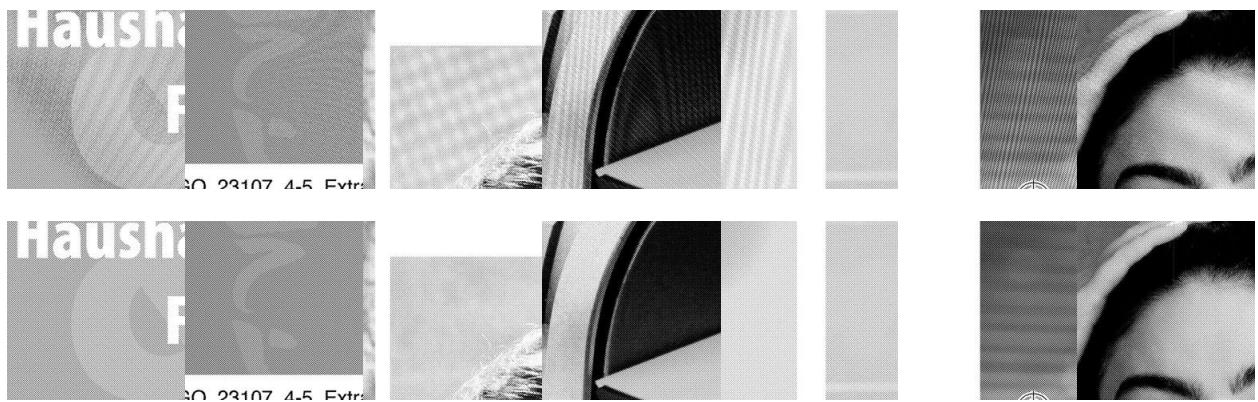


ABB. 9.2. Eine Anzahl von Beispielen für Paare von Klassifizierungskacheln. Oben jeweils die Kachel mit Moiré unten ohne Moiré.

der beschriebenen Paare eine weitere moiréfreie Klassifizierungskachel dem Datensatz hinzufügt. Diese Ausschnitte wurden zufällig aus den vorhandenen Seiten ausgewählt. Dadurch ergibt sich ein Verhältnis der Anzahl der Klassifizierungskacheln der einzelnen Klassen von 1 zu 2. Die so erzeugten Klassifizierungskacheln werden entsprechend TABELLE 9.1 auf die unterschiedlichen Datensätze aufgeteilt. Die prozentuale Verteilung ist für jede der Klassen separat gültig. Es finden sich also beispielsweise jeweils 10% aller Klassifizierungskacheln der Klasse *moiré* und 10% aller Klassifizierungskacheln der Klasse *kein moiré* im Validierungsdatensatz.

Bei der Aufteilung der Klassifizierungskacheln auf die verschiedenen Datensätze wurde sicher gestellt, dass alle Klassifizierungskacheln, die aus der selben Objektkachel erzeugt wurden, jeweils gemeinsam einem Datensatz zugeordnet werden. Da sich die abgebildeten Ausschnitte wie oben beschrieben zwischen mehreren Klassifizierungskacheln überschneiden, besteht bei einer rein zufälligen Verteilung der Klassifizierungskacheln auf die Datensätze die Gefahr, dass abgebildete Objekte anstatt der beinhalteten Moiréstrukturen erlernt werden.

Zusätzlich wird ein vierter Datensatz erzeugt. Für diesen werden aus den, wie in Abs. 7 beschrieben, ausgezeichneten realen Moirés ebenfalls entsprechend der in Abs. 9.1 beschriebenen Methode Klassifizierungskacheln erstellt. Dieser Datensatz wird als *realer Testdatensatz* bezeichnet. Pro Klassifizierungskachel, die auf einem natürlichen Moiré basiert, wird aus dem moiréfreien Bereich der selben Seite zufällig eine weitere Klassifizierungskachel erzeugt. Dadurch enthält der reale Validierungsdatensatz die gleiche Anzahl von Kacheln der Klasse *moiré* und *kein moiré*. Da anders als bei den synthetischen Moirés bei den natürlichen Moirés keine moiréfreie Kachel des selben Bildausschnitts zur Verfügung steht, kann der Datensatz nicht mit dem in Abs. 9.3 beschriebenen Vorgehen bereinigt werden. Daher wurde dieser Datensatz manuell bereinigt.

Datensatz	Anteil	Anzahl Klassifizierungskacheln
Trainingsdatensatz	70%	129.990
Testdatensatz	20%	40.491
Validierungsdatensatz	10%	14.437
realer Testdatensatz	-	6.238

TABELLE 9.1. Übersicht über die erstellten Datensätze und ihren jeweiligen Umfang.

9.3. Entfernung von Kacheln mit optisch nicht ausreichend erkennbarer Moiréstruktur

Zur automatischen Erkennung und Entfernung von Kacheln ohne optisch sichtbare Moiréstrukturen wird eine Kombination von zwei Werten verwendet. Für jedes der beschriebenen Paare von Kacheln (siehe: ABB. 9.2) werden die folgenden Werte berechnet:

- Der SSIM-Wert für das Kachelpaar[45]
- Der Frequency Gain für das Kachelpaar

Der Frequency Gain ist eine Metrik, die in [48] etabliert wird, um zu prüfen, ob erfolgreich ein Moiré aus einer Kachel entfernt werden konnte. Im Rahmen der vorliegenden Arbeit wird die Metrik für den entgegengesetzten Zweck eingesetzt. Hier wird geprüft, ob eine Klassifizierungskachel im Vergleich zur moiréfreien Klassifizierungskachel ein moiré enthält. Da die Klassifizierungskacheln bereits de facto im Graustufenmodus vorliegen, werden sie, abweichend zu dem Ansatz aus [48], nicht in den Lab sondern in den Graustufenmodus konvertiert. I bezeichnet die moiréfreie Klassifizierungskachel, O die Klassifizierungskachel mit Moiré. $\mathcal{F}_I(\omega)$ und $\mathcal{F}_O(\omega)$ bezeichnen jeweils die 2D-Fouriertransformation von O und I mit ω als Frequenz. Die Berechnung des Frequency Gains geschieht anhand von (9.1).

$$(9.1) \quad p(\omega) = \begin{cases} \log\left(\frac{|\mathcal{F}_I(\omega)|^2 + \eta}{|\mathcal{F}_O(\omega)|^2 + \eta}\right), & |\omega| \leq r \\ 1, & \text{andernfalls} \end{cases}$$

Zur Berechnung des Frequency-Gains werden nur Frequenzen ω unterhalb eines Schwellwertes r genutzt. Für diese Arbeit wird $r = 0,625$ verwendet. η dient als Zusatzwert, um eine Division durch null zu vermeiden. Hier wird $\eta = 0,00001$ verwendet. Die so erzeugte Matrix des Frequency Gains wird mit Hilfe eines Gaußschen Kernels[3](S. 883) mit $\sigma = 3$ weichgezeichnet. Als Frequency Gain wird schließlich der höchste Wert dieser Matrix verwendet.

Weder der SSIM-Wert noch der Frequency Gain stellen alleine eine ausreichende Metrik zur Auswahl der zum Training ungeeigneten Klassifizierungskacheln dar. Aus diesem Grund wird für diese Aufgabe eine Klassifizierungsmodell auf Basis des Support Vector Machine-Algorithmus[49](Abs. 7.1.3) trainiert. Dieses Modell erhält den SSIM-Wert und den Frequency-Gain eines Paares von Klassifizierungskacheln als Eingabe. Das Modell wurde anhand eines Datensatzes von 500 Paaren von Klassifizierungskacheln trainiert, die manuell den Klassen *enthält sichtbares Moiré* und *enthält kein sichtbares Moiré* zugeordnet wurden. Dieser Datensatz wurde im Verhältnis 2/3 zu 1/3 in einen Trainings- und einen Testdatensatz geteilt. Das trainierte Modell erreicht eine Accuracy von 78,2% auf dem Trainings- und 87,2% auf dem Testdatenset. Die Paare von Klassifizierungskacheln, welche dieses Modell als *enthält sichtbares Moiré* klassifiziert, werden aus dem Datenset entfernt.

9.4. Frequenzbasierter Datensatz

In Abs. 4.2 wird beschrieben, dass die untersuchten geometrischen Kategorien jeweils in ihrer Darstellung in der Frequenzdomäne ein charakteristisches Erscheinungsbild aufweisen. Aus diesem Grund soll untersucht werden, ob ein Modell anhand der Frequenzdomäne in der Lage ist, Klassifizierungskacheln korrekt zu klassifizieren. Zur Prüfung dieser Hypothese wird für jeden der zuvor beschriebenen Datensätze eine Repräsentation in der Frequenzdomäne angelegt. Dafür wird jede verwendete Klassifizierungskachel entsprechend (9.2) transformiert:

$$(9.2) \quad f(\omega) = g\left(\begin{cases} |\mathcal{F}(\omega)|, & \omega \leq r, \\ 1, & \text{andernfalls} \end{cases}\right), \sigma$$

$$f_{\text{norm}}(\omega) = \frac{f(\omega)}{\max(f(\omega))}$$

Das Originalbild wird mit Hilfe einer 2D-Fouriertransformation $\mathcal{F}(\omega)$ in die Frequenzdomäne umgewandelt. Sehr niedrige Frequenzen werden ignoriert, da insbesondere der DC-Impuls (siehe: Abs. 2.1) üblicherweise eine sehr viel höhere Intensität aufweist als die übrigen Frequenzanteile und somit für die Moiréentstehung relevante Frequenzanteile potenziell überlagern kann. Als Schwellwert wird

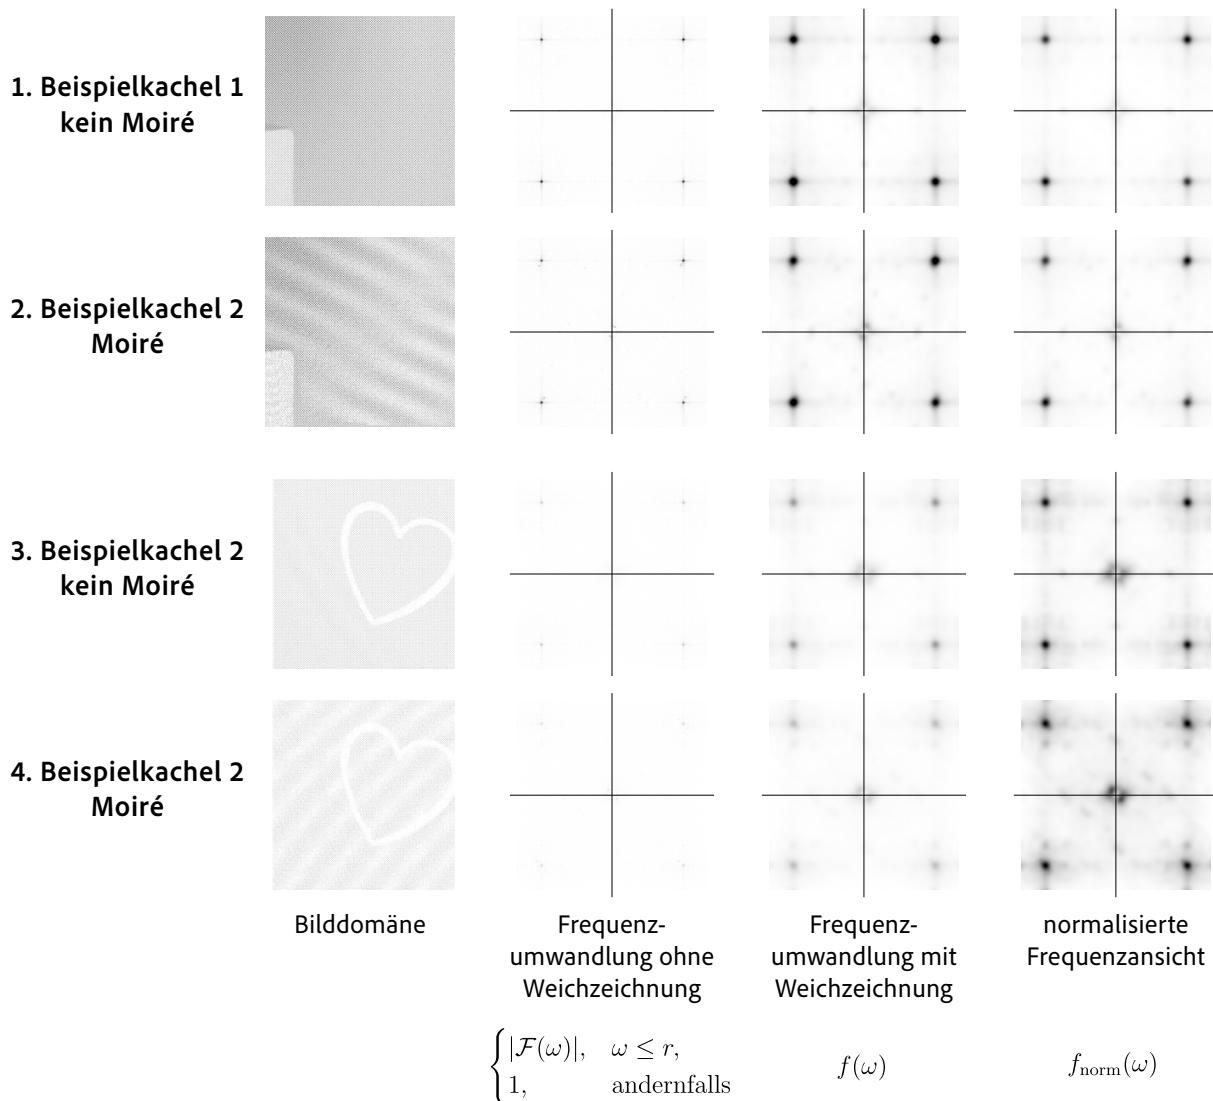


ABB. 9.3. Gezeigt werden zwei verschiedene Paare von Klassifizierungskacheln. Pro Zeile zeigen die Grafiken (von links nach rechts) die Kachel in der Bilddomäne, den absoluten Wert der 2D-Fouriertransformation (Wertebereich jeweils 0 - 400.000), denselben Wert mit angewandtem gaußschem Weichzeichner (Wertebereich 0 - 40.000) und die normalisierte Frequenzansicht (Wertebereich 0 - 1). Die gut sichtbaren Impulspaare auf 45° und -45° entstammen der Rasterstruktur, die durch die Umwandlung in eine Rasterabbildung entstanden sind.

$r = 0,045$ verwendet. Der absolute Wert des Ergebnisses wird mit Hilfe eines Gaußschen Kernels mit $\sigma = 3$ weichgezeichnet. Mit diesem Schritt sollen stark auf einzelne Frequenzen konzentrierte Impulse und Impulse, die sich über einen Bereich von Winkeln oder Intensitäten verteilen, einander angeglichen werden (siehe: ABB. 9.3).

Schließlich wird die Frequenzdarstellung der Klassifizierungskachel normalisiert $f_{\text{norm}}(\omega)$, indem alle Impulswerte der jeweiligen Frequenzdarstellung durch den maximalen Wert der Matrix geteilt werden (siehe: ABB. 9.3). Durch diesen Schritt werden zwar die Intensitäten der Moiréstrukturen der Klassifizierungskachel untereinander angeglichen. Es kann trotzdem angenommen werden, dass bei einer prominent sichtbaren Moiréstruktur ein dominanter Impuls in der Frequenzansicht vorhanden ist. Durch die Normalisierung werden in diesem Fall die Intensitäten der übrigen Frequenzen und Winkel unterdrückt.

Die so erstellten Datensätze werden nachfolgend als Frequenzdatensätze bezeichnet. Die Datensätze, die nicht in die Frequenzdomäne transformiert werden, werden zur Abgrenzung nachfolgend als Spatialdatensätze bezeichnet.

9.5. Verwendung von Augmentierungen zur Steigerung der Robustheit des Datensatzes

Wie bereits in Abs. 8.2 beschrieben, soll verhindert werden, dass ein Klassifizierungsmodell Helligkeit und Kontrast der eingegebenen Klassifizierungskacheln als Merkmale zur Klassifizierung nutzt. Daher wurden zufällige Anpassungen von Helligkeit und Kontrast als Augmentierung des Datensatzes verwendet. Der Effekt wird mit einer Wahrscheinlichkeit von 50% angewandt.

Ein Großteil der erzeugten synthetischen Moirés entsteht durch eine Interferenz mit dem Druckraster. Da Winkelung und Frequenz des Druckrasters fix sind, wird auf Augmentierungen, welche die Geometrie der Klassifizierungskachel verändern, verzichtet. Die notwendige Vielfalt von Winkel und Periode der Moiréstrukturen wird über das in Abs. 8 beschriebene Modell realisiert.

Auch auf Augmentierungen, die sich auf die Farbigkeit der Klassifizierungskachel auswirken, wird verzichtet. Das betrifft beispielsweise das Tauschen von Kanälen oder die Anpassung von Sättigung oder Farbton. Diese Gruppe von Augmentierungen ist für den Datensatz irrelevant, da es sich zwar technisch um RGB-Bilder handelt, die Kanäle jedoch identisch sind und somit de facto Graustufenbilder verwendet werden.

Die Augmentierungen werden nur auf den jeweiligen Trainingsdatensatz angewendet. Die Umwandlung in eine Frequenzansicht, wie in Abs. 9.4, wird erst nach der Anwendung der genannten Augmentierungen durchgeführt.

10. Aufbau und Training des Klassifizierungsmodells

Wie in Abs. 1 beschrieben, ist das gewünschte Ergebnis des Klassifizierungsmodells, zunächst für die ganze Seite zu entscheiden, ob diese ein Moiré enthält. Darüber hinaus soll in Seiten, die ein Moiré enthalten, die Position der erkannten Moirés näherungsweise markiert werden.

Die Klassifizierung einer Seite erfolgt, analog dem in Abs. 9.1 beschriebenen Ansatz, durch Aufteilen der Seite in Kacheln der Größe 224x224 Pixel und dreimaliger Verarbeitung einer Seite mit Auflösungen von 300 dpi, 200 dpi und 150 dpi.

Die Klassifizierung erfolgt in zwei Schritten. In einer Vorabklassifizierung (siehe: Abs. 10.1) werden zunächst Kacheln entfernt, für die Anhand einfacher Regeln ein Entstehen von Moirés ausgeschlossen werden kann. Dieser Schritt dient der Reduzierung der zur Verarbeitung benötigten Ressourcen. Die Kacheln, die nicht durch die Vorabklassifizierung ausgeschlossen werden, werden im nächsten Schritt durch ein Deep-Learning Modell klassifiziert. Die für dieses Modell gewählte Architektur sowie der Ablauf des Trainings werden in Abs. 10.2 und Abs. 10.3 beschrieben.

10.1. Vorabklassifizierung

Im ersten Schritt werden die erzeugten Kacheln vorabklassifiziert. Ziel ist es, diejenigen Kacheln herauszufiltern, bei denen aus technischer Sicht kein Moiré entstehen kann. Die Prüfung ist sehr streng angelegt. Sobald in Zweifel steht, ob in einer Kachel aus technischer Sicht ein Moiré enthalten sein kann, wird sie für Klassifizierung im zweiten Schritt übernommen.

Eine Kachel wird nicht für den zweiten Klassifizierungsschritt übernommen, wenn die folgenden Bedingungen zutreffen:

- Für jeden Kanal wird der Anteil der Pixel ausgerechnet, dessen Tonwert $> (100 - p)\%$ oder $< p\%$ ist
- Liegt dieser Anteil für jeden Kanal bei $\geq X\%$, so kann auf dieser Kachel aus technischer Sicht kein Moiré entstehen und die Kachel wird nicht weitergegeben.

Im Rahmen dieser Arbeit wurden für p und X die Werte 5% und 0,95 als Parameter gewählt.

Zur Prüfung der Wirksamkeit der Vorabklassifizierung wurden aus dem in Abs. 7 beschriebenen Datensatz 250 Seiten zufällig ausgewählt. Für diese Seiten wurde eine Vorabklassifizierung durchgeführt.

ABB. 10.1 zeigt den Anteil der jeweils durch Vorabklassifizierung entfernten Kacheln für diese Seiten. Im Durchschnitt konnten 36% der Kacheln pro Seite entfernt werden. Die Standardabweichung

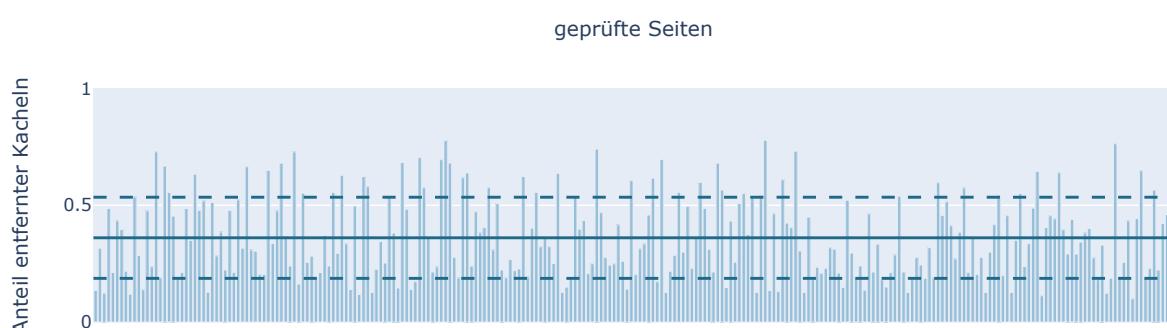


ABB. 10.1. Anteil der durch die Vorabklassifizierung entfernten Kacheln exemplarisch für 250 zufällig aus dem Testdatensatz ausgewählte Seiten. Die durchgezogene Linie markiert den Durchschnitt (0,36), die gestrichelten Linien die Standardabweichung (0,17).

beträgt 17%. Die hohe Schwankung des Anteils der entfernten Klassifizierungskacheln ist nicht verwunderlich, da beispielsweise bei einer Buchseite eines Romanes ein Großteil der Seite unbedruckt einfarbig mit Text bedruckt ist, während eine Anzeige typischerweise einen sehr geringen Anteil an unbedruckter Fläche aufweist.

10.2. Verwendete Modellarchitektur

Für die Klassifizierung der Kachen, die nicht durch den in Abs. 10.1 beschriebenen Prozess ausgeschlossenen werden konnten, wurden verschiedene Deep-Learning Modelle erstellt und geprüft. Bei den verwendeten Modellen handelt es sich um Convolutional Neural Networks. Diese bestehen aus sogenannten Convolutional Layern. Sie unterscheiden sich in ihrer Funktionsweise deutlich von den in Fully-Connected Networks verwendeten Layern. Als Eingabe wird anstatt eines eindimensionalen Vektors üblicherweise eine zwei- oder dreidimensionale Matrix verwendet. Im Falle der Verarbeitung von Bildern beschreiben die drei Dimensionen die Breite, Höhe und die Kanäle der Eingabe. Das Lernen innerhalb eines Convolutional Layers erfolgt nicht mit Hilfe von einzelnen Neuronen sondern durch sogenannte Kernel. Dabei handelt es sich um Matrizen mit einer Größe von zum Beispiel 3×3 oder 5×5 , jeweils mit der Anzahl der Kanäle der erzeugten Matrizen des vorhergehenden Layers als dritte Dimension. Diese werden über die eingegebenen Matrizen bewegt und mit dem jeweils überlagerten Ausschnitt multipliziert. Das Ergebnis wird in eine neue Matrix, die sogenannte Feature Map, geschrieben. Ein Beispiel für diesen Ablauf ist in ABB. 10.1 abgebildet. Die Verwendung von Convolutional Neural Networks eignet sich besonders für die Verarbeitung von Bildern. Durch die Verwendung von Kernels anstatt Neuronen können einzelne Eigenschaften unabhängig von ihrer Position im Eingabebild erlernt werden, ohne dass die Information über die Position des Features in der Eingabematrix verloren geht. Für Klassifizierungsaufgaben wird üblicherweise die Ausgabe des letzten Convolution Layers in einen eindimensionalen Vektor umgewandelt. Dieser dient als Eingabe für eine Anzahl an Fully-Connected Layern, welche die Klassifizierung vornehmen[3](Abs. 12.6). Eine beispielhafte Architektur eines Convolutional Neural Network ist in ABB. 10.3 abgebildet.

Für die in dieser Arbeit behandelte Klassifizierungsaufgabe wurde keine eigene Modellarchitektur entwickelt. Stattdessen wurden verschiedene weit verbreitete Modellarchitekturen mit vortrainier-

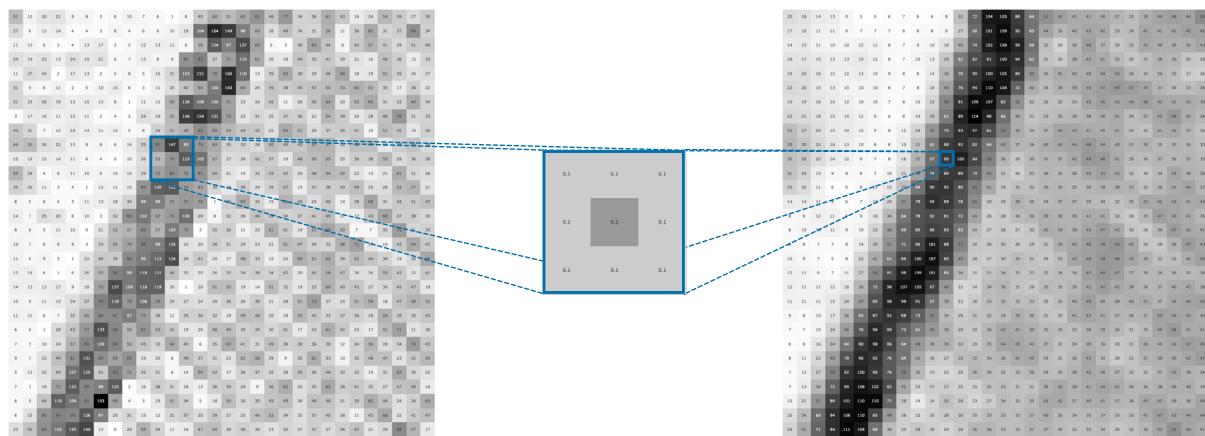


ABB. 10.2. Anwendung eines Kernels auf eine Eingabematrix. Im dargestellten Beispiel wird die ausgewählte Fläche aus der Eingabematrix mit dem Kernel multipliziert und das Ergebnis in der Zielmatrix in ein Feld geschrieben. Aus einer 3×3 Eingabe wird hier also ein einzelner Wert erzeugt.

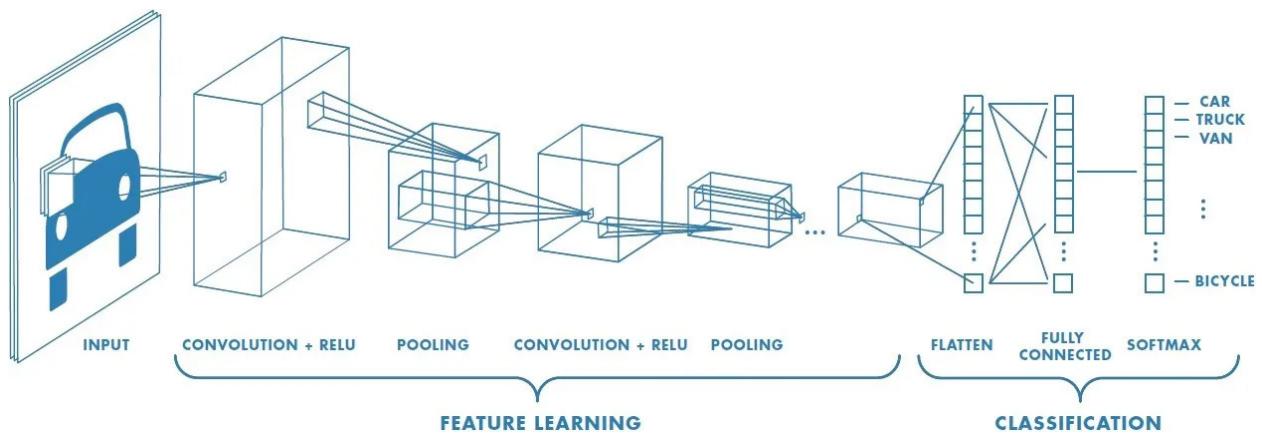


ABB. 10.3. Ein Beispiel für den Aufbau eines Convolutional Neural Networks. Aus dem eingegebenen Bild werden über Blöcke von Convolutional Layers und Pooling Layers die dem Bild innewohnenden Features extrahiert. Danach wird Feature Map in einen Vektor umgewandelt, der in eine Anzahl Fully Connected Layer eingegeben wird.

ten Parametern verwendet. Diese wurden mit dem in Abs. 9 beschriebenen Datensätzen trainiert. Die Modelle sollen die Klassifizierungskacheln einer von zwei Klassen zuordnen: *moiré* und *kein moiré*. Die zur Klassifizierung verwendeten Layer der zu Grunde liegenden Modelle wurden ersetzt durch einen Fully-Connected-Layer mit zwei Ausgabeknoten. Diese repräsentieren die Klassen *moiré* und *kein moiré*. Abschließend werden die erzeugten Werte mit Hilfe einer Softmax-Funktion in Wahrscheinlichkeiten umgewandelt [28](S.274). Die Softmax-Funktion errechnet die Wahrscheinlichkeit einer einzelnen Klasse basierend auf den Wahrscheinlichkeiten der übrigen Klassen, sodass die Summe des Ausgabevektors immer 1 ergibt. Das beschriebene Prinzip der Anpassung eines existierenden Modells an eine neue Aufgabe wird als *domain adaption* bezeichnet und ist im Bereich der Computer Vision weit verbreitet [28](5.4.7).

Im Rahmen dieser Arbeit wurden die folgenden Modellarchitekturen getestet:

- MobileNetV3-Small
- Resnet50

Diese Architekturen wurden ausgewählt, da sie weit verbreitet sind und für viele Computer Vision Probleme bereits erfolgreich eingesetzt wurden. Zudem wurden sie umfangreich auf Standarddatensets trainiert, wodurch der Prozess des Trainings auf die konkrete Aufgabe deutlich vereinfacht wird, da die Kernel bereits in der Lage sind, typische Strukturen im Bild zu erkennen.

Die Resnet Architektur[50] stellt einen guten Kompromiss zwischen Qualität der erreichbaren Ergebnisse und Komplexität des Modells beziehungsweise benötigter Rechenleistung dar (siehe: [28](Figure 5.44)). Die verwendete Variante Resnet50 verwendet 50 Convolutional Layer die in sogenannten Bottleneck Bausteinen zu je drei Layern angeordnet sind (siehe: Abb. 10.4). Rund um jeden Baustein wird eine so genannte Skip Connection hinzugefügt. Durch die Skip Connections wird Ergebnis des vorhergehenden Bausteins nach der Verarbeitung einer Eingabe durch

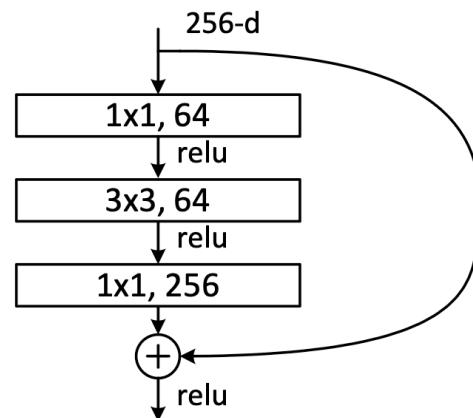


ABB. 10.4. Aufbau eines Bottleneck Bausteines aus der Resnet50-Architektur.

den aktuellen Baustein zu der Eingabe des Bausteins addiert. Diese Summe dient als Eingabe des nächsten Bausteins. Dadurch werden Macro-Eigenschaften zu den späteren Layern übertragen. Zudem erlaubt es dieses Vorgehen, sehr tiefe Netze zu verwenden.

Die MobileNetV3 Architektur ist eine besondere effiziente Architektur, die für den Einsatz auf Mobilgeräten wie Handys oder Tablets entwickelt wurde[51]. Sie weist eine geringere Komplexität als die Resnet50-Architektur aufweist, wodurch die Ergebnisse der Architektur, in Abhängigkeit der Komplexität der Aufgabe, weniger gut ausfallen können. Die MobileNet Architektur verwendet als Kernbestandteil ebenfalls Bottleneck Bausteine bestehend aus drei Convolutional Layern. Auch hier wird eine Skip Connection hinzugefügt. Die MobileNetV3-Small verwendet elf dieser Bottleneck Bausteine.

Durch den Vergleich der Architekturen soll geprüft werden, ob ein Standardmodell in der Lage ist, die geforderte Klassifizierung zu leisten oder ob eine speziell für die Aufgabe entwickelte Architektur notwendig ist. Zudem soll geprüft werden, ob ein komplexes Modell notwendig ist oder eine weniger komplexe Architektur ausreichende Ergebnisse liefert.

Da ein großer Anteil der Moiréstrukturen erst durch die Umwandlung in eine Rasterabbildung entstehen, liegt die Anwendung einer Architektur nahe, die auf dem Vergleich zweier Eingaben basiert. Ein Beispiel wäre hier die Anwendung der Siamese-Network Architektur [52] mit der moiréfreien Halbtönkachel sowie der potenziell moirébehafteten Rasterkachel als Eingabe. Ein solcher Ansatz ist vielversprechend, im Rahmen dieser Arbeit wird dieser jedoch nicht weiter verfolgt. Durch diesen Ansatz können nur Moirés der dritten in Abs. 5.1 beschriebenen Gruppe erkannt werden. Moirés der anderen beiden Gruppen werden nicht beachtet. Zudem wird der Effekt mindestens näherungsweise durch die in Abs. 9.1 beschriebene Bildung von Kachelpaaren nachgebildet.

10.3. Ablauf des Trainings und gewählte Hyperparameter

Entsprechend der Verwendung einer Softmaxfunktion zur Generierung der Ausgabe des Modells wird als Loss-Funktion im Training der Cross-Entropy-Loss verwendet[28](Abs. 5.3.4). Als Optimierungsfunktion wird der Adam-Optimizer verwendet[53].

Das Training erfolgte jeweils in 2x10 Epochen. Für die ersten 10 Epochen wird die Learning Rate auf 0,001 gesetzt, für die folgenden 10 auf 0,0001. Die übrigen Parameter des Adam-Optimizers (β_1 , β_2 , ε und weight decay) wurden auf die von Pytorch verwendeten Standardwerte gesetzt[54].

Die während des Trainingsprozesses verwendeten Trainings- und Validierungsdaten werden in Batches von je 64 Datenpunkten aufgeteilt. Zur Bewertung des Lernfortschrittes werden die Metriken Accuracy, Recall und Precision verwendet[28](Abs. 7.1, S.443). Die Accuracy beschreibt den Anteil der korrekt klassifizierten Klassifizierungskacheln. Recall bezeichnet den Anteil der korrekt erkannten Klassifizierungskacheln mit Moiré an allen Klassifizierungskacheln, die ein Moiré enthalten. Precision schließlich beschreibt den Anteil der korrekt als moiré erkannten Klassifizierungskacheln an allen vom Modell als moiré klassifizierten Klassifizierungskacheln.

Anders als im Prozess der domain adaption üblich, wurden die Parameter der Convolutional Layer für das Training nicht eingefroren. Da zur korrekten Klassifizierung der Klassifizierungskacheln geometrische Strukturen erkannt und konkrete abgebildete Objekte ignoriert werden sollen, wurde entschieden, dass auch die Parameter der Convolutional Layer weiter trainiert werden.

Das Training erfolgte auf einer virtuellen Maschine mit dem Betriebssystem RedHat 8.9[55] mit Hilfe einer Nvidia Tesla V100 Grafikkarte mit 16GB VRAM.

11. Diskussion der Ergebnisse

Nachfolgend werden die im Rahmen dieser Arbeit erarbeiteten Ergebnisse beschrieben und analysiert. Zunächst werden in Abs. 11.1 die entsprechend Abs. 8 erstellten Objektkacheln untersucht. Dabei soll insbesondere ergründet werden, welche Eigenschaften und Parameter während der Erzeugung von Objektkacheln sich überdurchschnittlich stark auf die Entstehung von Moiréstrukturen auswirken. Dies kann sowohl der Verbesserung der Erzeugung von Objektkacheln dienen, als auch Erkenntnisse über die Entstehung von Moirés in der Druckproduktion liefern.

In Abs. 11.2 erfolgt die Analyse der Ergebnisse der entsprechend Abs. 9 und Abs. 10 trainierten Modelle. Es soll insbesondere untersucht werden, ob es gelungen ist, Modelle zu trainieren, welche die beschriebene Klassifizierungsaufgabe in einer hohen Qualität durchführen können. Zudem soll geklärt werden, welche Modellarchitektur und welcher Trainingsdatensatz die besten Ergebnisse erreichen konnte.

11.1. Auswertung der Patternerstellung

Nachfolgend soll dargestellt werden, welche Eigenschaften der erzeugten Pattern (siehe: Abs. 8) sich signifikant auf das Entstehen von identifizierbaren Moiréstrukturen auswirken.

TABELLE 11.1 zeigt die drei Ergebnisklassen und die Anzahl der Objektkacheln, die der jeweiligen Klasse zugeordnet wurden. Wie in Abs. 8.5 werden Objektkacheln, bei denen im Vergleich zum Originalausschnitt ein SSIM-Wert von $> 0,95$ errechnet wird, ohne manuelle Auszeichnung als moiréfrei klassifiziert. Nachfolgend wird der Anteil der Objektkacheln mit Moiré an allen Objektkacheln einer Auswahl als Moirérate bezeichnet. Für alle erzeugten Objektkacheln liegt die Moirérate bei 0,11. Insgesamt kann festgehalten werden, dass keine einzelne Eigenschaft einen signifikanten Einfluss auf die Entstehung von Moiréstrukturen hat. Nachfolgend wird im Detail auf die Auswirkung der Eigenschaften der verwendeten Patternvorlagen sowie der verwendeten Effekte und deren Parameter eingegangen.

11.1.1. Auswertung nach Eigenschaften der Patternvorlagen

ABB. 11.1 zeigt die Verteilung der drei Klassen gruppiert nach dem Muster der Patternvorlage (siehe: Abs. 8.2.1). Die drei Muster weisen die folgenden Moirératen auf:

- Linie: 0,132
- Kreis: 0,096
- Karo: 0,1

Während Karo und Kreis nahezu gleiche Moirératen aufweisen, ist die Moirérate für die Linienmuster deutlich höher.

Klasse	Anzahl an Objektkacheln
geprüft - Moiré	1047
geprüft - kein Moiré	4281
ssim > 0,95	4160

TABELLE 11.1. Übersicht über die erstellten Klassen und die Anzahl der Objektkacheln, die den jeweiligen Klassen zugeordnet wurden.

Die Tabelle zeigt, dass die Anzahl der Objektkacheln in den drei Klassen unterschiedlich ist. Die Klasse "geprüft - Moiré" hat die geringste Anzahl an Objektkacheln (1047), während die Klasse "geprüft - kein Moiré" die höchste Anzahl an Objektkacheln (4281) aufweist. Die Klasse "ssim > 0,95" hat eine Anzahl von 4160 Objektkacheln.

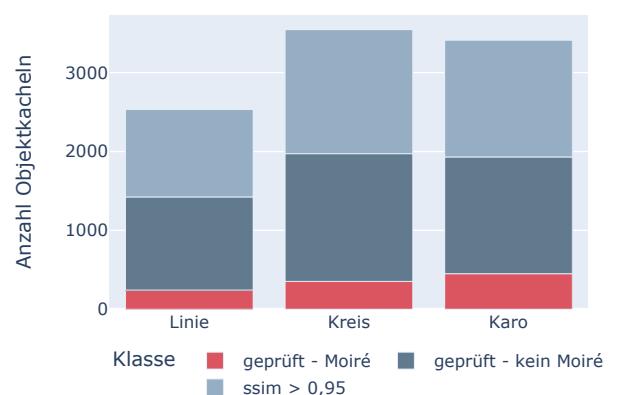


ABB. 11.1. Übersicht über die Verteilung der Klassen, gruppiert anhand der Grundform des montierten Patterns.

ten aufweisen, weist das Muster Linie eine erhöhte Moirérate auf. Dies deckt sich mit der Beobachtung aus Abs. 4.2, dass Moiréstrukturen, die durch Interferenz von eindimensionalen Grundstrukturen entstehen, eine höhere optische Intensität aufweisen, als diejenigen, die durch zweidimensionale Grundstrukturen entstehen (vergleiche: ABB. 4.11, ABB. 4.14 und ABB. 4.22). Ein Beweis für einen Zusammenhang ist dies jedoch nicht.

Die Verteilung der Flächendeckung innerhalb einer Patternvorlage erfolgt entweder gleichmäßig oder zufällig anhand des Perlin-Noise Algorithmus. ABB. 11.2 zeigt die Verteilung der drei Klassen gruppiert nach der Art der Verteilung der Flächendeckung.

Für die Gruppen wurden die folgenden Moirératen erreicht:

- gleichmäßige Verteilung: 0,103
- Verteilung mit Perlin-Noise: 0,113

Die Moirératen liegen eng beieinander, daher kann angenommen werden, dass diese Eigenschaft keinen signifikanten Einfluss auf die Entstehung von Moiréstrukturen hat.

Für die Bestimmung des Einflusses der Flächendeckung wurden nur diejenigen Patternvorlagen mit gleichmäßiger Verteilung der Flächendeckung betrachtet. Für die Patternvorlagen mit Verteilung der Flächendeckung auf Grundlage des Perlin-Noise Algorithmus wäre eine Aggregation der in der Patternvorlage vorhandenen Flächendeckungen, beispielsweise durch Bildung des Durchschnitts, notwendig gewesen. Dies kann potenziell zu einer Verzerrung des erkannten Zusammenhangs führen, wenn beispielsweise eine Moiréstruktur genau an der Stelle eines Perlin-Noise basierten Patternvorlage entsteht, die eine besonders stark vom Durchschnitt dieser Patternvorlage abweichende Flächendeckung aufweist.

Die Verteilung der Objektkacheln gruppiert nach Flächendeckung der Patternvorlage ist in ABB. 11.3 dargestellt. TABELLE 11.2 zeigt die ermittelten Moirératen. Bemerkenswert sind hier die Werte für die Flächendeckungen 0,5, 0,6 und 0,9, die deutlich erhöht sind. Bei den mittleren Flächendeckungen 0,5 und 0,6 ist, aufgrund der annähernd gleichverteilten hellen und dunklen Bereich, eine erhöhte Moirérate erwartbar. Bei einer Flächendeckung von 0,9 ist diese hingegen überraschend. Patternvorlagen mit einer Flächendeckung von 0,9 entsprechen in ihren geometrischen Eigenschaften weitestgehend einer Patternvorlage mit einer Flächendeckung von 0,1. Die hellen und dunklen Bereiche sind lediglich invertiert. Die Gruppe der Patternvorlagen mit einer Flächendeckung von 0,1 weisen jedoch eine deutlich unterdurchschnittliche Moirérate von 0,036 auf. Überraschend sind zudem die unterdurch-

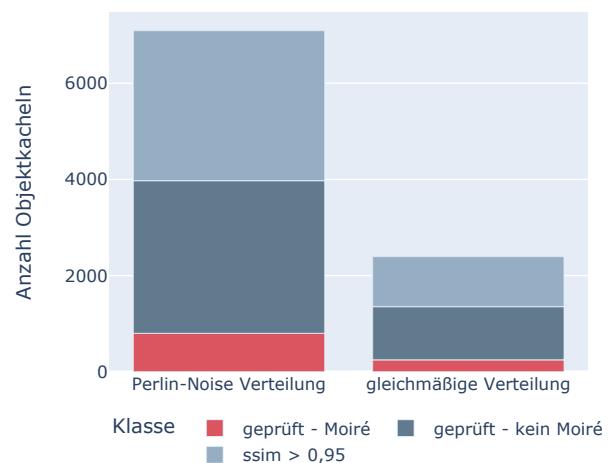


ABB. 11.2. Übersicht über die Verteilung der Klassen gruppiert anhand der Art der Verteilung der Flächendeckung.

Flächendeckung	Moirérate
0,1	0,036
0,2	0,081
0,3	0,107
0,4	0,089
0,5	0,122
0,6	0,136
0,7	0,066
0,8	0,114
0,9	0,131

TABELLE 11.2. Übersicht über die Moirératen gruppiert nach Flächendeckung der verwendeten Patternvorlage. Die Patternvorlagen mit Perlin-Noise basierter Verteilung der Flächendeckung werden nicht dargestellt.

schnittlichen Moirératen der Gruppen 0,4 und 0,7, welche direkt benachbart zu den Gruppen 0,5 und 0,6 liegen. Dadurch wäre eine vergleichbare Moirérate erwartbar.

11.1.2. Einfluss der Eigenschaften der unveränderten Objektkachel

Es kann angenommen werden, dass auch die optischen Eigenschaften der unveränderten Objektkachel Einfluss auf die Entstehung von Moiréstrukturen haben. ABB. 11.4 zeigt den Zusammenhang zwischen Helligkeit und Kontrast der unveränderten Objektkachel und der Entstehung von Moiréstrukturen. Die Helligkeit wird dargestellt durch den durchschnittlichen Tonwert des Schwarzkanals, der Kontrast durch die Standardabweichung selbigens.

Ein Zusammenhang zwischen der Helligkeit der Kachel und dem Entstehen von Moiréstrukturen ist nicht erkennbar. Beim Kontrast hingegen fällt auf, dass insbesondere die Objektkacheln der Klasse $ssim > 0,95$ sich in der Tendenz häufig nahe dem jeweils maximal möglichen Kontrastwert liegen, während die Objektkacheln der übrigen Klassen sich in der Tendenz im mittleren Kontrastbereich bewegen. Ein Zusammenhang zwischen dem Kontrast der unveränderten Objektkachel und der Entstehung von Moirés kann also angenommen werden. Es muss hier jedoch berücksichtigt werden, dass dieser Zusammenhang nur im Rahmen der künstlichen Montage von Pattern beobachtet wurde. Eine allgemeingültige Aussage für die Entstehung von Moiréstrukturen kann hieraus nicht abgeleitet werden.

11.1.3. Auswertung anhand der verwendeten Effekte

Nachfolgend wird untersucht, welchen Einfluss die verwendeten Effekte auf die Entstehung von Moirés haben. Zusammenfassend kann hier festgehalten werden, dass kein Feature einen signifikant überdurchschnittlichen Einfluss auf die Entstehung von Moirés hat.

TABELLE 11.3 zeigt die Wahrscheinlichkeit, dass eine Objektkachel ein Moiré enthält, unter der Bedingung, dass auf diese Objektkachel ein spezifischer Effekt angewandt wurde. Sämtliche Werte liegen eng beieinander. Mit Blick auf ABB. 11.5 und TABELLE 11.3 sticht der Wert für den Effekt Rotation heraus. Dies kann damit erklärt werden, dass die Patternvorlagen auf 0° gewinkelt sind. Da für die Entstehung eines Moirés geringer Winkelunterschied zwischen Basis- und Effektebene notwendig ist,

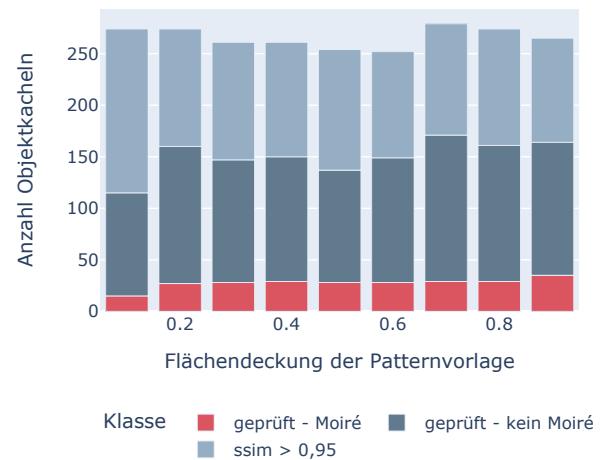


ABB. 11.3. Übersicht über die Verteilung der Klassen, gruppiert anhand der Art der Verteilung der Flächendeckung.

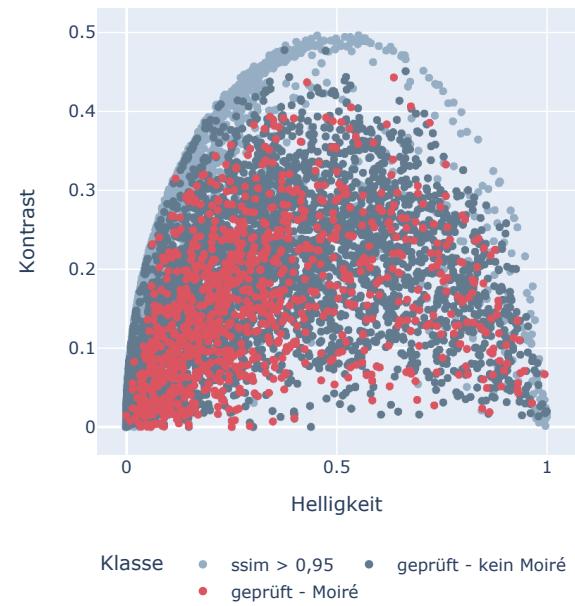


ABB. 11.4. Verteilung der Beispiele nach Helligkeit und Kontrast des Schwarzkanals der unveränderten Objektkachel. Die Helligkeit wird repräsentiert durch die durchschnittliche Flächendeckung, der Kontrast durch die Standardabweichung der Flächendeckung.

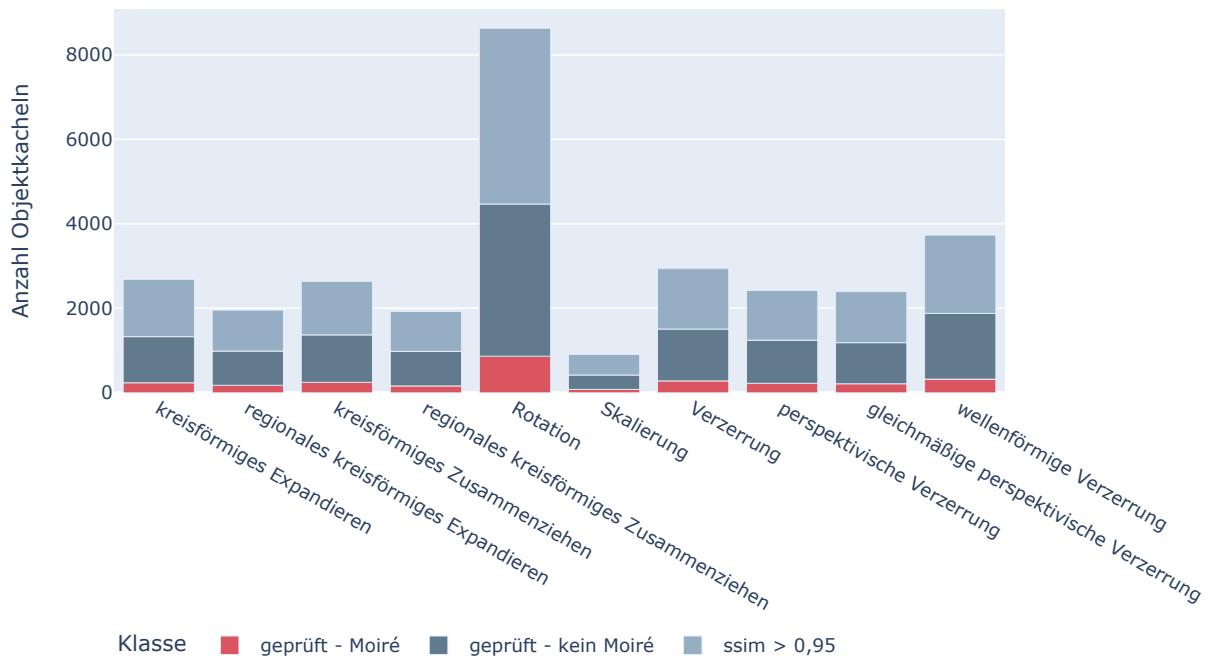


ABB. 11.5. Übersicht über die Verteilung der Klassen gruppiert anhand der verwendeten Patterneffekte. Da auf eine Objektkachel eine nicht fixe Anzahl an Patterneffekten angewendet werden können, ist die Summe der dargestellten Kacheln abweichend zu den vorherigen Grafiken.

wird auf die Mehrzahl der Objektkacheln der Effekt Rotation angewandt, häufig mit einem fixen Wert. Als Gesamtergebnis kann mit Blick auf TABELLE 11.3 festgehalten werden, dass die Verwendung keines Effektes einen herausstechend großen Einfluss auf die Entstehung von Moiréstrukturen hat.

Zusätzlich zur bloßen Verwendung einzelner Effekte wird nachfolgend auch die Auswirkung der verwendeten Werte für dessen Parameter auf die Entstehung von Moirés untersucht. Für diese Untersuchung wurden die Klassen *geprüft - kein Moiré* und *ssim > 0,95* wurde hierfür in die Klasse *kein moiré* zusammengefasst.

11.1.4. Berechnung des Einflusses der Effektparameter

In Abs. 11.1.1 und Abs. 11.1.3 wurden die Einflüsse der einzelnen Eigenschaften der erstellten Objektkacheln auf die Entstehung von Moiréstrukturen untersucht.

In diesem Abschnitt soll nun das Zusammenspiel der Faktoren untersucht werden. Dafür wurden alle untersuchten Eigenschaften der Objektkacheln in einer Tabelle zusammengeführt. Die Effekte Stretch und Skalierung sowie perspektivische Verzerrung und gleichmäßige perspektivische Verzerrung wurden hier zusammengefasst.

Effekt	Moirérate
kreisförmiges Expandieren	0,088
regionales kreisförmiges Expandieren	0,09
kreisförmiges Zusammenziehen	0,094
regionales kreisförmiges Zusammenziehen	0,083
Rotation	0,1
Skalierung	0,087
Verzerrung	0,096
perspektivische Verzerrung	0,092
gleichmäßige perspektivische Verzerrung	0,09
wellenförmige Verzerrung	0,086

TABELLE 11.3. Übersicht über die Moirératen gruppiert nach verwendetem Patterneffekt.

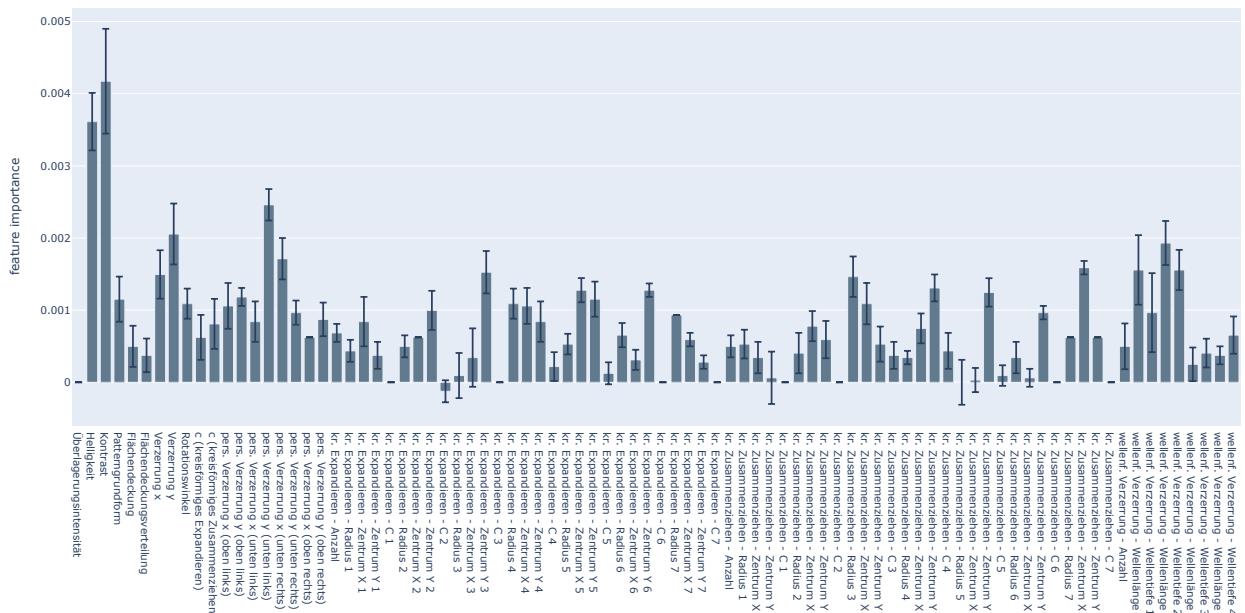


ABB. 11.6. Dargestellt ist der Einfluss der einzelnen Features auf die Entstehung von Moirés. Die Feature Importance entspricht der Abweichung der durchschnittlichen Accuracy des Random-Forest Klassifizierungsmodells bei Permutation des entsprechenden Features (siehe: Abs. 11.1.4).

In beiden Fällen lässt sich einer der Effekte verlustfrei durch den anderen Effekt darstellen, womit eine Zusammenfassung die Anzahl der zu betrachtenden Dimensionen reduziert. Die Effekte regionales kreisförmiges Expandieren und Zusammenziehen sowie wellenförmige Verzerrung können mehrfach innerhalb einer Objektkachel überlagert werden. Um dies abzubilden, werden die Parameter jeder Anwendung als separates Features behandelt. Es werden also beispielsweise die Wellentiefe der ersten angewendeten Wellen, die Wellentiefe der zweiten angewendeten Wellen und so weiter miteinander verglichen. Zusätzlich wird der durchschnittliche Tonwert des Schwarzenals der Objektkachel vor der Montage der Patternvorlage sowie deren Kontrast, dargestellt durch die Standardabweichung des Tonwertes, untersucht. Diese Werte sind zwar keine Parameter der angewendeten Effekte, wie jedoch in Abs. 11.1.3 dargestellt, kann ein Einfluss auf die Entstehung von Moiréstrukturen angenommen werden.

Aus dieser Tabelle wurden zufällig 80% der Werte ausgewählt. Mit dieser Auswahl wurde ein Random-Forest Klassifizierungsalgorithmus[28](Abs. 5.1.5) darauf trainiert, in die Klassen *moiré* und *kein moiré* zu unterscheiden. Dieses Modell erreichte auf dem Trainingsdatensatz eine Accuracy von 92,4% und auf dem Testdatensatz eine Accuracy von 90,9%. Das Modell ist demzufolge in der Lage, die Klassifizierung auf einem hohen Niveau durchzuführen. Weiterhin liegt kein Overfitting vor, da auch die Accuracy auf dem Testdatensatz auf einem vergleichbar hohen Niveau liegt.

Der Einfluss der einzelnen Features wird durch Berechnung der Permutation Importance[55] dargestellt. Dafür werden in einem Durchgang die Ausprägungen eines Features zufällig anderen Beispielen zugeordnet und erneut der Score des Modells errechnet. Der Einfluss des jeweiligen Features ergibt sich aus der Abweichung der durchschnittlichen Accuracy für den Random Forest Classifier. Für diese Arbeit wurde dieser Test zehn mal für jedes Feature durchgeführt. Die Ergebnisse sind in ABB. 11.6 dargestellt. Es ist erkennbar, dass bei keinem der Features eine Abweichung in der Accuracy von mehr als 0,5% festgestellt werden konnte. Durch die Verwendung der Permutation Importance wird auch die Kreuzkorrelation mit anderen Features geprüft. Zusammen mit der Erkenntnis, dass der beschriebene Random-Forest Classifier in der Lage ist, die Objektkacheln anhand ihrer Features zu über 90%

korrekt zu klassifizieren, lässt dies die Vermutung zu, dass die Entstehung von Moiréstrukturen nicht von einfach Zusammenhängen in den Merkmalsausprägungen abhängt, sondern durch eine komplexe Wechselwirkung mehrerer Features entsteht.

11.2. Auswertung der trainierten Klassifizierungsmodelle

Wie in Abs. 10.2 beschrieben, wurden Modelle auf Grundlage der Resnet50 und der MobileNetV3 Architektur trainiert. Von jedem dieser Modelle wurden zwei Varianten trainiert, je eines unter Verwendung der spatialen Datensätze und eines unter Verwendung der frequenzbasierten Datensätze (siehe: Abs. 9.4). Daraus ergeben sich insgesamt vier Modelle, die nachfolgend verglichen werden. Diese werden zur Unterscheidung nachfolgend als Resnet50 spatial, Resnet50 frequenz, MobileNetV3 spatial und MobileNetV3 frequenz bezeichnet.

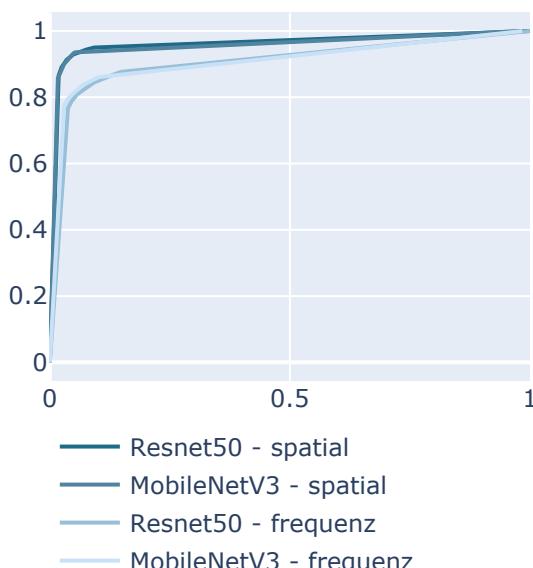
Zur Bewertung des Qualität des Modells werden der Testdatensatz und der reale Testdatensatz herangezogen. Deren Zusammenstellung wird in Abs. 9.2 beschrieben.

Die Betrachtung erfolgt unter drei Aspekten:

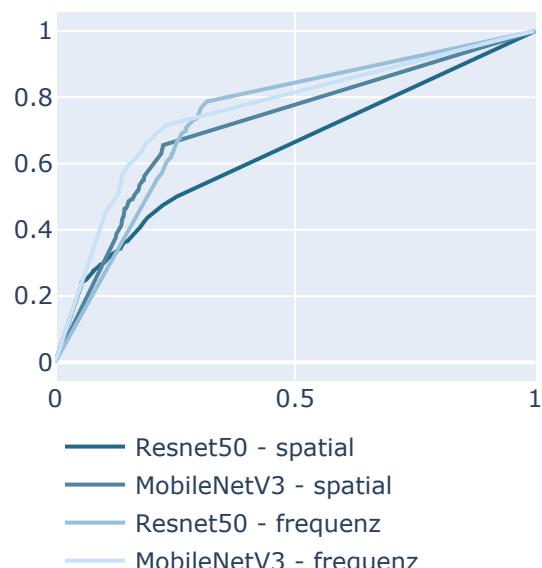
- auf Basis der einzelnen Klassifizierungskacheln
- gruppiert nach Auflösung der Klassifizierungskacheln
- gruppiert nach Objektmaske

Zudem wird abschließend auf die gemeinsame Verwendung mehrerer Modelle als Ensemble eingegangen.

Die Eignung der Modelle wird in Form von Receiver Operational Characteristics-Kurven (ROC) dargestellt[28](S.443f). Diese zeigen auf der x-Achse die False-Positive-Rate und auf der y-Achse die True-Positive-Rate für jeden Schwellwert zwischen 0 und 1. Als Positive wird hier die Klasse *moiré* verstanden, als Negative die Klasse *kein moiré*. Da die True-Positive-Rate in Richtung eins und die False-Positive-Rate in Richtung null optimiert werden, zeigt ein Modell bessere Ergebnisse, je näher sich die



1. Testdatensatz



2. realer Testdatensatz

ABB. 11.7. ROC-Kurven für alle Klassifizierungskacheln. 1. zeigt die Ergebnisse auf dem Testdatensatz, 2. die Ergebnisse auf dem realen Testdatensatz. Die x-Achse der Grafiken zeigt die False-Positive-Rate, die y-Achse die True-Positive Rate bei gegebenem Schwellwert.

Kurve der oberen linken Ecke des Graphen, also der Stelle 0|1, annähert.

Eine detaillierte tabellarische Übersicht über die erreichten Ergebnisse findet sich **ANHANG 3**, **ANHANG 4**, **ANHANG 5** und **ANHANG 6**. Für die dort dargestellten Ergebnisse sind jeweils True Positives (TP), True Negatives (TN), False Positives (FP) und False Negatives (FN) sowie die in Abs. 10.3 beschriebenen Metriken Accuracy, Recall und Precision dargestellt. Die Performance der Modelle bezogen auf Laufzeit findet sich in **TABELLE 11.4**.

Wie bereits in Abs. 7 beschrieben, ist der reale Testdatensatz aufgrund von Umfang und Zusammenstellung nur begrenzt repräsentativ. Trotzdem wird er hier zur Bewertung mit herangezogen, da eine alleinige Betrachtung des Testdatensatzes aus synthetisch generierten Moirés keine ausreichenden Rückschlüsse auf die Eignung der Modelle zur Erkennung realer Moirés zulässt.

11.2.1. Ergebnisse auf Basis der Klassifizierungskacheln

ABB. 11.7 zeigt die Ergebnisse der trainierten Modelle ohne Gruppierung der Klassifizierungskacheln. Bezogen auf den Testdatensatz kann festgestellt werden, dass die auf den Spatialdatensätzen trainierten Modelle deutlich bessere Ergebnisse liefern, als die auf den Frequenzdatensätzen trainierten Modelle. Die Ergebnisse der verglichenen Modellarchitekturen liegen bei Training mit dem selben Datensatz hingegen jeweils eng beieinander. Die besten Ergebnisse liefert in dieser Betrachtung das Resnet50 spatial Modell

mit einem Recall von 0,908 einer Precision von 0,95 (siehe: **ANHANG 3**). Aus den Ergebnissen kann abgeleitet werden, dass die verglichenen Modellarchitekturen beide in der Lage sind, eine Klassifizierung mit hoher Qualität vorzunehmen.

Betrachtet man den realen Testdatensatz, so zeigt sich hier ein anderes Bild. Hier liefern die auf den Frequenzdatensätzen trainierten Modelle die besseren Ergebnisse. Den besten Recall erreicht das Resnet50 frequenz Modell mit 0,671, die beste Precision das MobileNetV3 frequenz Modell mit 0,835 (siehe: **ANHANG 3**). Eine mögliche Erklärung kann sein, dass bei der Erstellung der Frequenzdatensätze auf die Frequenzen eine Normalisierung basierend auf dem jeweiligen Maximum der Klassifizierungskachel durchgeführt wird, wodurch optisch schwach sichtbare Impulse potenziell verstärkt werden. Insgesamt muss aber auch festgehalten werden, dass die Ergebnisse für alle Modelle im Vergleich zu den Ergebnissen des Testdatensatzes deutlich zurückfallen.

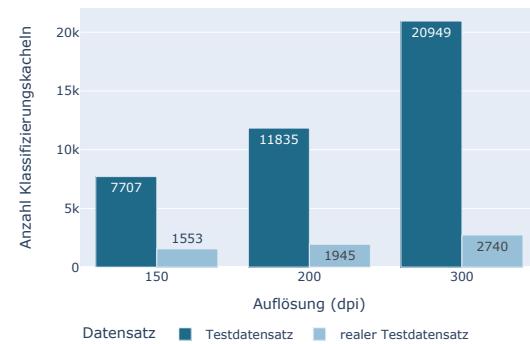


ABB. 11.8. Umfang der Datensätze gruppiert nach Auflösung der Klassifizierungskacheln.

Modell	Dauer GPU	Dauer CPU
Resnet50 <i>spatial</i>	97 s	1559 s
MobileNetV3 <i>spatial</i>	72 s	149 s
Resnet50 <i>frequenz</i>	263 s	1611 s
MobileNetV3 <i>frequenz</i>	169 s	259 s

TABELLE 11.4. Übersicht über die Geschwindigkeit der Verarbeitung der Klassifizierungskacheln durch die getesteten Modelle. Zur Erhebung der Werte wurde der Testdatensatz mit 40.491 Klassifizierungskacheln durch die jeweiligen Modelle je einmal unter Verwendung der GPU und unter Verwendung der CPU klassifiziert. Die Klassifizierung erfolgte auf dem selben System, wie das Training. Für Informationen zur verwendeten Hardware siehe Abs. 10.3.

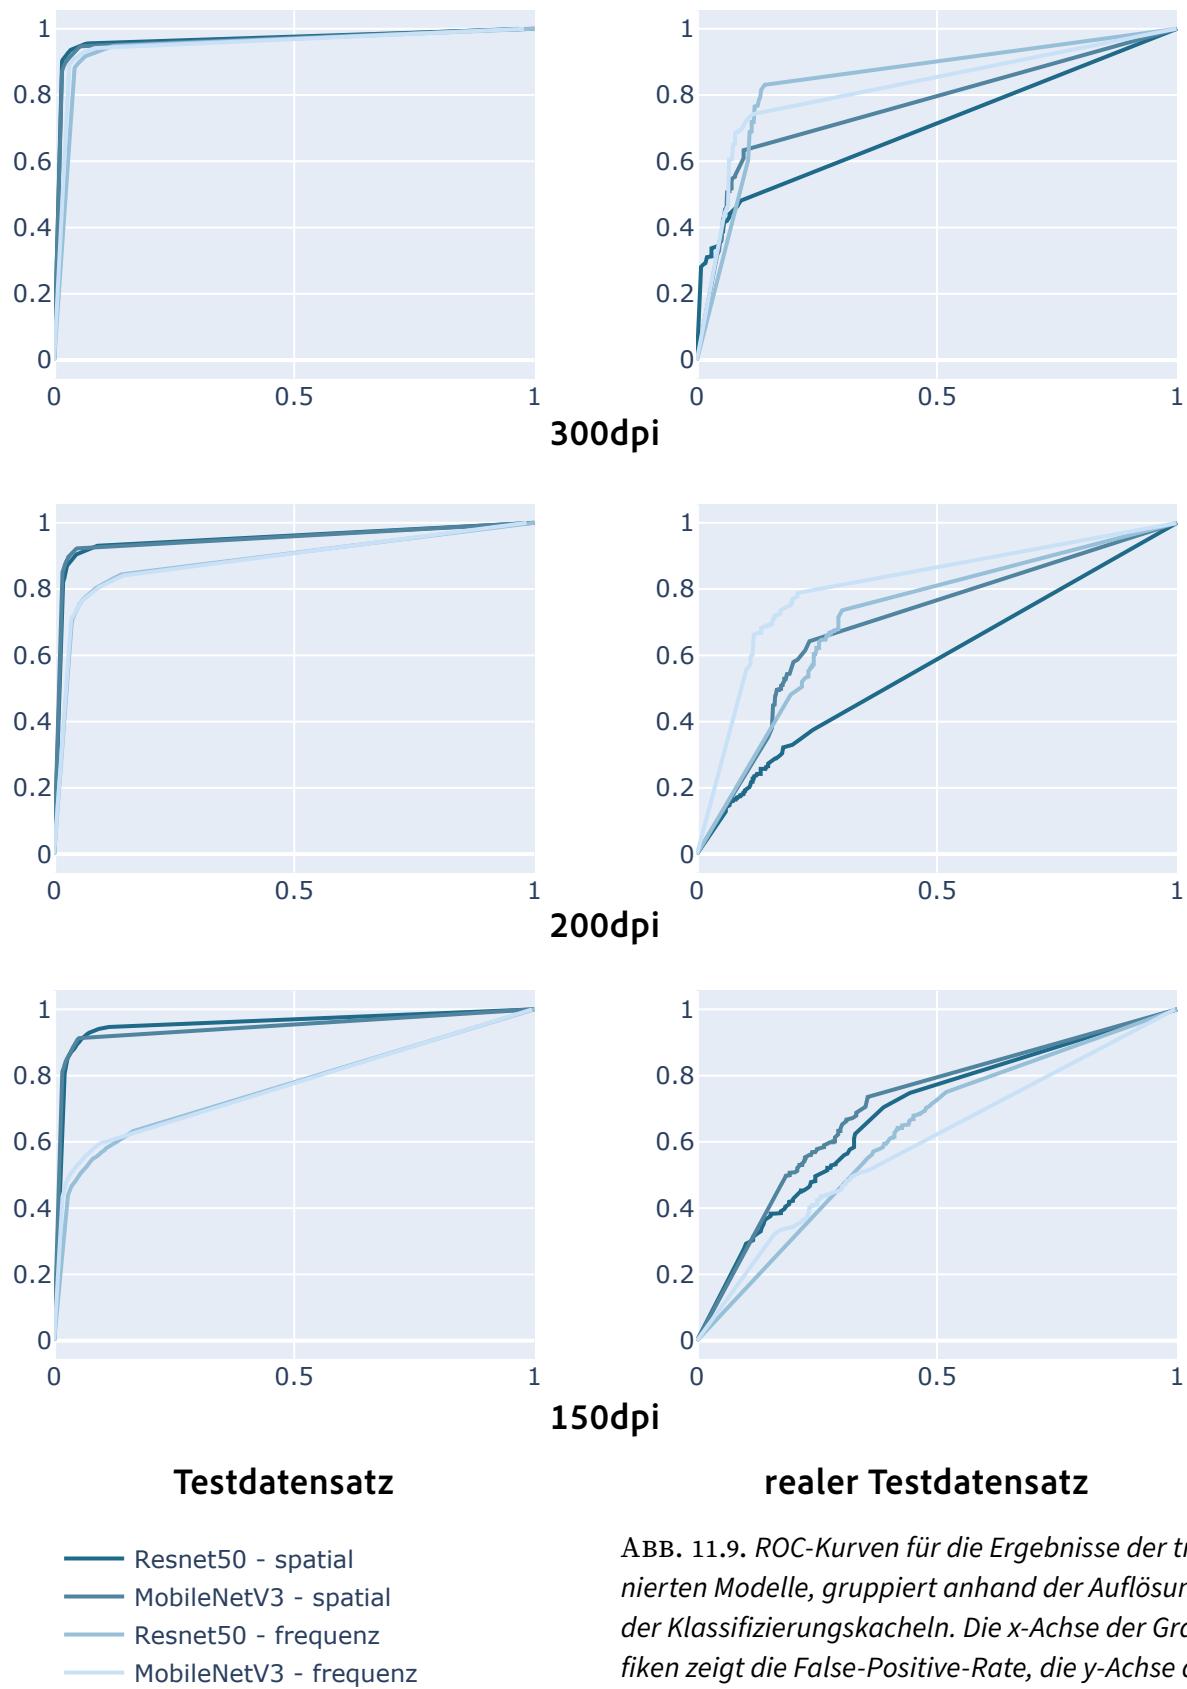


ABB. 11.9. ROC-Kurven für die Ergebnisse der trainierten Modelle, gruppiert anhand der Auflösung der Klassifizierungskacheln. Die x-Achse der Grafiken zeigt die False-Positive-Rate, die y-Achse die True-Positive Rate bei gegebenem Schwellwert.

Insgesamt kann auf dieser ersten Auswertung abgeleitet werden, dass beide verglichenen Modellarchitekturen für die beschriebene Klassifizierungsaufgabe geeignet sind. Aufgrund der unterschiedlichen Ergebnisse für den Testdatensatz und den realen Testdatensatz kann noch keine Aussage darüber getroffen werden, ob die Verwendung der spatialen oder der frequenzbasierten Varianten der Modelle die besseren Ergebnisse erzielt.

11.2.2. Auswertung der Ergebnisse gruppiert nach Auflösung der Klassifizierungskacheln

In Abs. 9.1 wurde die Hypothese aufgestellt, dass die mehrfache Verarbeitung eines Bildausschnittes in unterschiedlichen Auflösungen eine Verbesserung des Klassifizierungsergebnisses zur Folge hat. Nachfolgend wird untersucht, ob diese Hypothese durch die erzielten Ergebnisse gestützt wird oder abgelehnt werden muss. Die Ergebnisse der trainierten Modelle sind in ABB. 11.9 dargestellt. Für die Ergebnisse aller Datensätze fällt auf, dass bessere Ergebnisse erzielt werden konnten je höher die Auflösung der verarbeiteten Klassifizierungskacheln liegt. Dies steht in Kontrast zu der Beobachtung aus Abs. 9.1, dass Moirés in Kacheln mit niedriger Auflösung optisch deutlicher sichtbar sind. Eine mögliche Erklärung ist, dass, wie in ABB. 11.8 zu sehen, die Datensätze deutlich mehr Klassifizierungskacheln mit hoher Auflösung umfassen als Klassifizierungskacheln mit niedriger Auflösung. Dieses Phänomen ist logisch zu erklären, da die Aufteilung der selben Objektkachel in Klassifizierungskacheln mit einem fixen Pixelformat bei höheren Auflösungen mehr Kacheln entstehen lässt. Die erhöhte Anzahl an Klassifizierungskacheln kann ein Grund für die besseren Ergebnisse bei höherer Auflösung sein, da diese im Trainingsprozess stärker präsent sind.

Betrachtet man ausschließlich die Ergebnisse der Modelle für Kacheln mit einer Auflösung von 300 dpi, sind die Ergebnisse in diesem Fall besser, als die Ergebnisse über alle Kacheln hinweg betrachtet. Die Modelle mit dem jeweils besten Ergebnissen sind hier:

- Resnet50 spatial mit einem Recall von 0,930 und einer Precision von 0,959 für den Testdatensatz.
- Resnet50 frequenz mit einem Recall von 0,716 und MobileNetV3 frequenz mit einer Precision von 0,921 für den realen Testdatensatz

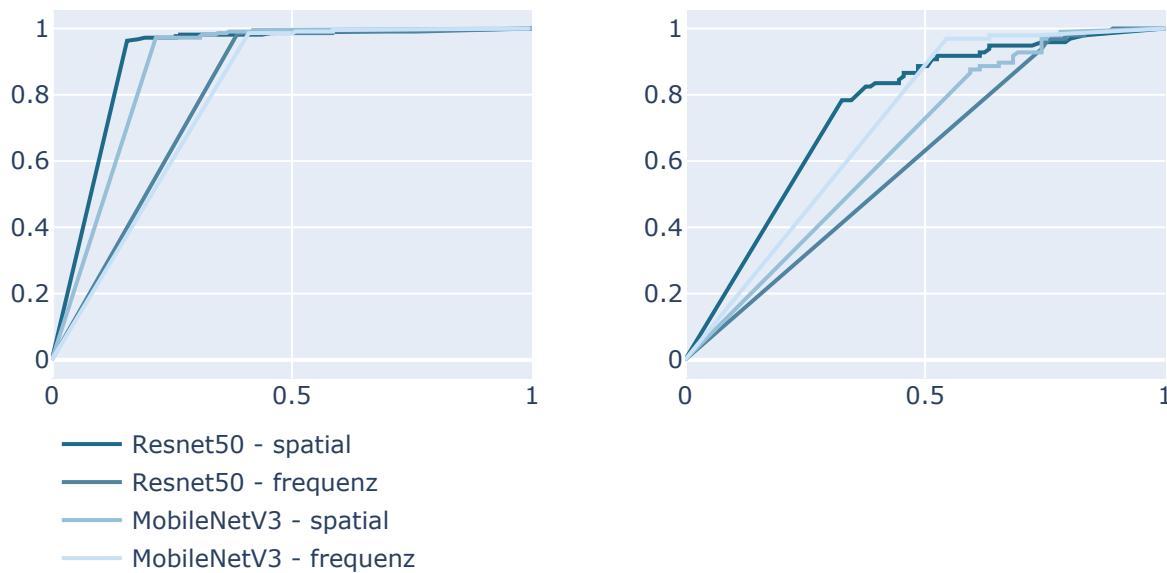
Die Hypothese, dass eine Verarbeitung der selben Objektkacheln in unterschiedlichen Auflösungen die Ergebnisse der Modelle verbessern, muss daher vorerst abgelehnt werden. In Abs. 11.2.3 wird diese Vermutung anhand der Ergebnisse gruppiert nach Objektkacheln weitergehend untersucht.

11.2.3. Auswertung der Ergebnisse gruppiert nach Objektkacheln

Nachfolgend soll analysiert werden, in welcher Qualität die erzeugten Modelle in der Lage sind, ganze Objektkacheln korrekt zu klassifizieren. Entsprechend der in Abs. 1 beschriebenen Problemstellung sowie der in Abs. 9.1 beschriebenen Aufteilung einer Seite in Klassifizierungskacheln ist keine korrekte Klassifizierung aller Klassifizierungskacheln notwendig. Vielmehr bewirkt die Aufteilung einer Objektkachel beziehungsweise eines Seitenausschnittes in mehrere Ausschnitte und Auflösungen eine Verschränkung dieser Klassifizierungen. Wird eine Klassifizierungskachel falsch klassifiziert, kann dies durch die korrekte Klassifizierung einer weiteren Kachel ausgeglichen werden.

Für die folgenden Auswertungen gilt die Annahme: Sobald mindestens eine der Klassifizierungskacheln, die einer spezifischen Objektkachel zugeordnet werden können, als *moiré* klassifiziert wird, gilt diese Klassifizierung auch für die komplette Objektkachel. Nur wenn keine der Klassifizierungskacheln der Klasse *moiré* zugeordnet ist, wird auch die Objektkachel als *kein moiré* klassifiziert. Die entspricht der Markierung einer gesamten Seite, sobald auf einer Kachel ein Moiré erkannt wird.

ABB. 11.10 zeigt die Ergebnisse der Modelle gruppiert nach Objektkacheln und errechnet nach dem



1. Testdatensatz

2. realer Testdatensatz

ABB. 11.10. ROC-Kurven für die Ergebnisse der Modelle gruppiert nach Objektkacheln. 1. zeigt die Ergebnisse auf dem Testdatensatz, 2. die Ergebnisse auf dem realen Testdatensatz. Für die Berechnung der Ergebnisse gilt: Sobald für mindestens eine Klassifizierungskachel, die einer Objektkachel zugeordnet werden kann, die Klasse moiré vorhergesagt wird, so wird die gesamte Objektkachel der Klasse moiré zugeordnet. Die x-Achse der Grafiken zeigt die False-Positive-Rate, die y-Achse die True-Positive Rate bei gegebenem Schwellwert.

beschriebenen Prinzip. Es ist zu erkennen, dass die True-Positive-Rate im Vergleich zur Auswertung nach Klassifizierungskacheln (ABB. 11.7) erhöht ist, während die False-Positive-Rate niedriger liegt. Dies ist auch anhand der gemessenen Metriken erkennbar. Diese liegen für das Modell mit den besten Ergebnissen, dem Resnet50 spatial Modell, bei einem Recall von 0,981 und einer Precision von 0,774 im Vergleich zu 0,908 und 0,95 für das selbe Modell bezogen auf die einzelnen Klassifizierungskacheln. Mit Blick auf die Erkenntnisse, die in Abs. 11.2.2 beschrieben sind, kann angenommen werden, dass auch gruppiert nach Objektkacheln die Ergebnisse für Klassifizierungskacheln mit hoher Auflösung über denen mit niedriger Auflösung liegen. Die in ABB. 11.11 dargestellten Ergebnisse stützen diese Annahme, wobei mit abnehmender Auflösung zwar die True-Positive-Rate sinkt, die False-Positive-Rate jedoch auch abnimmt. Dies spiegelt sich auch in den Metriken wieder:

- Recall: 0,981, Precision: 0,836 bei 300 dpi
- Recall: 0,937, Precision: 0,854 bei 200 dpi
- Recall: 0,933, Precision: 0,852 bei 150 dpi

Die Werte beziehen sich jeweils auf das Resnet50 spatial Modell und den Testdatensatz.

Für die Implementierung der beschriebenen Modelle in eine Software zur Klassifizierung ganzer Seiten kann eine optimierte Methode zur Aggregation der Einzelergebnisse der Klassifizierungskacheln erarbeitet werden. Exemplarisch werden nachfolgend Ergebnisse unter Verwendung einer abgewandelten Aggregationsfunktion errechnet. Anstatt die Objektkachel der Klasse moiré zuzuordnen, sobald mindestens eine der Klassifizierungskacheln der Klasse moiré zugeordnet wird, geschieht die Aggregation hier durch Verwendung des am häufigsten vorhergesagten Klasse unter den Klassifizierungskacheln. Falls eine gleiche Anzahl der Klassifizierungskacheln als moiré und *kein* moiré klassifiziert wurden, wird die Objektkachel als moiré klassifiziert.

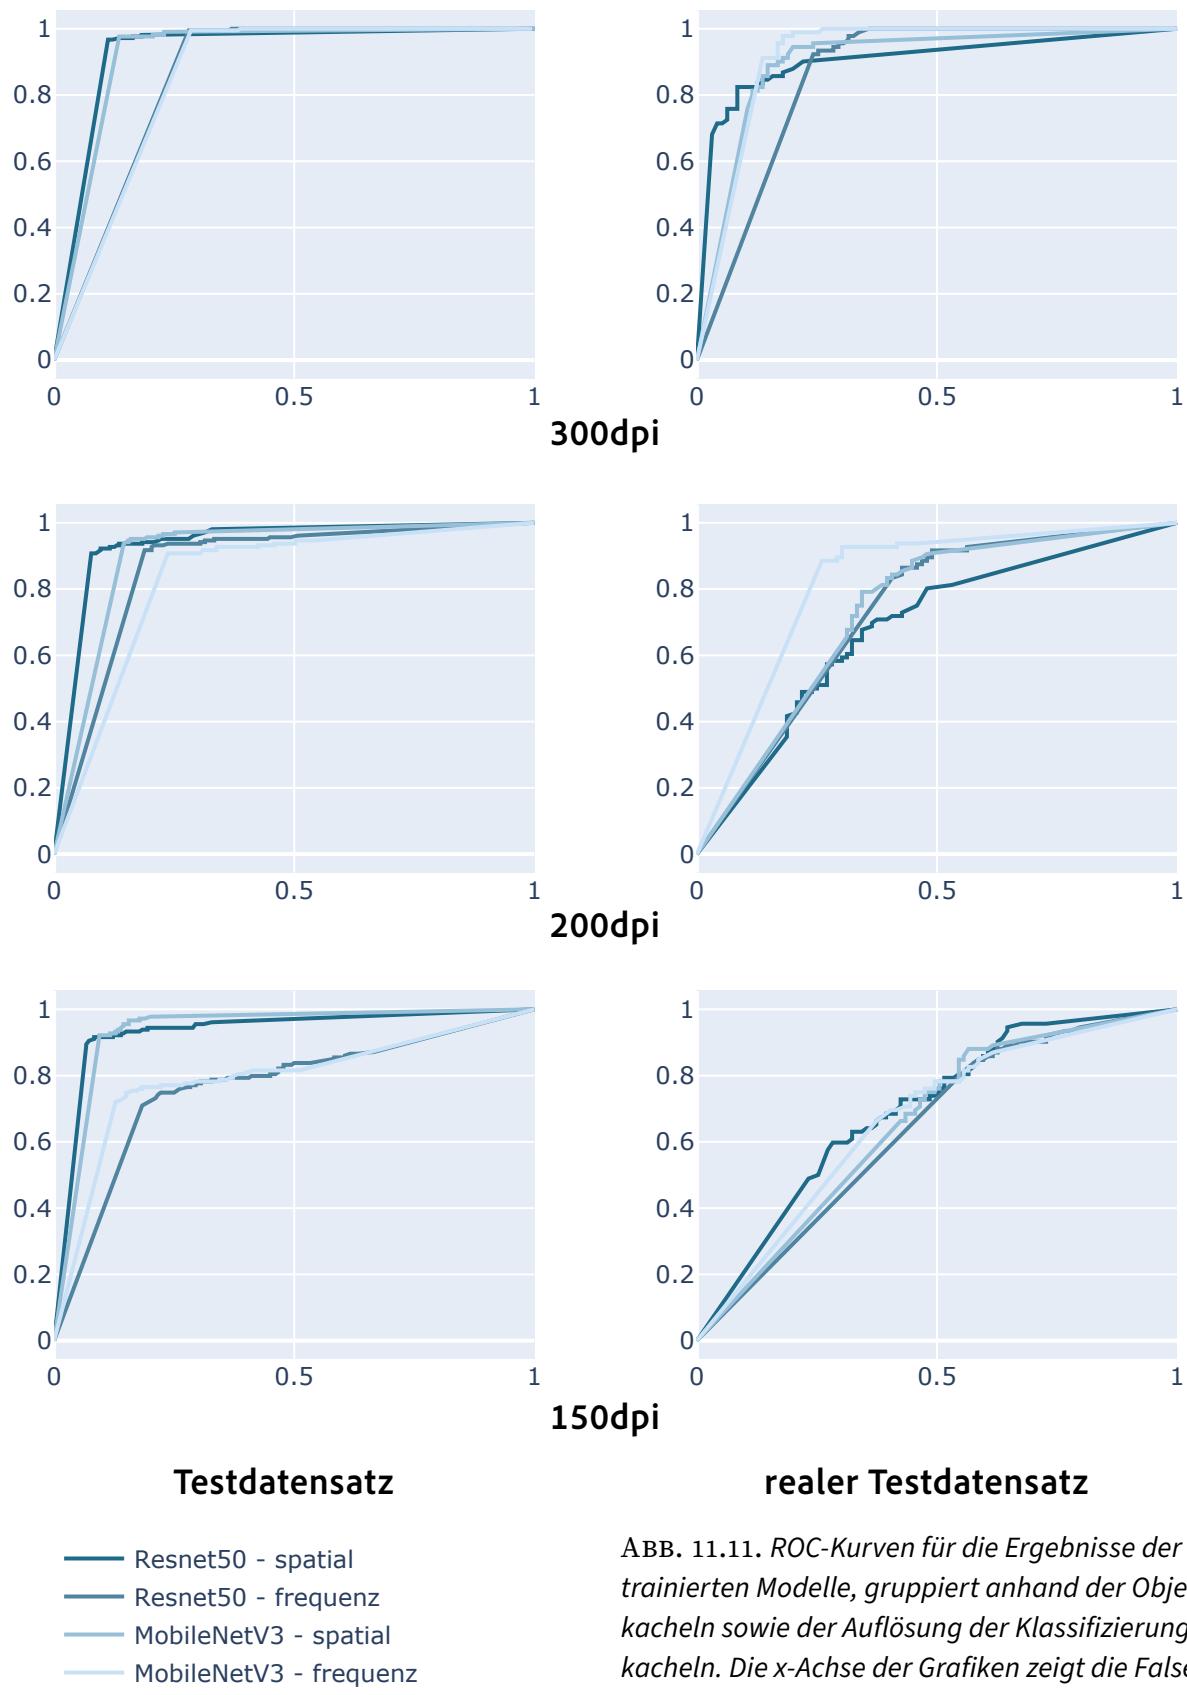


ABB. 11.11. ROC-Kurven für die Ergebnisse der trainierten Modelle, gruppiert anhand der Objektkacheln sowie der Auflösung der Klassifizierungskacheln. Die x-Achse der Grafiken zeigt die False-Positive-Rate, die y-Achse die True-Positive Rate bei gegebenem Schwellwert.

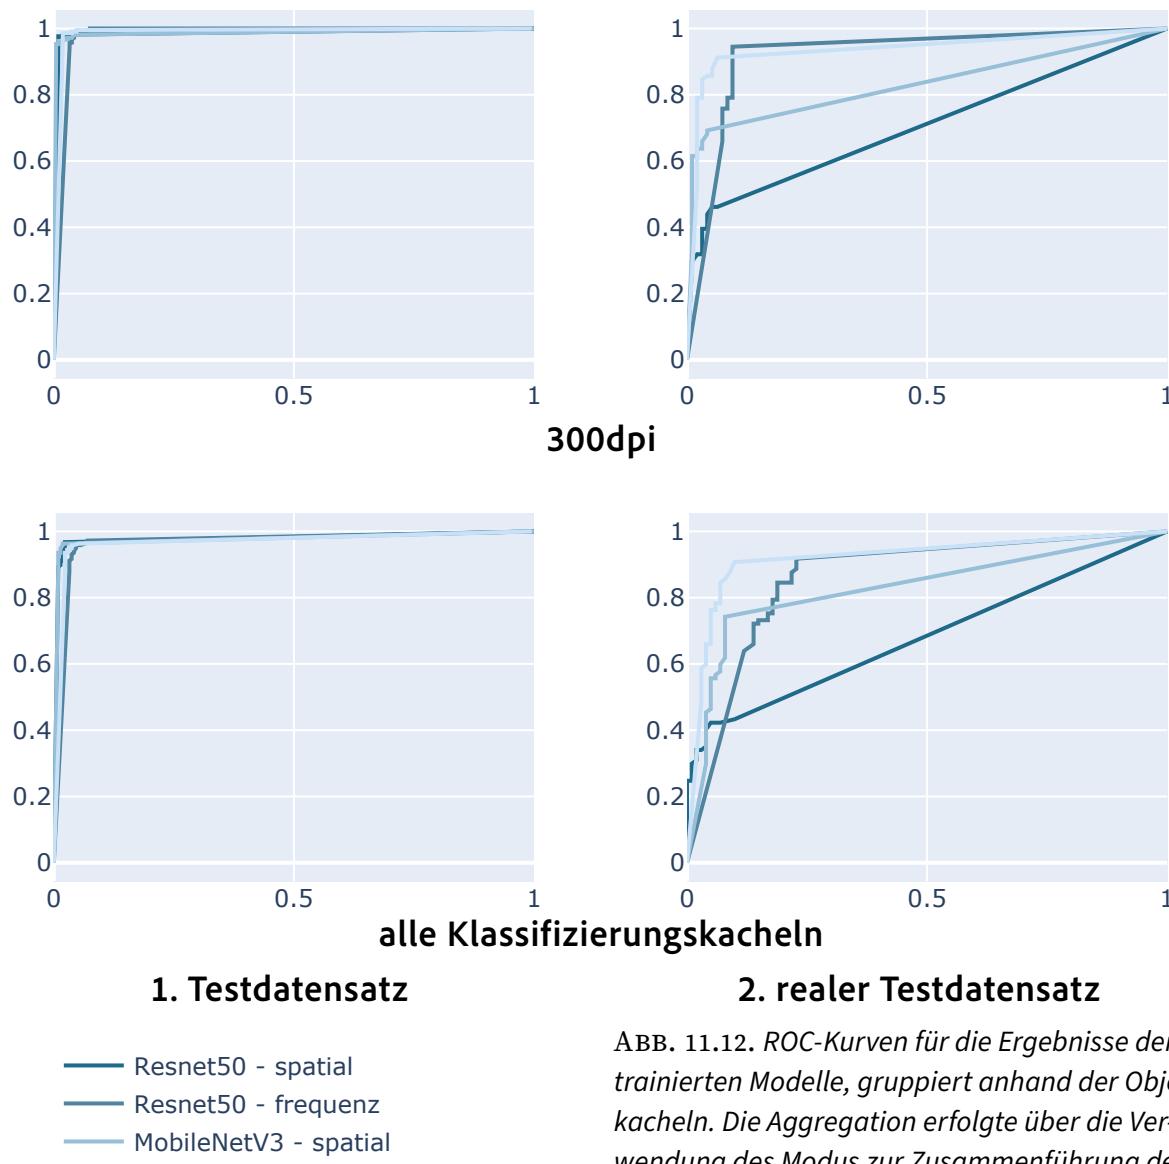


ABB. 11.12. ROC-Kurven für die Ergebnisse der trainierten Modelle, gruppiert anhand der Objektkacheln. Die Aggregation erfolgte über die Verwendung des Modus zur Zusammenführung der Einzelergebnisse. Die x-Achse der Grafiken zeigt die False-Positive-Rate, die y-Achse die True-Positive Rate bei gegebenem Schwellwert.

Wie in ABB. 11.11 zu sehen können so auf dem Testdatensatz nochmals deutlich bessere Ergebnisse erzielt werden. Die Ergebnisse auf dem realen Testdatensatz sind hingegen auf einem vergleichbaren oder leicht besseren Niveau zu den zuvor vorgestellten Ergebnissen. Die jeweils besten Modelle nach Metriken sind wie folgt (siehe: ANHANG 5 und ANHANG 6):

- Das Modell Resnet50 spatial mit einer Precision von 0,981 einem Recall von 0,944 auf dem Testdatensatz.
- Das Modell MobileNetV3 spatial mit einer Precision von 0,809 einem Recall von 0,784 auf dem realen Testdatensatz.

Da in einem realen Szenario eine Zuordnung von Klassifizierungskacheln zu Objektkacheln nicht möglich ist, kann die Verwendung des Modus nur eine Annäherung an eine verbesserte Aggregationsfunktion darstellen. Die Erarbeitung einer solchen verbesserten Aggregationsfunktion kann Teil zukünftiger Forschung sein.

11.2.4. Verwendung der Modelle als Ensemble

In den bisher vorgestellten Ergebnissen erzielten jeweils die spatialen Modelle die besseren Ergebnisse auf dem Testdatensatz, während die frequenzbasierten Modelle sich als besser geeignet zur Klassifizierung der Daten des realen Testdatensatzes erwiesen. Aus diesem Grund soll abschließend geprüft werden, ob ein spatiales und ein frequenzbasiertes Modell als Ensemble eingesetzt werden können, um so die Ergebnisse der Modell weiter zu verbessern. Dafür wurde jeweils ein Ensemble aus den beiden Modellen einer Architektur gebildet.

Die Ergebnisse der Modelle werden zusammengeführt, indem für die errechnete Wahrscheinlichkeit der Klasse *moiré*, bezeichnet mit x , beider Modelle die Unsicherheit der Vorhersage verglichen wird. Die Unsicherheit w wird errechnet durch (11.1). Es wird angenommen, dass eine Vorhersage sicherer ist, je näher sie an 0 oder 1 liegt.

$$(11.1) \quad w(x) = |x - 0.5|$$

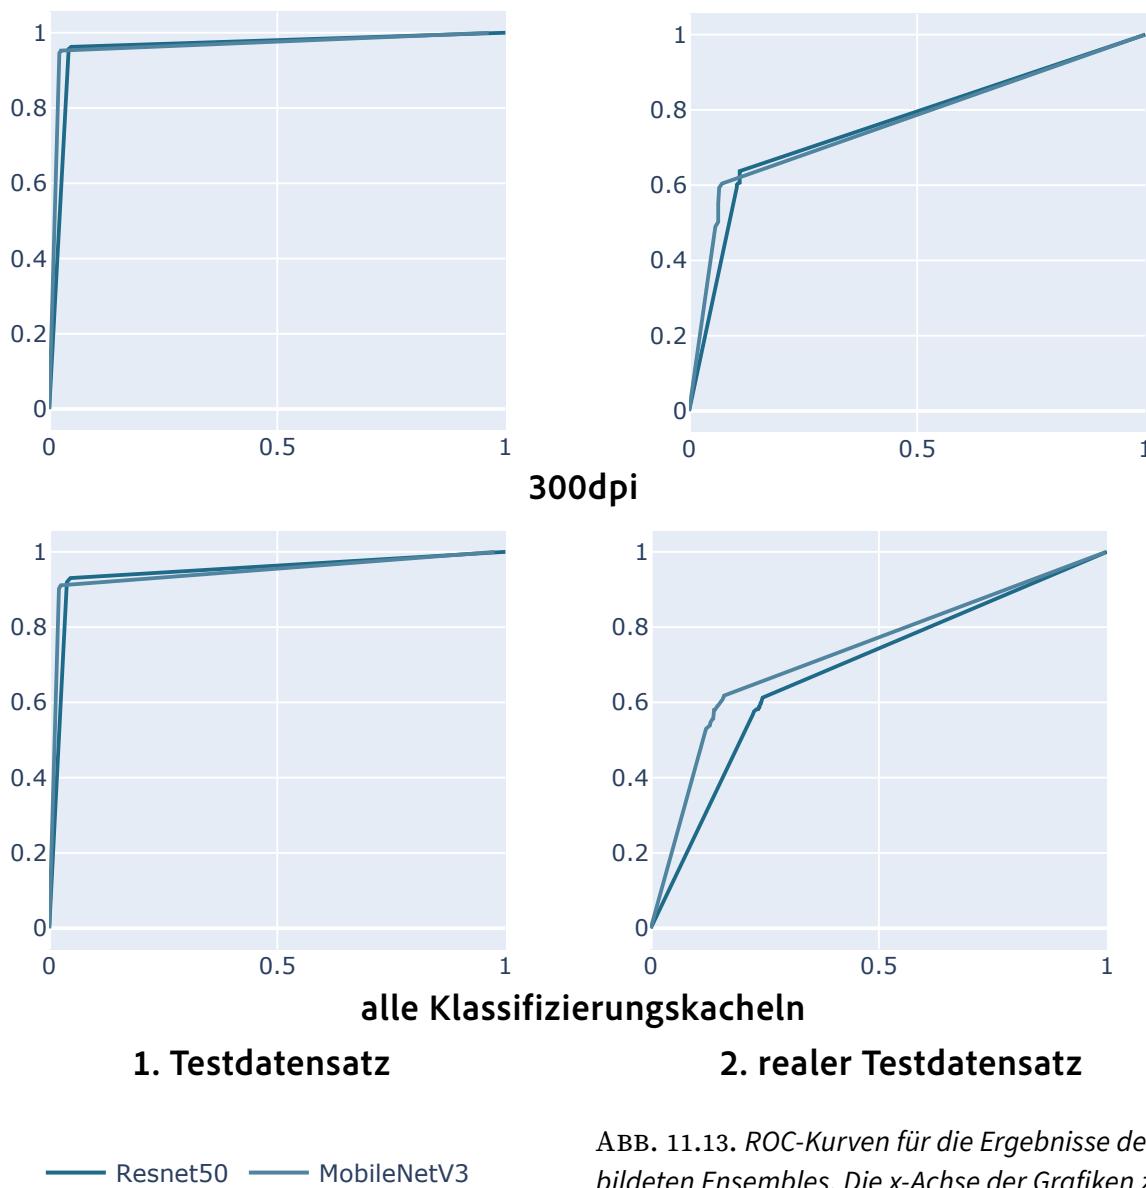


ABB. 11.13. ROC-Kurven für die Ergebnisse der gebildeten Ensembles. Die x-Achse der Grafiken zeigt die False-Positive-Rate, die y-Achse die True-Positive Rate bei gegebenem Schwellwert.

Als Vorhersage des Ensembles wird die Vorhersage des Modelles mit der geringeren Unsicherheit verwendet. Mit Blick auf ABB. 11.13 muss hier festgehalten werden, dass die Verwendung eines Modellensembles die Qualität der Ergebnisse nicht verbessert. Dies zeigt sich auch mit Blick auf die errechneten Metriken. Diese liegen für Recall und Precision bei 0,905 und 0,946 auf dem Testdatensatz beziehungsweise 0,328 und 0,778 auf dem realen Testdatensatz für das Resnet50 Ensemble. Die Werte für das MobileNetV3 Ensemble liegen bei 0,828 und 0,947 auf dem Testdatensatz sowie 0,489 und 0,801 auf dem realen Testdatensatz. Die genannten Werte gelten für die Betrachtung aller Klassifizierungskacheln. Die Werte nur für die 300 dpi Kacheln sind vergleichbar.

12. Fazit und Ausblick

Zusammenfassend kann festgehalten werden, dass sich die Erzeugung von synthetischen Moirés sowie das Training von Klassifizierungsmodellen auf deren Basis als sinnvoll erwiesen haben. Die beschriebenen Methoden bieten darüber hinaus eine Vielzahl an Möglichkeiten zur Weiterentwicklung und Verbesserung der in im Rahmen dieser Arbeit beschriebenen Basis. Es ist anzunehmen, dass die Qualität der Ergebnisse durch Weiterentwicklung verbessert werden kann.

Nachfolgend wird im Detail auf die beiden Hauptteile der Arbeit, die Erzeugung von synthetischen Moiréstrukturen sowie Aufbau und Training der Klassifizierungsmodelle und deren Ergebnisse, eingegangen.

12.1. Erzeugung von synthetischen Moiréstrukturen

Die Erzeugung von synthetischen Moirés hat sich im Rahmen dieser Arbeit als geeigneter Ansatz zur Schaffung von Trainingsdaten für die Moiréerkennung erwiesen. Durch die Erarbeitung des neuen Verfahrens konnten die spezifischen Charakteristika von Moiréstrukturen in der Druckproduktion nachgebildet und im Vergleich zu existierenden Ansätzen (siehe: Abs. 5.1.3) eine größere Bandbreite an Moiréstrukturen erzeugt werden. Die beschriebene Methode bildet eine Basis für weitere Entwicklungen. Die in Abs. 4.2 beschriebenen Kategorien stellen eine Annäherung an mögliche Moiréstrukturen in der Druckproduktion dar. Zukünftige Entwicklungen können sich mit der Erfassung weiterer Einflüsse auf das optische Erscheinungsbild von Moiréstrukturen und deren Umsetzung in zusätzliche Effekte beschäftigen.

Betrachtet man die in Abs. 11.2 dargestellten Ergebnisse, muss festgehalten werden, dass die Ergebnisse der Modelle auf dem Testdatensatz im Vergleich zum realen Testdatensatz deutlich abweichen. Daraus folgt, dass die Eigenschaften der realen Moirés nicht in vollem Umfang nachgebildet werden konnten. Eine Weiterentwicklung der vorgestellten Methode sollte zum Ziel haben, diese Abweichung zu verringern.

In diesem Zusammenhang kann es sinnvoll sein, detailliertere Kenntnisse über die verwendeten Datensätze zu erarbeiten. Eine Möglichkeit hierfür ist das Bilden von Clustern von Moirés basierend auf deren optischen Eigenschaften. Diese Cluster können für eine Weiterentwicklung der Generierungs- und Klassifizierungsmodelle genutzt werden, um die Ergebnisse der Modelle basierend auf dem jeweiligen Cluster zu bewerten und die Modelle gegebenenfalls weiterzuentwickeln.

Die insgesamt erreichte Moirérate von 0,11 kann durch Verfeinerung der Einstellungen in Konfigurationen verbessert werden. Dabei muss jedoch beachtet werden, dass eine solche Verfeinerung zwar den Anteil der erzeugten Objektkacheln mit Moiré erhöhen kann, aber im Gegenzug die Gefahr birgt, dass die Vielfalt der optischen Erscheinungsbilder der Moiréstrukturen sinkt. Letztere ist der zur Sicherstellung der Robustheit der Klassifizierungsmodelle einer verbesserten Moirérate vorzuziehen.

In Abs. 11.1 wurde dargelegt, dass die Entstehung von Moiréstrukturen nicht auf einzelne Effekte oder deren Eigenschaften zurückgeführt werden kann. Das in Abs. 11.1.4 verwendete RandomForest-Modell ist jedoch in der Lage, anhand der Parameter der verwendeten Effekte mit einer hohen Genauigkeit die Entstehung von Moirés vorherzusagen. Daraus kann geschlossen werden, dass die Entstehung von Moiréstrukturen von einem komplexen Zusammenspiel der Parameter abhängt. Der einzige signifikante Zusammenhang der erkannt wurde, betrifft den Kontrast der unveränderten Objektkacheln. Hier konnte in Abs. 11.1 gezeigt werden, dass sich Objektkacheln ohne erkennbares Moiré, insbesondere solche mit einem SSIM-Werte über 0,95, in der Tendenz nahe dem jeweiligen Maximum des Kont-

rastes befinden. Für Objektkacheln mit Moiré ist dies nicht der Fall. In weiteren Untersuchungen sollte geprüft werden, ob dieser Zusammenhang nur im Kontext der Montage eines Patterns gilt, oder ob es sich um eine grundsätzliche Eigenschaft auch von natürlichen Moirés handelt.

12.2. Aufbau und Training der Klassifizierungsmodelle

Für die Implementierung der trainierten Modelle in eine Anwendung in der Druckproduktion sind insbesondere die in Abs. 11.2.3 beschriebenen Ergebnisse relevant. Es konnte gezeigt werden, dass die verwendeten Modellarchitekturen in der Lage sind, eine Klassifizierung sowohl des Spatial- als auch des Frequenzdatensatzes mit Recall- und Precisionwerten deutlich oberhalb von 0,9 zu erlernen. Hier ist insbesondere die Erkenntnis relevant, dass Standardarchitekturen, die primär auf die Erkennung von High-Level Features ausgelegt sind (siehe: [50] und [51]), durch domain adaption in der Lage sind, High-Level Features zu ignorieren und Low-Level Features zu erlernen. Beide der getesteten Modellarchitekturen, Resnet50 und MobileNetV3, erzielten Ergebnisse auf einem vergleichbar hohen Niveau und sind damit für die Lösung des beschriebenen Problems geeignet. Mit Blick auf TABELLE 11.4 sollte für die Verwendung auf einer CPU ein auf der MobileNetV3 basierendes Modell verwendet werden. Bei Verwendung einer GPU sind beide Architekturen geeignet, aufgrund der leicht besseren Ergebnisse wird eine leichte Empfehlung für ein Resnet50 basierendes Modell ausgesprochen.

Entgegen der in Abs. 9.1 aufgestellten Hypothese erwies sich die Verarbeitung der Objektkacheln in mehreren Auflösungen nicht als sinnvoll. Verwendet man anstatt der Klassifizierungskacheln in drei Auflösungen lediglich die Klassifizierungskacheln mit einer Auflösung von 300 dpi, so verbessern sich die Ergebnisse der Modelle (siehe: 11.2.2). Daher wird für Weiterentwicklungen des Verfahrens empfohlen, sich auf die Verarbeitung von Klassifizierungskacheln mit 300 dpi zu konzentrieren. Da durch den Wegfall der übrigen Auflösungen keine Mehrfachverarbeitung aller Ausschnitte einer Seite mehr geschieht, kann es sinnvoll sein, den Algorithmus zur Aufteilung einer Seite in Klassifizierungskacheln anzupassen.

Die Verwendung eines Modellensembles zeigte weniger gute Ergebnisse als erhofft. Nichtsdestotrotz sollte dieser Ansatz in Weiterentwicklungen nicht außer Acht gelassen werden. Zukünftige Verbesserungen können sich mit der Weiterentwicklung der Funktion zur Zusammenführung der Ergebnisse beider Modelle und der Entwicklung einer geeigneten Funktion zur Aggregation von Ergebnissen mehrerer Klassifizierungskacheln beschäftigen.

Betrachtet man isoliert die dritte Gruppe der in Abs. 4.1 beschriebenen Entstehungsbedingungen für Moirés, die Entstehung durch Interferenz mit dem Druckraster, liegt die Verwendung eines Ansatzes nahe, der auf dem Vergleich zweier Eingaben basiert. Die erste Eingabe ist in diesem Fall eine moiré-freie Halbtonkachel, die zweite die ein potenziell moirébehaftete Rasterabbildung der selben Kachel. In zukünftiger Forschung können Modelle erarbeitet werden, welche explizit auf die Erkennung von Moirés aus dieser Gruppe abzielen. Ein solches Modell könnte zum Beispiel auf Basis einer Siamese-Network Architektur in Kombination mit einer Contrastive- oder Triplet-Loss Funktion trainiert werden.

Glossar

Basisebene

Bezeichnet in der Überlagerung eines unveränderten und eines angepassten Rasters das unveränderte Raster.

Boundingbox

Als Boundingbox wird das kleinste Rechteck bezeichnet, dass ein spezifisches Objekt umfänglich einschließt.

Effektebene

Bezeichnet in der Überlagerung eines unveränderten und eines angepassten Rasters das angepasste Raster.

Frequenzdatensatz

Der Frequenzdatensatz beschreibt die erstellten Klassifizierungskacheln umgewandelt in ihre Frequenzdarstellung

Generierungsdatensatz

Der Generierungsdatensatz umfasst 2000 moiréfreie PDF-Seiten, die als Grundlage zur Generierung synthetischer Moirés dienen.

Halbtontbild

Ein Halbtontbild verwendet zur Erzeugung von Farbeindrücken eine Mischung der Intensitäten der jeweiligen Grundfarben.

Klassifizierungskachel

Eine Klassifizierungskachel ist eine Kachel mit einer Größe von 224x224 Pixeln, welches aus den Objektkacheln erstellt und zum Training und zum Test der erstellten Modelle genutzt wird.

natürlicher Moirédatensatz

Der natürliche Moirédatensatz umfasst alle im Rahmen dieser Arbeit gesammelten natürlichen Moirés.

natürliches Moiré

Als natürliches Moiré werden Moirés bezeichnet, die in der Druckproduktion gesammelt und nicht anhand des in Abs. 8 beschriebenen Modells künstlich erzeugt wurde,

Objektkachel

Als Objektkachel wird ein Ausschnitt aus einer Seite des Generierungsdatensatzes bezeichnet, nachdem ein Pattern montiert wurde.

Objektmaske

Eine Objektmaske markiert ein Objekt in einer Seite des Generierungsdatensatzes und dient als Grundlage zur Erzeugung von Objektkacheln.

Pattern

Ein Pattern ist eine angepasste Rasterabbildung, die durch Kombination mit einer unveränderten Objektkachel potenziell eine Moiréstruktur entstehen lässt. Es entsteht durch Kombination einer Patternvorlage mit ein- oder mehreren Patterneffekten.

Patterneffekt

Ein Patterneffekt ist ein Effekt, der auf eine Patternvorlage angewandt werden kann, um ein Pattern zu erzeugen.

Patternvorlage

Eine Patternvorlage ist ein Bild mit einer regelmäßigen Rasterstruktur auf 0°, welche durch Patterneffekte angepasst und in eine unveränderte Objektkacheln montiert wird, um eine Objektkachel zu erzeugen.

Rasterbild

Ein Rasterbild verwendet zur Erzeugung eines Farbeindrucks nicht die Intensität eines Pixel. Stattdessen wird eine Anzahl an Pixeln einer Fläche entsprechend der gewünschten Intensität des Farbeindruckes mit voller Intensität verwendet. Durch den Abstand zur Abbildung entsteht im menschlichen Sehapparat ein Halbtonfarbeindruck.

Spatialdatensatz

Der Spatialdatensatz beschreibt die Menge aller erzeugten Klassifizierungskacheln ohne Umwandlung in eine Frequenzdarstellung.

synthetisches Moiré

Ein synthetisches Moiré ist ein Moiré, dass durch das in Abs. 8 beschriebene Modell künstlich erzeugt wurde.

unveränderte Objektkachel

Als unveränderte Objektkachel wird der Ausschnitt aus einer Seite des Generierungsdatensatz bezeichnet, welche durch die Boundingbox einer Objektmaske definiert wird.

Sie entspricht der Objektkachel vor der Montage eines Patterns.

Literaturverzeichnis

- [1] Nicolai, C., „Moiré Index“, Die Gestalten Verlag GmbH & Co. KG, Berlin (2010)
- [2] Amidror, I., „The Theory of the Moiré Phenomenon - Volume 1: Periodic Layers“, Second Edition, Springer-Verlag London Limited (2009)
- [3] Gonzalez, R.C., Woods, R.E., „Digital Image Processing“, Fourth Edition, Pearson Education Limited (2018)
- [4] Quan, J., Linhart, L., Lin, M.L. et al. „Phonon renormalization in reconstructed MoS₂ moiré superlattices“ Nat. Mater. 20, 1100–1105 (2021). <https://doi.org/10.1038/s41563-021-00960-1>
- [5] Kafri, O. & Glatt, I., „The Physics of Moiré Metrology“, (1990)
- [6] Garcia, D. & De Queiroz, R., „Face-Spoofing 2D-Detection Based on Moiré-Pattern Analysis“, IEEE Transactions on Information Forensics and Security. 10. 778-786. 10.1109/TIFS.2015.2411394, (2015)
- [7] Bracewell, R.N., „The Fourier Transform and its applications - Third Edition“ McGraw-Hill Book Co, Singapur (2000)
- [8] Kipphan, H. (Hrsg.), „Handbuch der Printmedien - Technologien und Produktionsverfahren“, Springer-Verlag Berlin Heidelberg (2000)
- [9] „Rasterarten - Prinergy 10.0 - Kodak Workflow Documentation“, kodak.com, <https://workflow-help.kodak.com/display/PRIN100/Screen+types> (abgerufen am 19.5.2024)
- [10] Hoffmann-Walbeck, T. et al., „Standards in der Medienproduktion“, Springer-Verlag Berlin Heidelberg (2013)
- [11] „Pantone-Farbsysteme – Für Grafik“ pantone.com <https://www.pantone.com/eu/de/farbsysteme/fur-grafik> (abgerufen: 1.5.2024)
- [12] „European Color Initiative“ - eci.org <http://www.eci.org/doku.php?id=de:colorstandards:offset> (abgerufen: 1.5.2024)
- [13] Gemeinhardt, J. et al., „Wiedergabe moderner Rasterverfahren unter dem Einfluss verschiedener Druckbedingungen im Offsetdruck“, Fogra Forschungsgesellschaft Druck e.V (2009)
- [14] Bühler P. et al., „Bibliothek der Mediengestaltung - Digitale Fotografie“, Springer-Verlag GmbH Deutschland (2017)
- [15] He, Z. & Bouman, C., „AM/FM halftoning: Digital halftoning through simultaneous modulation of dot size and dot density“, J. Electronic Imaging. 13. 286-302. 10.1117/1.1669555., (2004)
- [16] Shanxin, Y. et al. „NTIRE 2020 Challenge on Image Demoiréing: Methods and Results“, IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW), Seattle, WA, USA, 2020, pp. 1882-1893, doi: 10.1109/CVPRW50498.2020.00238
- [17] X. Luo, J. Zhang, M. Hong, Y. Qu, Y. Xie and C. Li, „Deep Wavelet Network with Domain Adaptation for Single Image Demoiréing,“ 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW), Seattle, WA, USA, 2020, pp. 1687-1694, doi: 10.1109/CVPRW50498.2020.00218.
- [18] D. Xu, Y. Chu and Q. Sun, „Moiré Pattern Removal via Attentive Fractal Network,“ 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW), Seattle, WA, USA, 2020, pp. 1943-1952, doi: 10.1109/CVPRW50498.2020.00244.
- [19] Liu, Shuai & Li, Chenghua & Nan, Nan & Zong, Ziyao & Song, Ruixia. (2020). MMDM: Multi-frame and Multi-scale for Image Demoiréing. 1751-1759. 10.1109/CVPRW50498.2020.00225.
- [20] Y. Sun, Y. Yu and W. Wang, „Moiré Photo Restoration Using Multiresolution Convolutional Neural Networks,“ in IEEE Transactions on Image Processing, vol. 27, no. 8, pp. 4160-4172, Aug. 2018, doi: 10.1109/TIP.2018.2834737.

- [21] C. Yang, Z. Yang, Y. Ke, T. Chen, M. Grzegorzek and J. See, „Doing More With Moiré Pattern Detection in Digital Photos,“ in IEEE Transactions on Image Processing, vol. 32, pp. 694-708, 2023, doi: 10.1109/TIP.2022.3232232.
- [22] B. He, C. Wang, B. Shi and L. Duan, „Mop Moiré Patterns Using MopNet,“ 2019 IEEE/CVF International Conference on Computer Vision (ICCV), Seoul, Korea (South), 2019, pp. 2424-2432, doi: 10.1109/ICCV.2019.00251.
- [23] E. Abraham, „Moiré Pattern Detection using Wavelet Decomposition and Convolutional Neural Network,“ 2018 IEEE Symposium Series on Computational Intelligence (SSCI), Bangalore, India, 2018, pp. 1275-1279, doi: 10.1109/SSCI.2018.8628746.
- [24] G. Huang, Z. Liu, L. Van Der Maaten and K. Q. Weinberger, „Densely Connected Convolutional Networks,“ 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), Honolulu, HI, USA, 2017, pp. 2261-2269, doi: 10.1109/CVPR.2017.243.
- [25] Ronneberger, Olaf & Fischer, Philipp & Brox, Thomas. (2015). U-Net: Convolutional Networks for Biomedical Image Segmentation. LNCS. 9351. 234-241. 10.1007/978-3-319-24574-4_28.
- [26] M. Tan, R. Pang and Q. V. Le, „EfficientDet: Scalable and Efficient Object Detection,“ 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), Seattle, WA, USA, 2020, pp. 10778-10787, doi: 10.1109/CVPR42600.2020.01079.
- [27] K. He, X. Zhang, S. Ren and J. Sun, „Deep Residual Learning for Image Recognition,“ 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), Las Vegas, NV, USA, 2016, pp. 770-778, doi: 10.1109/CVPR.2016.90.
- [28] Szeliski R. „Computer Vision: Algorithms and Applications“, 2nd Edition, Springer (2021)
- [29] „Welcome to Python.org“ [python.org](https://www.python.org/) <https://www.python.org/> (abgerufen: 8.5.2024)
- [30] „Pillow (PIL Fork) 10.3.0 documentation“ [pillow.readthedocs.io](https://pillow.readthedocs.io/en/stable/) <https://pillow.readthedocs.io/en/stable/> (abgerufen: 8.5.2024)
- [31] „OpenCV - Open Computer Vision Library“ opencv.org <https://opencv.org/> (abgerufen: 8.5.2024)
- [32] „Fotos transformieren und stilische Grafiken gestalten | Adobe Photoshop“ [\[33\] „Aktionen und das Aktionenbedienfeld in Photoshop“ \[helpx.adobe.com\]\(https://helpx.adobe.com/de/photoshop/using/actions-actions-panel.html\) <https://helpx.adobe.com/de/photoshop/using/actions-actions-panel.html> \(abgerufen: 8.5.2024\)

\[34\] „Scripting in Photoshop“ \[helpx.adobe.com\]\(https://helpx.adobe.com/photoshop/using/scripting.html\) <https://helpx.adobe.com/photoshop/using/scripting.html> \(abgerufen: 8.5.2024\)

\[35\] „NumPy“ \[numpy.org\]\(https://numpy.org/\) <https://numpy.org/> \(abgerufen: 8.5.2024\)

\[36\] „PyTorch“ \[pytorch.org\]\(https://pytorch.org/\) <https://pytorch.org/> \(abgerufen: 8.5.2024\)

\[37\] Kirillov, A et al., „Segment Anything“, \(2023\)

\[38\] „Open Source Data Labeling | Label Studio“ \[labelstud.io\]\(https://labelstud.io/\) <https://labelstud.io/> \(abgerufen: 8.5.2024\)

\[39\] Bühler P. et al., „Bibliothek der Mediengestaltung - Digitale Farbe“, Springer-Verlag GmbH Deutschland \(2017\)

\[40\] „GitHub - facebookresearch/segment-anything“ \[github.com\]\(https://github.com/\), \[https://dl.fbaipublicfiles.com/segmentAnything/sam_vit_h_4b8939.pth\]\(https://dl.fbaipublicfiles.com/segmentAnything/sam_vit_h_4b8939.pth\) \(abgerufen am 10.5.2024\)](https://www.adobe.com/de/products/photoshop/landpa.html?gclid=Cj0KCQjw8pKxBhD_ARIsAPrG45kWXST2SauQkzxjBpKC2ZAL9Wbw-w1O298CZljZomcWJJw9J3yXyxoAg1_EALw_wcB&mv=search&s_kwcid=AL!3085!3!474052075834!e!!g!!adobe%20photoshop!1419109629!54636022246&mv=search&mv2=paidsearch&sdid=2XBSBWB&ef_id=Cj0KCQjw8pKxBhD_ARIsAPrG45kWXST2SauQkzxjBpKC2ZAL9Wbw-w1O298CZljZomcWJJw9J3yXyxoAg1_EALw_wcB:G:s&s_kwcid=AL!3085!3!474052075834!e!!g!!adobe%20photoshop!1419109629!54636022246&gad_source=1)

-
- [41] „GitHub - tesseract-ocr/tesseract“ [github.com, https://github.com/tesseract-ocr/tesseract](https://github.com/tesseract-ocr/tesseract) (abgerufen am 10.5.2024)
 - [42] „Mischmodi in Adobe Photoshop“ [helpx.adobe.com, https://helpx.adobe.com/de/photoshop/using/blending-modes.html](https://helpx.adobe.com/de/photoshop/using/blending-modes.html) (abgerufen am 10.5.24)
 - [43] „Pillow/src/libImaging/Chops.c“ [https://github.com, https://github.com/python-pillow/Pillow/blob/main/src/libImaging/Chops.c](https://github.com/python-pillow/Pillow/blob/main/src/libImaging/Chops.c) (abgerufen am 10.5.24)
 - [44] „numpy.random.normal“, [numpy.org, https://numpy.org/doc/stable/reference/random/generated/numpy.random.normal.html](https://numpy.org/doc/stable/reference/random/generated/numpy.random.normal.html) (abgerufen am 10.5.2024)
 - [45] Zhou Wang, A. C. Bovik, H. R. Sheikh and E. P. Simoncelli, „Image quality assessment: from error visibility to structural similarity,“ in IEEE Transactions on Image Processing, vol. 13, no. 4, pp. 600-612, April 2004, doi: 10.1109/TIP.2003.819861.
 - [46] Gustavson, S., „Simplex noise demystified“ (2005)
 - [47] „GitHub - dinox0r/liquify-tool: A liquify effect tool demo for the article <http://geekofficedog.blogspot.com/2015/01/liquify-effect-hello-swirl-2.html> , github.com <https://github.com/dinox0r/liquify-tool>“ (abgerufen am 19.5.24)
 - [48] Gharbi, M. et al., „Deep joint demosaicking and denoising“ TOG (2016)
 - [49] Bishop, C. M., „Pattern recognition and machine learning“, Springer (2006)
 - [50] Kaiming, H. et al., „Deep residual learning for image recognition“, CVPR (2015)
 - [51] Howard, A. et al., „Searching for MobileNetV3“, ICCV (2019)
 - [52] Koch, G., Zemel, R., & Salakhutdinov, R. „Siamese Neural Networks for One-shot Image Recognition“, (2015)
 - [53] Kingma, D. P. and Ba, J., „Adam: A Method for Stochastic Optimization“, ICLR (2015)
 - [54] „Adam – PyTorch 2.3 documentation“, [pytorch.org, https://pytorch.org/docs/stable/generated/torch.optim.Adam.html](https://pytorch.org/docs/stable/generated/torch.optim.Adam.html) (abgerufen am 11.5.2024)
 - [55] „8.9 Release Notes Red Hat Enterprise Linux 8 | Red Hat Customer Portal“, [access.redhat.com, https://access.redhat.com/documentation/de-de/red_hat_enterprise_linux/8/html/8.9_release_notes/index](https://access.redhat.com/documentation/de-de/red_hat_enterprise_linux/8/html/8.9_release_notes/index) (abgerufen am 11.5.2024)
 - [56] „4.2. Permutation feature importance — scikit-learn 1.4.2 documentation“, [scikit-learn.org, https://scikit-learn.org/stable/modules/permutation_importance.html#permutation-importance](https://scikit-learn.org/stable/modules/permutation_importance.html#permutation-importance)

Abbildungsverzeichnis

- ABB. 2.1 eigene Abbildung
ABB. 2.2 eigene Abbildung
ABB. 2.3 übernommen aus [2](fig 2.2)
ABB. 2.4 eigene Abbildung
ABB. 2.5 eigene Abbildung, Originalbild: <https://unsplash.com/de/fotos/ein-steinturm-mit-einer-fahne-auf-der-spitze-dl5flzIgtXE>, abgerufen am 5.5.2024
ABB. 3.1 eigene Abbildung
ABB. 3.2 eigene Abbildung
ABB. 3.3 übernommen aus [8](Abb. 2.1-74)
ABB. 3.4 übernommen aus [8](Abb. 3.2-12)
ABB. 3.5 eigene Abbildung, Originalbild: <https://unsplash.com/de/fotos/ein-steinturm-mit-einer-fahne-auf-der-spitze-dl5flzIgtXE>, abgerufen am 5.5.2024
ABB. 3.6 übernommen aus [10](Abb.2.43)
ABB. 3.7 eigene Abbildung, Originalbild: <https://unsplash.com/de/fotos/ein-steinturm-mit-einer-fahne-auf-der-spitze-dl5flzIgtXE>, abgerufen am 5.5.2024
ABB. 4.1 eigene Abbildung, Original übernommen aus archivierten Druckdaten
ABB. 4.2 eigene Abbildung, Original übernommen aus archivierten Druckdaten
ABB. 4.3 eigene Abbildung, Original übernommen aus archivierten Druckdaten
ABB. 4.4 eigene Abbildung, Original übernommen aus archivierten Druckdaten
ABB. 4.5 eigene Abbildung, Original übernommen aus archivierten Druckdaten
ABB. 4.6 eigene Abbildung
ABB. 4.7 eigene Abbildung
ABB. 4.8 eigene Abbildung
ABB. 4.9 eigene Abbildung
ABB. 4.10 eigene Abbildung, Original übernommen aus archivierten Druckdaten
ABB. 4.11 eigene Abbildung, Original aus archivierten Druckdaten
ABB. 4.12 eigene Abbildung, Original aus archivierten Druckdaten
ABB. 4.13 eigene Abbildung
ABB. 4.14 eigene Abbildung
ABB. 4.15 eigene Abbildung
ABB. 4.16 eigene Abbildung
ABB. 4.17 eigene Abbildung, Original aus archivierten Druckdaten
ABB. 4.18 eigene Abbildung
ABB. 4.19 eigene Abbildung
ABB. 4.20 eigene Abbildung
ABB. 4.21 eigene Abbildung
ABB. 4.22 eigene Abbildung
ABB. 4.23 eigene Abbildung
ABB. 4.24 eigene Abbildung
ABB. 5.1 übernommen aus [21] Fig. 3
ABB. 7.1 eigene Abbildung, 1. übernommen aus dem in [16] beschriebenen Datensatz. 2. übernommen archivierten Druckdaten
ABB. 7.2 eigene Abbildung, Original aus archivierten Druckdaten
ABB. 7.3 eigene Abbildung, Original aus archivierten Druckdaten

ABB. 7.4	eigene Abbildung, Original aus archivierten Druckdaten
ABB. 8.1	<i>eigene Abbildung</i>
ABB. 8.2	eigene Abbildung, Original aus archivierten Druckdaten
ABB. 8.3	eigene Abbildung, Original aus archivierten Druckdaten
ABB. 8.4	eigene Abbildung, Original aus archivierten Druckdaten
ABB. 8.5	<i>eigene Abbildung</i>
ABB. 8.6	<i>eigene Abbildung</i>
ABB. 8.7	eigene Abbildung, Original aus archivierten Druckdaten
ABB. 8.8	<i>eigene Abbildung</i>
ABB. 8.9	<i>eigene Abbildung</i>
ABB. 8.10	<i>eigene Abbildung</i>
ABB. 9.1	eigene Abbildung, Original aus archivierten Druckdaten
ABB. 9.2	eigene Abbildung, Original aus archivierten Druckdaten
ABB. 9.3	eigene Abbildung, Original aus archivierten Druckdaten
ABB. 10.1	<i>eigene Abbildung</i>
ABB. 10.2	<i>eigene Abbildung</i>
ABB. 10.3	übernommen aus https://towardsdatascience.com/a-comprehensive-guide-to-convolutional-neural-networks-the-eli5-way-3bd2b1164a53 , abgerufen am 5.5.2024
ABB. 10.4	übernommen aus [50], Figure 5
ABB. 11.1	<i>eigene Abbildung</i>
ABB. 11.2	<i>eigene Abbildung</i>
ABB. 11.3	<i>eigene Abbildung</i>
ABB. 11.4	<i>eigene Abbildung</i>
ABB. 11.5	<i>eigene Abbildung</i>
ABB. 11.6	<i>eigene Abbildung</i>
ABB. 11.7	<i>eigene Abbildung</i>
ABB. 11.8	<i>eigene Abbildung</i>
ABB. 11.9	<i>eigene Abbildung</i>
ABB. 11.10	<i>eigene Abbildung</i>
ABB. 11.11	<i>eigene Abbildung</i>
ABB. 11.12	<i>eigene Abbildung</i>
ABB. 11.13	<i>eigene Abbildung</i>
ANHANG 1	<i>eigene Abbildung</i>
ANHANG 2	<i>eigene Abbildungen</i>

Anhang

Anhang 1: Herleitung der Formel (4.4)

Herleitung der Berechnung des Winkels

Es kann angenommen werden, dass der Winkel in ABB. 8.1 von rechts nach links linear von 0 bis zu Θ_{\max} streben. Θ_{\max} entspricht dem Winkel α , sich aus einem gedachten rechtwinkligen Dreieck mit der Verlängerung der horizontalen als Ankathete und der vertikalen der Abbildung als Gegenkathete ergibt. Die ursprüngliche Höhe und Breite der Abbildung wird entsprechend mit 1 definiert.

Da s_2 den Verlängerungsfaktor der linken Ecke angibt, ergibt sich also zur Berechnung des maximalen Winkels:

$$\tan^{-1}\left(\frac{s_2-1}{1}\right)$$

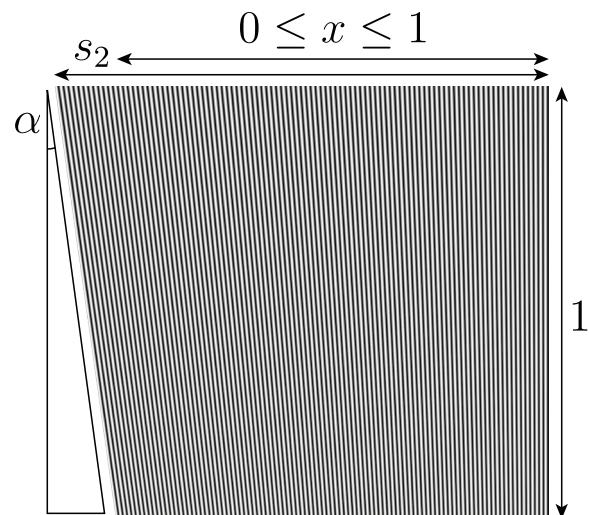


ABB. 8.1. einseitige perspektivische Verzerrung

Der Winkelunterschied zwischen dem maximalen und dem minimalen Winkel wird auf den Wertebereich von x verteilt, indem der maximale Winkel durch s_2 geteilt wird. Es ist zu beachten, dass bei einem Wert von $x = 1$ der Winkel an der ursprünglichen nicht der angepassten Ecke der Effektebene ausgegeben werden soll. Um die Formel für alle Winkel für Θ_1 verwendbar zu machen, wird Θ_1 addiert. Die Errechnung des maximalen Winkels bleibt unverändert, da hier nur der Winkelunterschied zwischen Basis- und Effektebene betrachtet wird. Es ergibt sich also:

$$\theta_2(x) = x \cdot \frac{\tan^{-1}\left(\frac{s_2-1}{1}\right)}{s_2} + \Theta_1$$

Herleitung der Berechnung der Periode

Analog zur Berechnung des Winkels an einer Position x wird angenommen, dass die Periode des Rasters der Effektebene linear von der rechten Ecke zur angepassten linken Ecke steigt. Die Periode an der rechten Ecke entspricht also T_1 . Da, angenommen es hätte keine Verzerrung stattgefunden, die Periode an der linken Ecke ebenfalls T_1 ist, entspricht die Gesamtzunahme der Periode $s_2 - 1$. Diese wird wiederum auf den Wertebereich von x verteilt, indem sie durch s_2 geteilt wird. Es ergibt sich:

$$t_2(x) = x \frac{(s_2 - 1)T_1}{s_2} + T_1$$

Anhang 2: Schwellwertmatrizen

Anbei finden sich die zur Erstellung der Patternvorlagen genutzten Schwellwertmatrizen. Die Zahl in jeder Zelle ist der Schwellwert, ab dem die Zelle zur Modellierung eines Tonwertes aktiviert wird.

Grundform Linie

256	224	192	160	128	96	64	32	16	48	80	112	144	176	208	240
254	222	190	158	126	94	62	30	14	46	78	110	142	174	206	238
252	220	188	156	124	92	60	28	12	44	76	108	140	172	204	236
250	218	186	154	122	90	58	26	10	42	74	106	138	170	202	234
248	216	184	152	120	88	56	24	8	40	72	104	136	168	200	232
246	214	182	150	118	86	54	22	6	38	70	102	134	166	198	230
244	212	180	148	116	84	52	20	4	36	68	100	132	164	196	228
242	210	178	146	114	82	50	18	2	34	66	98	130	162	194	226
241	209	177	145	113	81	49	17	1	33	65	97	129	161	193	225
243	211	179	147	115	83	51	19	3	35	67	99	131	163	195	227
245	213	181	149	117	85	53	21	5	37	69	101	133	165	197	229
247	215	183	151	119	87	55	23	7	39	71	103	135	167	199	231
249	217	185	153	121	89	57	25	9	41	73	105	137	169	201	233
251	219	187	155	123	91	59	27	11	43	75	107	139	171	203	235
253	221	189	157	125	93	61	29	13	45	77	109	141	173	205	237
255	223	191	159	127	95	63	31	15	47	79	111	143	175	207	239

Grundform Kreis

254	246	234	230	186	174	170	94	95	171	175	187	231	235	247	255
250	238	226	194	178	166	102	86	87	103	167	179	195	227	239	251
242	222	202	182	162	110	90	82	83	91	111	163	183	203	223	243
218	210	190	158	118	98	78	34	35	79	99	119	159	191	211	219
214	198	154	126	106	74	42	26	27	43	75	107	127	155	199	215
206	150	134	114	70	50	30	22	23	31	51	71	115	135	151	207
146	138	122	66	54	38	18	6	7	19	39	55	67	123	139	147
142	130	62	58	46	14	10	2	3	11	15	47	59	63	131	143
144	132	64	60	48	16	12	4	1	9	13	45	57	61	129	141
148	140	124	68	56	40	20	8	5	17	37	53	65	121	137	145
208	152	136	116	72	52	32	24	21	29	49	69	113	133	149	205
216	200	156	128	108	76	44	28	25	41	73	105	125	153	197	213
220	212	192	160	120	100	80	36	33	77	97	117	157	189	209	217
244	224	204	184	164	112	92	84	81	89	109	161	181	201	221	241
252	240	228	196	180	168	104	88	85	101	165	177	193	225	237	249
256	248	236	232	188	176	172	96	93	169	173	185	229	233	245	253

Grundform Karo

256	252	236	232	186	200	202	203	196	176	205	224	234	242	248	254
246	240	194	182	168	164	143	146	152	170	145	138	213	218	230	250
238	180	211	148	96	124	117	118	130	120	98	102	140	192	220	244
228	178	162	104	122	85	76	83	87	72	78	128	92	150	207	226
184	172	94	113	80	48	50	51	40	42	57	64	100	111	158	198
216	154	109	68	46	26	22	34	31	24	36	53	74	126	136	188
209	166	115	70	55	29	15	11	8	13	20	44	89	107	160	190
214	141	105	81	58	27	16	2	4	10	33	60	66	133	156	222
221	155	132	65	59	32	9	3	1	5	17	37	61	90	134	174
189	159	106	88	43	19	12	7	6	14	28	54	69	114	165	208
187	135	125	73	52	35	23	30	18	21	25	45	67	108	153	215
197	157	110	99	63	56	41	39	38	49	47	79	112	93	171	183
225	206	149	91	127	77	71	86	62	75	84	121	103	161	177	227
243	219	191	139	101	97	119	129	82	116	123	95	147	210	179	237
249	229	217	212	137	144	169	151	131	142	163	167	181	193	239	245
253	247	241	233	223	204	175	195	173	201	199	185	231	235	251	255

Anhang 3: Auswertung der Modelle anhand der Klassifizierungskacheln

Übersicht über die Ergebnisse der Modelle unter Verwendung der einzelnen Klassifizierungskacheln. Für die verwendeten Metriken Accuracy, Precision und Recall sind pro Datensatz sind jeweils die besten Ergebnisse markiert. Zusätzlich sind die True-Positives (TP), True-Negatives (TN), False-Positives (FP) und False-Negatives (FN) dargestellt.

Datensatz	Modell	TP	TN	FP	FN	Accuracy	Precision	Recall
realer Testdatensatz	Resnet50 <i>spatial</i>	1150	2403	329	2356	0,57	0,779	0,328
	MobileNetV3 <i>spatial</i>	1715	2306	426	1791	0,646	0,801	0,489
	Resnet50 <i>frequenz</i>	2353	2037	695	1153	0,704	0,772	0,671
	MobileNetV3 <i>frequenz</i>	2079	2320	412	1427	0,705	0,835	0,593
Testdatensatz	Resnet50 <i>spatial</i>	14007	24258	801	1425	0,945	0,95	0,908
	MobileNetV3 <i>spatial</i>	13962	24277	782	1470	0,944	0,947	0,905
	Resnet50 <i>frequenz</i>	12735	23357	1702	2697	0,891	0,882	0,825
	MobileNetV3 <i>frequenz</i>	12743	23608	1451	2689	0,898	0,898	0,826

Anhang 4: Auswertung der Modelle anhand der Klassifizierungskacheln gruppiert nach Auflösung, Testdatensatz

Übersicht über die erzielten Ergebnisse auf dem Testdatensatz und dem realen Testdatensatz, gruppiert nach verwendetem Modell, Datensatz und Auflösung der verarbeiteten Klassifizierungskacheln. Für die verwendeten Metriken Accuracy, Precision und Recall sind pro Datensatz sind jeweils die besten Ergebnisse markiert. Zusätzlich sind die True-Positives (TP), True-Negatives (TN), False-Positives (FP) und False-Negatives (FN) dargestellt.

Testdatensatz

Auflösung	Modell	TP	TN	FP	FN	Accuracy	Precision	Recall
150	Resnet50 <i>spatial</i>	1955	5264	210	278	0,937	0,903	0,876
	MobileNetV3 <i>spatial</i>	1946	5298	176	287	0,940	0,917	0,871
	Resnet50 <i>frequenz</i>	1159	5142	332	1074	0,818	0,777	0,519
	MobileNetV3 <i>frequenz</i>	1161	5248	226	1072	0,832	0,837	0,520
200	Resnet50 <i>spatial</i>	3779	7303	233	520	0,936	0,942	0,879
	MobileNetV3 <i>spatial</i>	3857	7314	222	442	0,944	0,946	0,897
	Resnet50 <i>frequenz</i>	3347	7043	493	952	0,878	0,872	0,779
	MobileNetV3 <i>frequenz</i>	3356	6994	542	943	0,875	0,861	0,781
300	Resnet50 <i>spatial</i>	8273	11691	358	627	0,953	0,959	0,930
	MobileNetV3 <i>spatial</i>	8159	11665	384	741	0,946	0,955	0,917
	Resnet50 <i>frequenz</i>	8229	11172	877	671	0,926	0,904	0,925
	MobileNetV3 <i>frequenz</i>	8226	11366	683	674	0,935	0,923	0,924

Realer Testdatensatz

Auflösung	Modell	TP	TN	FP	FN	Accuracy	Precision	Recall
150	Resnet50 <i>spatial</i>	300	693	187	373	0,639	0,616	0,446
	MobileNetV3 <i>spatial</i>	389	660	220	284	0,675	0,639	0,578
	Resnet50 <i>frequenz</i>	426	517	363	247	0,607	0,540	0,633
	MobileNetV3 <i>frequenz</i>	292	652	228	381	0,608	0,562	0,434
200	Resnet50 <i>spatial</i>	238	792	104	811	0,530	0,696	0,227
	MobileNetV3 <i>spatial</i>	520	743	153	529	0,649	0,773	0,496
	Resnet50 <i>frequenz</i>	649	673	223	400	0,680	0,744	0,619
	MobileNetV3 <i>frequenz</i>	711	776	120	338	0,765	0,856	0,678
300	Resnet50 <i>spatial</i>	612	918	38	1172	0,558	0,942	0,343
	MobileNetV3 <i>spatial</i>	806	903	53	978	0,624	0,938	0,452
	Resnet50 <i>frequenz</i>	1278	847	109	506	0,776	0,921	0,716
	MobileNetV3 <i>frequenz</i>	1076	892	64	708	0,718	0,944	0,603

Anhang 5: Auswertung der Modelle anhand der Klassifizierungsachen gruppiert nach Objektkachel

Übersicht über die erzielten Ergebnisse auf dem Testdatensatz und dem realen Testdatensatz, gruppiert nach verwendetem Modell, Datensatz und der zugehörigen Objektkachel. Für die verwendeten Metriken Accuracy, Precision und Recall sind pro Datensatz die besten Ergebnisse markiert. Zusätzlich sind die True-Positives (TP), True-Negatives (TN), False-Positives (FP) und False-Negatives (FN) dargestellt.

Datensatz	Modell	TP	TN	FP	FN	Accuracy	Precision	Recall
realer Testdatensatz	Resnet50 <i>spatial</i>	31	100	1	66	0,662	0,969	0,320
	MobileNetV3 <i>spatial</i>	76	83	18	21	0,803	0,809	0,784
	Resnet50 <i>frequenz</i>	49	96	5	48	0,732	0,907	0,505
	MobileNetV3 <i>frequenz</i>	65	96	5	32	0,813	0,929	0,670
Testdatensatz	Resnet50 <i>spatial</i>	204	212	4	12	0,963	0,981	0,944
	MobileNetV3 <i>spatial</i>	202	209	7	14	0,951	0,967	0,935
	Resnet50 <i>frequenz</i>	203	214	2	13	0,965	0,990	0,940
	MobileNetV3 <i>frequenz</i>	198	211	5	18	0,947	0,975	0,917

Anhang 6: Auswertung der Modelle anhand der Klassifizierungskacheln gruppiert nach Objektkachel und Auflösung

Übersicht über die erzielten Ergebnisse auf dem Testdatensatz und dem realen Testdatensatz, gruppiert nach verwendetem Modell, Datensatz, Auflösung der Klassifizierungskachel und der zugehörigen Objektkachel. Für die verwendeten Metriken Accuracy, Precision und Recall sind pro Datensatz jeweils die besten Ergebnisse markiert. Zusätzlich sind die True-Positives (TP), True-Negatives (TN), False-Positives (FP) und False-Negatives (FN) dargestellt.

Testdatensatz

Auflösung	Modell	TP	TN	FP	FN	Accuracy	Precision	Recall
150	Resnet50 <i>spatial</i>	209	172	41	4	0,894	0,836	0,981
	MobileNetV3 <i>spatial</i>	213	106	107	0	0,749	0,666	1,000
	Resnet50 <i>frequenz</i>	209	170	43	4	0,890	0,829	0,981
	MobileNetV3 <i>frequenz</i>	213	122	91	0	0,786	0,701	1,000
200	Resnet50 <i>spatial</i>	193	173	33	13	0,888	0,854	0,937
	MobileNetV3 <i>spatial</i>	195	139	67	11	0,811	0,744	0,947
	Resnet50 <i>frequenz</i>	196	168	38	10	0,883	0,838	0,951
	MobileNetV3 <i>frequenz</i>	191	120	86	15	0,755	0,690	0,927
300	Resnet50 <i>spatial</i>	167	150	29	12	0,885	0,852	0,933
	MobileNetV3 <i>spatial</i>	142	112	67	37	0,709	0,679	0,793
	Resnet50 <i>frequenz</i>	173	151	28	6	0,905	0,861	0,966
	MobileNetV3 <i>frequenz</i>	139	131	48	40	0,754	0,743	0,777

realer Testdatensatz

Auflösung	Modell	TP	TN	FP	FN	Accuracy	Precision	Recall
150	Resnet50 <i>spatial</i>	75	85	10	16	0,860	0,882	0,824
	MobileNetV3 <i>spatial</i>	85	69	26	6	0,828	0,766	0,934
	Resnet50 <i>frequenz</i>	81	81	14	10	0,871	0,853	0,890
	MobileNetV3 <i>frequenz</i>	89	78	17	2	0,898	0,840	0,978
200	Resnet50 <i>spatial</i>	56	69	27	40	0,651	0,675	0,583
	MobileNetV3 <i>spatial</i>	85	50	46	11	0,703	0,649	0,885
	Resnet50 <i>frequenz</i>	76	62	34	20	0,719	0,691	0,792
	MobileNetV3 <i>frequenz</i>	89	64	32	7	0,797	0,736	0,927
300	Resnet50 <i>spatial</i>	67	55	44	25	0,639	0,604	0,728
	MobileNetV3 <i>spatial</i>	82	33	66	10	0,602	0,554	0,891
	Resnet50 <i>frequenz</i>	71	49	50	21	0,628	0,587	0,772
	MobileNetV3 <i>frequenz</i>	71	50	49	21	0,634	0,592	0,772

Anhang 7: Auswertung der Modellensembles

Übersicht über die erzielten Ergebnisse auf dem Testdatensatz und dem realen Testdatensatz, gruppiert nach Modellensemble und Datensatz. Für die verwendeten Metriken Accuracy, Precision und Recall sind pro Datensatz die besten Ergebnisse markiert. Zusätzlich sind die True-Positives (TP), True-Negatives (TN), False-Positives (FP) und False-Negatives (FN) dargestellt.

Alle Klassifizierungskacheln

Datensatz	Modell	TP	TN	FP	FN	Accuracy	Precision	Recall
realer Testdatensatz	Resnet50	14007	24258	801	1425	0,945	0,946	0,905
	MobileNetV3	13962	24277	782	1470	0,944	0,947	0,828
Testdatensatz	Resnet50	1150	2403	329	2356	0,570	0,778	0,328
	MobileNetV3	1715	2306	426	1791	0,645	0,801	0,489

300 dpi Klassifizierungskacheln

Datensatz	Modell	TP	TN	FP	FN	Accuracy	Precision	Recall
realer Testdatensatz	Resnet50	8273	11691	358	627	0,953	0,959	0,930
	MobileNetV3	8159	11665	384	741	0,946	0,955	0,917
Testdatensatz	Resnet50	612	918	38	1172	0,558	0,942	0,343
	MobileNetV3	806	903	53	978	0,624	0,938	0,452